

Analisi Statistica del Contenuto Alcolico nel Vino

Modelli Grafici e Predittivi sul Wine Dataset

Eros Pinzani

Contents

Abstract	3
1 Introduzione	3
1.1 Il Dataset Wine	3
1.2 Variabile Target: Contenuto Alcolico	3
1.3 Obiettivi dello Studio	3
1.3.1 Fase 1: Analisi della Popolazione Globale (senza Cultivar)	4
1.3.2 Fase 2: Analisi con Cultivar	4
1.3.3 Metodologia	4
1.4 Software	4
2 Osservazioni e Preprocessing dei Dati	5
2.1 Visualizzazione Dataset	5
2.2 Preparazione dei Dati	7
2.2.1 Dataset per la Fase 1: Popolazione Globale	7
2.2.2 Dataset per la Fase 2: Analisi Completa con Cultivar	7
3 Analisi Esplorativa	9
3.1 Statistiche Descrittive e Density Plot	9
3.2 BoxPlot	11
3.3 Matrici Scatterplot	12
3.4 Matrice di Correlazione	13
3.4.1 Correlazioni - Intera Popolazione	13
3.4.2 Correlazioni per Cultivar - Confronto	14
3.5 Heatmap delle Correlazioni	15
3.5.1 Heatmap - Intera Popolazione	15
3.6 Sintesi dell'Analisi Esplorativa	17
4 Modelli Grafici Indiretti	18
4.1 Introduzione alla Matrice di Concentrazione	18
4.2 Matrice di Concentrazione - Intera Popolazione	18
4.2.1 Correlazioni Parziali - Intera Popolazione	18
4.3 Selezione Modello	18
4.4 Grafo Indiretto - Intera Popolazione	18
4.5 Grafo Indiretto - Wine Dataset con Cultivar	18
4.6 Risultati Ottenuti	18
5 Modelli Grafici Diretti (DAG)	19
5.1 DAG - Intera Popolazione	19
5.1.1 DAG Libero	19
5.1.2 DAG con Alch come Variabile Target	19

5.2	DAG - Wine Dataset con Cultivar	19
5.2.1	DAG Libero con Cultivar	19
5.2.2	DAG con Variabili Esogene e Target	19
5.3	Considerazioni sui DAG	19
6	Modello Predittivo	20
6.1	Intera Popolazione	20
6.1.1	Definizione Modelli Base	20
6.1.2	Selezione con BIC	20
6.1.3	Diagnostica del Modello	20
6.1.4	Verifica Multicollinearità	20
6.2	Wine Dataset con Cultivar	20
6.2.1	Definizione Modelli Base	20
6.2.2	Selezione con BIC	20
6.2.3	Diagnostica del Modello	20
6.3	Confronto Modelli	20
7	Conclusioni	21
7.1	Bibliografia	21

Abstract

In questo progetto analizziamo la composizione chimica di diversi campioni di vino con l'obiettivo di valutare in che modo alcune sostanze chimiche influenzino il contenuto alcolico. L'analisi prenderà in considerazione sia l'intera popolazione dei campioni sia il ruolo della variabile categorica cultivar, al fine di verificare se il tipo di coltivazione rappresenti un fattore determinante. L'approccio metodologico integra modelli grafici indiretti per individuare dipendenze condizionali, grafi aciclici diretti per esplorare relazioni causali, e regressione lineare multipla per quantificare l'effetto dei predittori chimici sul contenuto alcolico.

1 Introduzione

1.1 Il Dataset Wine

Il dataset Wine è un insieme di dati classico utilizzato in ambito statistico e di machine learning, contiene i risultati di analisi chimiche condotte su 178 campioni di vino provenienti dalla stessa regione italiana ma prodotti da tre diversi coltivatori (cultivar).

Le **13 variabili chimiche** misurate per ciascun campione sono:

- **Alch** (Alcohol): contenuto alcolico
- **Malca** (Malic Acid): acido malico
- **Ash**: ceneri
- **Aloa** (Alkalinity of Ash): alcalinità delle ceneri
- **Mgns** (Magnesium): magnesio
- **Ttlp** (Total Phenols): fenoli totali
- **Flvn** (Flavonoids): flavonoidi
- **Nnfp** (Nonflavanoid Phenols): fenoli non flavonoidi
- **Prnt** (Proanthocyanins): proantocianidine
- **Clri** (Color Intensity): intensità del colore
- **Hue**: tonalità
- **Oodw** (OD280/OD315 of diluted wines): rapporto di assorbanza
- **Prln** (Proline): prolina

Inoltre, il dataset include la variabile categorica **Cult** (Cultivar) che identifica il tipo di coltivazione (1, 2 o 3) da cui proviene ciascun campione.

1.2 Variabile Target: Contenuto Alcolico

In questa analisi, la variabile **Alch** (contenuto alcolico) rappresenta la nostra variabile target. Il contenuto alcolico è una delle caratteristiche più rilevanti nella valutazione della qualità del vino e dipende da molteplici fattori biochimici che intervengono durante il processo di fermentazione e produzione.

Comprendere quali componenti chimici influenzino maggiormente il contenuto alcolico permette di:

1. Identificare le **relazioni causali** tra la composizione chimica e il grado alcolico
2. Costruire **modelli predittivi** per stimare il contenuto alcolico a partire da altre misure chimiche
3. Valutare se e come il **tipo di cultivar** influenzi tali relazioni

1.3 Obiettivi dello Studio

L'obiettivo principale di questo studio è analizzare il contenuto alcolico nel vino utilizzando tecniche statistiche avanzate per comprendere le relazioni tra le variabili chimiche e il ruolo del cultivar. L'analisi si articola in due fasi distinte:

1.3.1 Fase 1: Analisi della Popolazione Globale (senza Cultivar)

Nella prima fase analizziamo l'intero dataset **escludendo la variabile Cult**, concentrandoci esclusivamente sulle relazioni chimiche pure tra le sostanze. Questo approccio permette di:

- Identificare le **dipendenze condizionali** tra le variabili chimiche attraverso modelli grafici indiretti (Gaussian Graphical Models)
- Studiare le **relazioni causali** tra componenti chimici mediante grafi aciclici diretti (DAG)
- Costruire **modelli predittivi** per il contenuto alcolico basati unicamente su fattori chimici
- Comprendere la struttura intrinseca delle relazioni biochimiche indipendentemente dal tipo di coltivazione

1.3.2 Fase 2: Analisi con Cultivar

Nella seconda fase includiamo la variabile **Cult** per valutare l'impatto del tipo di cultivar sulla composizione chimica e sul contenuto alcolico. Questa analisi permette di:

- Verificare se il cultivar modifica le **relazioni di dipendenza** tra le variabili chimiche
- Determinare se il tipo di coltivazione ha un **effetto diretto** sul contenuto alcolico
- Confrontare i modelli con e senza cultivar per valutare il **contributo informativo** di questa variabile categorica
- Esplorare eventuali **pattern di interazione** tra cultivar e componenti chimici

1.3.3 Metodologia

Per raggiungere questi obiettivi utilizzeremo tre approcci statistici complementari:

1. **Modelli Grafici Indiretti (Gaussian Graphical Models)**: per identificare le dipendenze condizionali tra variabili attraverso la matrice di concentrazione (inversa della matrice di covarianza)
2. **Modelli Grafici Diretti (DAG - Directed Acyclic Graphs)**: per esplorare possibili relazioni causali tra le variabili chimiche e il contenuto alcolico
3. **Regressione Lineare Multipla**: per quantificare l'effetto dei predittori chimici sul contenuto alcolico e valutare la capacità predittiva dei modelli

1.4 Software

L'analisi è condotta utilizzando il software **R**, un ambiente open-source ampiamente utilizzato per l'analisi statistica e la modellizzazione dei dati. Sono stati impiegati diversi pacchetti specializzati per l'analisi di modelli grafici gaussiani, l'inferenza causale tramite grafi aciclici diretti, la visualizzazione dei dati e la regressione lineare multipla.

Il codice R Markdown utilizzato per generare questo documento garantisce la **riproducibilità** completa dell'analisi.

2 Osservazioni e Preprocessing dei Dati

Prima di procedere con l'analisi statistica vera e propria, è fondamentale esplorare la struttura del dataset e preparare i dati in modo adeguato per le diverse fasi dell'analisi.

2.1 Visualizzazione Dataset

Il dataset **Wine** è disponibile nel pacchetto **gRbase** di R e contiene informazioni chimiche su 178 campioni di vino italiano. Iniziamo caricando il dataset e osservandone la struttura.

```
# Caricamento dataset Wine
data(wine)

# Visualizzazione delle prime righe
head(wine)
```

```
##   Cult  Alch Mlca  Ash Aloa Mgns Ttlp Flvn Nnfp Prnt Clri  Hue Oodw Prln
## 1   v1 14.23 1.71 2.43 15.6 127 2.80 3.06 0.28 2.29 5.64 1.04 3.92 1065
## 2   v1 13.20 1.78 2.14 11.2 100 2.65 2.76 0.26 1.28 4.38 1.05 3.40 1050
## 3   v1 13.16 2.36 2.67 18.6 101 2.80 3.24 0.30 2.81 5.68 1.03 3.17 1185
## 4   v1 14.37 1.95 2.50 16.8 113 3.85 3.49 0.24 2.18 7.80 0.86 3.45 1480
## 5   v1 13.24 2.59 2.87 21.0 118 2.80 2.69 0.39 1.82 4.32 1.04 2.93 735
## 6   v1 14.20 1.76 2.45 15.2 112 3.27 3.39 0.34 1.97 6.75 1.05 2.85 1450
```

La funzione `head()` mostra le **prime 6 osservazioni** del dataset, permettendoci di vedere i valori “grezzi” delle variabili per i primi campioni di vino. Questo ci consente di verificare immediatamente il formato dei dati e di avere un'idea dei range di valori per ciascuna variabile chimica. Possiamo osservare, ad esempio, che il contenuto alcolico (Alch) varia tra valori intorno a 13-14%, mentre la prolina (Prol) presenta valori nell'ordine delle centinaia.

Per ottenere una visione più completa della distribuzione dei dati, utilizziamo la funzione `summary()`:

```
# Statistiche descrittive per tutte le variabili
summary(wine)
```

```
##   Cult      Alch      Mlca      Ash      Aloa
## v1:59   Min.   :11.03   Min.   :0.740   Min.   :1.360   Min.   :10.60
## v2:71   1st Qu.:12.36   1st Qu.:1.603   1st Qu.:2.210   1st Qu.:17.20
## v3:48   Median :13.05   Median :1.865   Median :2.360   Median :19.50
##          Mean   :13.00   Mean   :2.336   Mean   :2.367   Mean   :19.49
##          3rd Qu.:13.68   3rd Qu.:3.083   3rd Qu.:2.558   3rd Qu.:21.50
##          Max.   :14.83   Max.   :5.800   Max.   :3.230   Max.   :30.00
##      Mgns      Ttlp      Flvn      Nnfp
## Min.   : 70.00   Min.   :0.980   Min.   :0.340   Min.   :0.1300
## 1st Qu.: 88.00   1st Qu.:1.742   1st Qu.:1.205   1st Qu.:0.2700
## Median : 98.00   Median :2.355   Median :2.135   Median :0.3400
## Mean   : 99.74   Mean   :2.295   Mean   :2.029   Mean   :0.3619
## 3rd Qu.:107.00   3rd Qu.:2.800   3rd Qu.:2.875   3rd Qu.:0.4375
## Max.   :162.00   Max.   :3.880   Max.   :5.080   Max.   :0.6600
##      Prnt      Clri      Hue      Oodw
## Min.   :0.410   Min.   :1.280   Min.   :0.4800   Min.   :1.270
## 1st Qu.:1.250   1st Qu.:3.220   1st Qu.:0.7825   1st Qu.:1.938
## Median :1.555   Median :4.690   Median :0.9650   Median :2.780
## Mean   :1.591   Mean   :5.058   Mean   :0.9574   Mean   :2.612
## 3rd Qu.:1.950   3rd Qu.:6.200   3rd Qu.:1.1200   3rd Qu.:3.170
## Max.   :3.580   Max.   :13.000   Max.   :1.7100   Max.   :4.000
##      Prln
## Min.   : 278.0
## 1st Qu.: 500.5
## Median : 673.5
## Mean   : 746.9
## 3rd Qu.: 985.0
```

```
## Max. :1680.0
```

Il `summary()` fornisce una panoramica statistica completa del dataset:

- Per le **variabili numeriche** (Alch, Maac, Ash, ecc.), vengono calcolati:
 - **Min** e **Max**: valori minimo e massimo osservati
 - **1st Qu.** e **3rd Qu.**: primo e terzo quartile (25° e 75° percentile)
 - **Median**: valore mediano (50° percentile)
 - **Mean**: media aritmetica
- Per la **variabile categorica Cult**, viene mostrata la **frequenza** di ciascun livello (cultivar)

Queste statistiche sono fondamentali per identificare eventuali caratteristiche peculiari delle variabili, come la presenza di outlier o distribuzioni asimmetriche.

Esaminiamo ora la struttura formale del dataset:

```
# Struttura del dataset
str(wine)
```

```
## 'data.frame': 178 obs. of 14 variables:
## $ Cult: Factor w/ 3 levels "v1","v2","v3": 1 1 1 1 1 1 1 1 1 1 ...
## $ Alch: num 14.2 13.2 13.2 14.4 13.2 ...
## $ Mlca: num 1.71 1.78 2.36 1.95 2.59 1.76 1.87 2.15 1.64 1.35 ...
## $ Ash : num 2.43 2.14 2.67 2.5 2.87 2.45 2.45 2.61 2.17 2.27 ...
## $ Aloa: num 15.6 11.2 18.6 16.8 21 15.2 14.6 17.6 14 16 ...
## $ Mgns: int 127 100 101 113 118 112 96 121 97 98 ...
## $ Ttlp: num 2.8 2.65 2.8 3.85 2.8 3.27 2.5 2.6 2.8 2.98 ...
## $ Flvn: num 3.06 2.76 3.24 3.49 2.69 3.39 2.52 2.51 2.98 3.15 ...
## $ Nnfp: num 0.28 0.26 0.3 0.24 0.39 0.34 0.3 0.31 0.29 0.22 ...
## $ Prnt: num 2.29 1.28 2.81 2.18 1.82 1.97 1.98 1.25 1.98 1.85 ...
## $ Clri: num 5.64 4.38 5.68 7.8 4.32 6.75 5.25 5.05 5.2 7.22 ...
## $ Hue : num 1.04 1.05 1.03 0.86 1.04 1.05 1.02 1.06 1.08 1.01 ...
## $ Oodw: num 3.92 3.4 3.17 3.45 2.93 2.85 3.58 3.58 2.85 3.55 ...
## $ Prln: int 1065 1050 1185 1480 735 1450 1290 1295 1045 1045 ...
```

```
# Dimensioni del dataset
dim(wine)
```

```
## [1] 178 14
```

La funzione `str()` (structure) rivela che il dataset contiene **178 osservazioni** (campioni di vino) e **14 variabili**. Possiamo notare che:

- Le prime 13 variabili (da **Alch** a **Prol**) sono **variabili numeriche continue** (num) che rappresentano misure chimiche ottenute tramite analisi di laboratorio
- La variabile **Cult** è una variabile **categorica** (Factor) con tre livelli (v1, v2, v3), che identifica il tipo di cultivar da cui proviene ciascun campione

Questa distinzione è cruciale per le analisi successive, poiché le tecniche statistiche appropriate differiscono a seconda della natura delle variabili.

Approfondiamo la distribuzione dei campioni tra i tre cultivar:

```
# Distribuzione dei campioni per cultivar
table(wine$Cult)
```

```
##
## v1 v2 v3
## 59 71 48
```

```
# Proporzioni percentuali
round(prop.table(table(wine$Cult)) * 100, 1)
```

```
##
##   v1   v2   v3
## 33.1 39.9 27.0
```

La tabella di frequenza mostra che:

- Il **cultivar v1** conta 59 campioni (33.1% del totale)
- Il **cultivar v2** è il più rappresentato con 71 campioni (39.9%)
- Il **cultivar v3** presenta 48 campioni (27.0%)

Sebbene i tre cultivar non siano perfettamente bilanciati, tutti presentano un **numero sufficiente di osservazioni** ($n > 30$) per condurre analisi statistiche robuste e ottenere stime affidabili sia per l'intera popolazione che per i singoli gruppi.

2.2 Preparazione dei Dati

Come descritto nella sezione degli obiettivi, l'analisi si articola in **due fasi distinte** che richiedono due versioni del dataset:

2.2.1 Dataset per la Fase 1: Popolazione Globale

Per la prima fase dell'analisi, creiamo un dataset che **esclude la variabile Cult**, contenente esclusivamente le 13 misure chimiche. Questo ci permetterà di studiare le relazioni chimiche “pure” tra le sostanze, indipendentemente dal tipo di coltivazione.

```
# Creazione dataset senza la variabile Cult
wine_no_cult <- wine[, -which(names(wine) == "Cult")]

# Verifica della struttura
dim(wine_no_cult)
```

```
## [1] 178 13
```

```
names(wine_no_cult)
```

```
## [1] "Alch" "Mlca" "Ash"  "Aloa" "Mgns" "Ttlp" "Flvn" "Nnfp" "Prnt" "Clri"
## [11] "Hue"  "Oodw" "Prln"
```

Il dataset `wine_no_cult` contiene **13 variabili** (tutte continue) e sarà utilizzato per:

- Analisi esplorativa delle relazioni chimiche
- Costruzione di modelli grafici indiretti (UG)
- Inferenza di grafi causali (DAG) senza l'influenza del cultivar
- Modelli di regressione basati esclusivamente su predittori chimici

2.2.2 Dataset per la Fase 2: Analisi Completa con Cultivar

Per la seconda fase, utilizzeremo il **dataset completo wine** che include la variabile categorica **Cult**. Questo ci permetterà di:

- Valutare l'effetto del tipo di cultivar sulle relazioni tra variabili chimiche
- Verificare se il cultivar influenza direttamente il contenuto alcolico
- Confrontare i modelli con e senza cultivar

Prima di procedere, convertiamo la variabile `Cult` in fattore, se non lo è già, per assicurarci che R la tratti correttamente come variabile categorica nelle analisi successive.

```
# Verifica e conversione di Cult in fattore  
wine$Cult <- as.factor(wine$Cult)  
  
# Verifica dei livelli  
levels(wine$Cult)
```

```
## [1] "v1" "v2" "v3"
```

Con i dati ora preparati possiamo procedere con l'analisi esplorativa approfondita che ci permetterà di comprendere le distribuzioni delle variabili, le loro correlazioni e le eventuali differenze tra i cultivar.

3 Analisi Esplorativa

L'analisi esplorativa permette di comprendere le distribuzioni, identificare outlier, visualizzare relazioni bivariate, quantificare correlazioni e confrontare i cultivar.

- Comprendere la **distribuzione** delle variabili chimiche e della variabile target (contenuto alcolico)
- Identificare eventuali **outlier** o valori anomali che potrebbero influenzare le analisi successive
- Visualizzare le **relazioni bivariate** tra le variabili attraverso grafici a dispersione
- Quantificare le **correlazioni lineari** tra i predittori chimici e il contenuto alcolico
- Confrontare le **caratteristiche distributive** dei tre cultivar per evidenziare eventuali differenze sistematiche

L'analisi esplorativa fornisce quindi una **base intuitiva** per interpretare i risultati dei modelli più complessi che costruiremo nelle sezioni successive. In particolare, l'esame delle correlazioni tra variabili ci darà indicazioni preliminari su quali componenti chimici potrebbero essere maggiormente associati al contenuto alcolico, mentre il confronto tra cultivar ci permetterà di valutare se il tipo di coltivazione introduce variabilità sistematica nella composizione chimica del vino.

In questa sezione utilizzeremo diverse tecniche di visualizzazione:

1. **Density plots:** per esaminare la forma delle distribuzioni univariate, verificare la presenza di asimmetrie o multimodalità, e confrontare visivamente le distribuzioni del contenuto alcolico tra i tre cultivar
2. **Boxplots:** per identificare la posizione centrale, la dispersione e la presenza di outlier, con particolare attenzione alle differenze del contenuto alcolico tra i cultivar
3. **Scatterplot matrices:** per esplorare le relazioni bivariate tra le variabili chimiche più rilevanti e individuare pattern lineari o non lineari
4. **Matrici di correlazione e heatmap:** per quantificare e visualizzare l'intensità delle associazioni lineari tra tutte le coppie di variabili, sia per l'intera popolazione che separatamente per ciascun cultivar

Questa esplorazione visiva e numerica ci consentirà di formulare **ipotesi informate** sulle relazioni tra variabili che saranno successivamente testate formalmente attraverso modelli grafici e regressione lineare multipla.

3.1 Statistiche Descrittive e Density Plot

Iniziamo l'analisi esplorativa esaminando la distribuzione della nostra **variabile target**: il contenuto alcolico (Alch). La Tabella seguente riporta le principali statistiche descrittive per l'intera popolazione e per ciascun cultivar.

```
# Statistiche per l'intera popolazione
stat_globali <- wine %>%
  summarise(
    Gruppo = "Globale",
    N = n(),
    Media = round(mean(Alch), 2),
    Dev_Std = round(sd(Alch), 2),
    Minimo = round(min(Alch), 2),
    Q1 = round(quantile(Alch, 0.25), 2),
    Mediana = round(median(Alch), 2),
    Q3 = round(quantile(Alch, 0.75), 2),
    Massimo = round(max(Alch), 2)
  )

# Statistiche per cultivar
stat_cultivar <- wine %>%
  group_by(Cult) %>%
  summarise(
    N = n(),
```

```

Media = round(mean(Alch), 2),
Dev_Std = round(sd(Alch), 2),
Minimo = round(min(Alch), 2),
Q1 = round(quantile(Alch, 0.25), 2),
Mediana = round(median(Alch), 2),
Q3 = round(quantile(Alch, 0.75), 2),
Massimo = round(max(Alch), 2)
) %>%
mutate(Gruppo = paste("Cultivar", ifelse(Cult == "v1", "1", ifelse(Cult == "v2", "2", "3")))) %>%
select(Gruppo, N, Media, Dev_Std, Minimo, Q1, Mediana, Q3, Massimo)

# Unione delle tabelle
stat_complete <- bind_rows(stat_globali, stat_cultivar)

# Visualizzazione tabella
knitr::kable(stat_complete, caption = "Statistiche descrittive del contenuto alcolico")

```

Table 1: Statistiche descrittive del contenuto alcolico

Gruppo	N	Media	Dev_Std	Minimo	Q1	Mediana	Q3	Massimo
Globale	178	13.00	0.81	11.03	12.36	13.05	13.68	14.83
Cultivar 1	59	13.74	0.46	12.85	13.40	13.75	14.10	14.83
Cultivar 2	71	12.28	0.54	11.03	11.91	12.29	12.52	13.86
Cultivar 3	48	13.15	0.53	12.20	12.80	13.16	13.50	14.34

Il contenuto alcolico presenta un range complessivo da 11.03% a 14.83% con media globale di 13%. Si osserva una netta differenziazione tra i tre cultivar: il Cultivar 1 mostra i valori medi più elevati, il Cultivar 3 presenta valori intermedi, mentre il Cultivar 2 registra i contenuti alcolici più bassi. Questa separazione è visivamente evidente nella Figura seguente.

```

ggplot(wine, aes(x = Alch)) +
  geom_density(aes(fill = Cult), alpha = 0.6) +
  geom_density(aes(linetype = "Popolazione Generale"), color = "black", size = 0.8) +
  scale_fill_manual(values = c("v1" = "#E69F00", "v2" = "#56B4E9", "v3" = "#009E73"),
                    labels = c("Cultivar 1", "Cultivar 2", "Cultivar 3"),
                    name = NULL) +
  scale_linetype_manual(values = c("Popolazione Generale" = "dashed"),
                       name = NULL) +
  labs(x = "Contenuto Alcolico (%)",
       y = "Densità") +
  theme_minimal() +
  theme(legend.position = "right",
        legend.text = element_text(size = 7),
        legend.key.size = unit(0.4, "cm"))

```




Figure 1: Distribuzione del contenuto alcolico per cultivar e popolazione generale

Le distribuzioni mostrano una chiara separazione tra i tre gruppi con limitata sovrapposizione, suggerendo che il tipo di cultivar rappresenta un fattore determinante per il contenuto alcolico. Questa evidente differenza giustifica il nostro approccio a due fasi: prima analizzeremo le relazioni chimiche senza considerare il cultivar (Fase 1), poi lo includeremo esplicitamente nei modelli per valutarne l'effetto (Fase 2).

3.2 BoxPlot

Per approfondire l'analisi delle distribuzioni, utilizziamo dei boxplot che consentono di visualizzare sinteticamente la posizione centrale, la dispersione e la presenza di eventuali valori anomali del contenuto alcolico. Il confronto tra la popolazione generale e i singoli cultivar evidenzia l'effetto della stratificazione sulla variabilità osservata.

```
# Boxplot popolazione generale
p1 <- ggplot(wine, aes(x = "", y = Alch)) +
  geom_boxplot(fill = "gray70", alpha = 0.7, outlier.colour = "red", outlier.shape = 16,
    outlier.size = 1.5) +
  labs(x = "Popolazione Generale", y = "Contenuto Alcolico (%)") +
  theme_minimal() +
  theme(axis.text.x = element_text(size = 9))

# Boxplot per cultivar
p2 <- ggplot(wine, aes(x = Cult, y = Alch, fill = Cult)) +
  geom_boxplot(alpha = 0.7, outlier.colour = "red", outlier.shape = 16, outlier.size = 1.5) +
  scale_fill_manual(values = c("v1" = "#E69F00", "v2" = "#56B4E9", "v3" = "#009E73")) +
  scale_x_discrete(labels = c("Cultivar 1", "Cultivar 2", "Cultivar 3")) +
  labs(x = "Cultivar", y = "Contenuto Alcolico (%)") +
  theme_minimal() +
  theme(legend.position = "none", axis.text.x = element_text(size = 8))

grid.arrange(p1, p2, ncol = 2, widths = c(1, 2))
```




Figure 2: Boxplot del contenuto alcolico: popolazione generale e per cultivar

Il confronto è illuminante: il boxplot della popolazione generale mostra una variabilità elevata (intervallo 11-15%) che riflette la sovrapposizione delle tre distribuzioni cultivar-specifiche. Quando stratifichiamo per cultivar (pannello destro), osserviamo mediane ben distinte con l'ordinamento già evidenziato (Cultivar 1 > Cultivar 3 > Cultivar 2) e intervalli interquartili notevolmente più ristretti. Questo conferma che il cultivar è un fattore determinante del contenuto alcolico e che ignorarlo nella modellazione comporterebbe una perdita significativa di potere esplicativo. Eventuali valori anomali (punti rossi) indicano osservazioni che si discostano significativamente dalla distribuzione del proprio gruppo.

3.3 Matrici Scatterplot

Le matrici di scatterplot permettono di esplorare simultaneamente le relazioni bivariate tra tutte le variabili chimiche del dataset. Questa visualizzazione completa consente di identificare pattern, correlazioni e potenziali problemi di multicollinearità che influenzeranno le analisi successive.

```
# Matrice di scatterplot completa
plot(wine_no_cult,
     pch = 20,
     cex = 0.3,
     col = rgb(0, 0, 0.8, 0.3))
```




Figure 3: Matrice di scatterplot dell'intera popolazione

La matrice completa rivela la **struttura di dipendenza** tra tutte le variabili chimiche. Osservando la

prima riga/colonna (Alch), emergono correlazioni moderate con Prln (prolina, $r=0.64$) e Clri (intensità del colore, $r=0.55$), che si confermano come i predittori candidati principali per il contenuto alcolico. Si evidenzia una **forte multicollinearità** in diversi cluster di variabili: i composti fenolici (Flvn-Ttlp $r=0.86$, Flvn-Oodw $r=0.79$) mostrano intercorrelazioni elevate, così come alcune misure chimiche secondarie. Questi pattern richiederanno particolare attenzione nella fase di modellazione per evitare problemi di instabilità. Gli scatterplot mostrano prevalentemente relazioni lineari, validando l'appropriatezza di approcci basati su modelli gaussiani.

3.4 Matrice di Correlazione

La matrice di correlazione quantifica l'intensità e la direzione delle relazioni lineari tra tutte le coppie di variabili chimiche, fornendo una sintesi numerica dei pattern osservati negli scatterplot.

3.4.1 Correlazioni - Intera Popolazione

Analizziamo la struttura di correlazione dell'intera popolazione, senza distinzione per cultivar, per identificare le variabili più associate al contenuto alcolico e individuare eventuali problemi di multicollinearità.

```
# Calcolo della matrice di correlazione
cor_matrix <- cor(wine_no_cult)

# Visualizzazione con corrplot
corrplot(cor_matrix,
  method = "color",
  type = "upper",
  order = "original",
  tl.col = "black",
  tl.cex = 0.7,
  tl.srt = 45,
  addCoef.col = "black",
  number.cex = 0.5,
  col = colorRampPalette(c("#6D9EC1", "white", "#E46726"))(200),
  mar = c(0, 0, 0, 0))
```




Figure 4: Matrice di correlazione - Intera popolazione

Le variabili più fortemente correlate con Alch sono Prln ($r=0.64$), Clri ($r=0.55$), Ttlp ($r=0.29$) e Mgns ($r=0.27$), confermando la prolina e l'intensità del colore come predittori candidati principali. Si osserva una **forte multicollinearità** tra Flvn-Ttlp ($r=0.86$) e Flvn-Oodw ($r=0.79$), suggerendo che questi composti fenolici condividono informazione ridondante. Le correlazioni negative sono generalmente deboli, con Aloa-Alch ($r=-0.31$) e Nnfp-Alch ($r=-0.16$) come più rilevanti. Questa struttura di dipendenza guiderà la selezione delle variabili nei modelli successivi.

3.4.2 Correlazioni per Cultivar - Confronto

Verifichiamo se le relazioni lineari tra variabili rimangono costanti attraverso i tre cultivar o se il tipo di coltivazione modifica la struttura di correlazione.

```
# Calcolo correlazioni con Alch per ciascun cultivar
wine_c1 <- wine %>% filter(Cult == "v1") %>% select(-Cult)
wine_c2 <- wine %>% filter(Cult == "v2") %>% select(-Cult)
wine_c3 <- wine %>% filter(Cult == "v3") %>% select(-Cult)

cor_alch_c1 <- cor(wine_c1)[, "Alch"]
cor_alch_c2 <- cor(wine_c2)[, "Alch"]
cor_alch_c3 <- cor(wine_c3)[, "Alch"]

# Creazione dataframe per visualizzazione
df_comp <- data.frame(
  Variabile = names(cor_alch_c1)[names(cor_alch_c1) != "Alch"],
  Cultivar_1 = cor_alch_c1[names(cor_alch_c1) != "Alch"],
  Cultivar_2 = cor_alch_c2[names(cor_alch_c2) != "Alch"],
  Cultivar_3 = cor_alch_c3[names(cor_alch_c3) != "Alch"]
)

# Reshape per ggplot
df_long <- df_comp %>%
  pivot_longer(cols = starts_with("Cultivar"),
    names_to = "Cultivar",
    values_to = "Correlazione") %>%
  mutate(Cultivar = gsub("Cultivar_", "Cultivar ", Cultivar))

# Grafico a punti
ggplot(df_long, aes(x = Variabile, y = Correlazione, color = Cultivar, shape = Cultivar)) +
  geom_point(size = 2.5, alpha = 0.8) +
  geom_hline(yintercept = 0, linetype = "dashed", color = "gray50") +
  scale_color_manual(values = c("Cultivar 1" = "#E69F00",
                                "Cultivar 2" = "#56B4E9",
                                "Cultivar 3" = "#009E73")) +
  scale_shape_manual(values = c("Cultivar 1" = 16, "Cultivar 2" = 17, "Cultivar 3" = 15)) +
  labs(x = "Variabile",
    y = "Correlazione con Alch",
    color = NULL,
    shape = NULL) +
  theme_minimal() +
  theme(axis.text.x = element_text(angle = 45, hjust = 1, size = 8),
    legend.position = "top")
```




Figure 5: Confronto correlazioni con Alch per cultivar

Il confronto rivela **eterogeneità marcata** nelle relazioni lineari tra cultivar. Poche variabili mostrano stabilità: **Ash** e **Hue** presentano correlazioni simili attraverso i tre gruppi (rispettivamente ~ 0.2 e ~ 0). Al contrario, si osservano **variazioni sostanziali** per **Prnt** (range -0.2 a $+0.3$), **Aloa** (-0.3 a $+0.2$), **Flvn**, **Ttlp** e **Prln**, dove Cultivar 2 mostra sistematicamente correlazioni prossime allo zero o negative, mentre Cultivar 1 (e in parte 3) presentano valori positivi moderati-forti. Questa eterogeneità indica che il cultivar modifica significativamente la struttura di dipendenza lineare, giustificando l'inclusione di termini di interazione o modelli cultivar-specifici nelle analisi predittive.

3.5 Heatmap delle Correlazioni

Le heatmap con clustering gerarchico offrono una rappresentazione complementare rispetto alla matrice di correlazione standard, raggruppando le variabili in base alla similarità dei loro profili di correlazione. Questo permette di identificare **cluster di variabili** chimicamente correlate e di comprendere la struttura latente del dataset.

In questa sezione presentiamo un'unica heatmap riferita all'**intera popolazione**, poiché il suo valore aggiunto rispetto alle analisi precedenti risiede specificamente nel **clustering gerarchico**, che riordina le variabili evidenziando raggruppamenti non immediatamente visibili nella matrice di correlazione standard. Il confronto delle correlazioni tra i singoli cultivar è stato già ampiamente trattato nella sezione precedente tramite il grafico a punti, che risulta più efficace per mettere in luce le differenze cultivar-specifiche senza ridondanza. Replicare la heatmap per ciascun cultivar non aggiungerebbe informazione sostanziale rispetto a quanto già emerso.

3.5.1 Heatmap - Intera Popolazione

Costruiamo quindi una heatmap della matrice di correlazione dell'intera popolazione, applicando il clustering gerarchico sia sulle righe che sulle colonne per evidenziare i raggruppamenti naturali tra le variabili chimiche.

```
# Matrice di correlazione (già calcolata in precedenza)
cor_pop <- cor(wine_no_cult)
```

```
# Heatmap con clustering gerarchico
pheatmap(cor_pop,
          display_numbers = TRUE,
```

```

number_format = "%.2f",
fontsize_number = 7,
fontsize = 9,
color = colorRampPalette(c("#6D9EC1", "white", "#E46726"))(100),
breaks = seq(-1, 1, length.out = 101),
clustering_method = "ward.D2",
clustering_distance_rows = as.dist(1 - abs(cor_pop)),
clustering_distance_cols = as.dist(1 - abs(cor_pop)),
border_color = "grey90",
main = ""

```




Figure 6: Heatmap con clustering gerarchico della matrice di correlazione - Intera popolazione

Il clustering gerarchico rivela una struttura a **blocchi** ben definita nella matrice di correlazione. Il dendrogramma separa le variabili in quattro raggruppamenti principali:

- Un primo cluster comprende i **composti fenolici** (Flvn, Ttlp, Oodw e Prnt), caratterizzato da forti correlazioni positive interne (in particolare Flvn-Ttlp $r=0.86$ e Flvn-Oodw $r=0.79$). Queste variabili condividono un profilo chimico legato ai processi di maturazione e alle proprietà antiossidanti del vino.
- Un secondo cluster raggruppa **Mlca, Hue e Nnfp**. Si tratta di variabili con profili di correlazione atipici rispetto ai cluster adiacenti: **Hue** presenta correlazioni positive con i fenolici ($r=0.54$ con Flvn) ma è più debolmente connessa al blocco Alch-Prln, mentre **Nnfp** (fenoli non-flavonoidi), pur appartenendo alla famiglia fenolica, si correla negativamente con i flavonoidi ($r=-0.54$), suggerendo un rapporto di

compensazione nella composizione fenolica. **Mlca** (acido malico) si associa negativamente sia a Hue ($r=-0.56$) sia ai fenolici, collocandosi in una posizione intermedia nel dendrogramma.

- Un terzo cluster raggruppa le variabili **Mgns**, **Clri**, **Alch** e **Prln**, legate alla struttura alcolica e cromatica del vino. All'interno di questo blocco, le correlazioni più forti con il contenuto alcolico sono quelle con **Prln** ($r=0.64$) e **Clri** ($r=0.55$), che si confermano come i predittori candidati principali. La prolina, un amminoacido la cui concentrazione aumenta con la maturazione dell'uva, è anche moderatamente correlata con l'intensità del colore ($r=0.32$) e il magnesio ($r=0.39$).
- Le variabili **Ash** e **Aloa** formano una coppia a sé stante, legata alla componente minerale del vino, con relazioni più deboli e indipendenti rispetto ai cluster principali.

Come già evidenziato dal confronto delle correlazioni per cultivar nella sezione precedente, questa struttura a blocchi rappresenta una sintesi della popolazione globale che maschera dinamiche cultivar-specifiche, rafforzando la necessità di considerare il cultivar come variabile esplicativa nei modelli successivi.

3.6 Sintesi dell'Analisi Esplorativa

L'analisi esplorativa ha permesso di delineare un quadro chiaro della struttura del dataset e delle relazioni tra le variabili chimiche. I risultati principali possono essere riassunti nei seguenti punti:

- **Variabile target (Alch):** il contenuto alcolico presenta una distribuzione compresa tra 11% e 15% circa, con una media globale intorno a 13%. La stratificazione per cultivar rivela tre distribuzioni ben separate (Cultivar 1 > Cultivar 3 > Cultivar 2), con intervalli interquartili nettamente più ristretti rispetto alla popolazione globale.
- **Predittori principali:** le variabili più fortemente correlate con il contenuto alcolico sono **Prln** ($r=0.64$) e **Clri** ($r=0.55$), seguite a distanza da **Ttlp** ($r=0.29$) e **Mgns** ($r=0.27$). Questi predittori candidati guideranno la costruzione dei modelli nelle sezioni successive.
- **Multicollinearità:** il dataset presenta cluster di variabili fortemente intercorrelate, in particolare i composti fenolici (**Flvn-Ttlp** $r=0.86$, **Flvn-Oodw** $r=0.79$). Questa ridondanza informativa dovrà essere tenuta in considerazione nella fase di modellazione per evitare problemi di instabilità nelle stime.
- **Eterogeneità tra cultivar:** il confronto delle correlazioni ha evidenziato che le relazioni lineari tra variabili chimiche variano significativamente tra i tre cultivar. Il Cultivar 2, in particolare, mostra correlazioni sistematicamente più deboli con il contenuto alcolico rispetto agli altri due gruppi. Questa eterogeneità giustifica l'approccio a due fasi adottato nell'analisi: nella **Fase 1** si studiano le relazioni chimiche pure sull'intera popolazione escludendo il cultivar, per cogliere la struttura di dipendenza intrinseca tra le sostanze; nella **Fase 2** si include il cultivar come variabile esplicativa, per valutare se e come il tipo di coltivazione modifichi tali relazioni e contribuisca alla previsione del contenuto alcolico.

Questi risultati forniscono le basi per le analisi successive: i modelli grafici indiretti (Capitolo 4) e diretti (Capitolo 5) permetteranno di distinguere le correlazioni marginali qui osservate dalle **dipendenze condizionali** e dalle **relazioni causali** tra le variabili, mentre la regressione lineare multipla (Capitolo 6) quantificherà formalmente il contributo di ciascun predittore.

4 Modelli Grafici Indiretti

4.1 Introduzione alla Matrice di Concentrazione

4.2 Matrice di Concentrazione - Intera Popolazione

4.2.1 Correlazioni Parziali - Intera Popolazione

4.3 Selezione Modello

4.4 Grafo Indiretto - Intera Popolazione

4.5 Grafo Indiretto - Wine Dataset con Cultivar

4.6 Risultati Ottenuti

5 Modelli Grafici Diretti (DAG)

5.1 DAG - Intera Popolazione

5.1.1 DAG Libero

5.1.2 DAG con Alch come Variabile Target

5.2 DAG - Wine Dataset con Cultivar

5.2.1 DAG Libero con Cultivar

5.2.2 DAG con Variabili Esogene e Target

5.3 Considerazioni sui DAG

6 Modello Predittivo

6.1 Intera Popolazione

6.1.1 Definizione Modelli Base

6.1.2 Selezione con BIC

6.1.3 Diagnostica del Modello

6.1.4 Verifica Multicollinearità

6.2 Wine Dataset con Cultivar

6.2.1 Definizione Modelli Base

6.2.2 Selezione con BIC

6.2.3 Diagnostica del Modello

6.3 Confronto Modelli

7 Conclusioni

7.1 Bibliografia