

Analisi Statistica del Contenuto Alcolico nel Vino

Modelli Grafici e Predittivi sul Wine Dataset

Eros Pinzani

Contents

Abstract	3
1 Introduzione	3
1.1 Il Dataset Wine	3
1.2 Variabile Target: Contenuto Alcolico	3
1.3 Obiettivi dello Studio	3
1.3.1 Fase 1: Analisi della Popolazione Globale (senza Cultivar)	4
1.3.2 Fase 2: Analisi con Cultivar	4
1.3.3 Metodologia	4
1.4 Software	4
2 Osservazioni e Preprocessing dei Dati	5
2.1 Visualizzazione Dataset	5
2.2 Preparazione dei Dati	7
2.2.1 Dataset per la Fase 1: Popolazione Globale	7
2.2.2 Dataset per la Fase 2: Analisi Completa con Cultivar	7
3 Analisi Esplorativa	9
3.1 Statistiche Descrittive e Density Plot	9
3.2 BoxPlot	11
3.3 Matrici Scatterplot	12
3.4 Matrice di Correlazione	13
3.4.1 Correlazioni - Intera Popolazione	13
3.4.2 Correlazioni per Cultivar - Confronto	14
3.5 Heatmap delle Correlazioni	15
3.5.1 Heatmap - Intera Popolazione	15
3.6 Sintesi dell'Analisi Esplorativa	17
4 Modelli Grafici Indiretti	18
4.1 Introduzione ai Modelli Grafici Gaussiani	18
4.2 Matrice di Concentrazione - Intera Popolazione	18
4.2.1 Correlazioni Parziali - Intera Popolazione	19
4.3 Selezione del Modello - Intera Popolazione	22
4.4 Grafo Indiretto - Intera Popolazione	26
4.5 Grafo Indiretto - Con Cultivar	28
4.6 Sintesi dei Modelli Grafici Indiretti	32
5 Modelli Grafici Diretti (DAG)	33
5.1 DAG - Intera Popolazione	33
5.1.1 DAG Libero	33
5.1.2 DAG con Alch Target	35

5.2	DAG - Con Cultivar	37
5.2.1	DAG Libero con Cultivar	37
5.2.2	DAG con Cult Esogena e Alch Target	37
5.3	Sintesi dei Modelli Grafici Diretti	37
6	Modello Predittivo	38
6.1	Intera Popolazione	38
6.1.1	Definizione Modelli Base	38
6.1.2	Selezione con BIC	38
6.1.3	Diagnostica del Modello	38
6.1.4	Verifica Multicollinearità	38
6.2	Wine Dataset con Cultivar	38
6.2.1	Definizione Modelli Base	38
6.2.2	Selezione con BIC	38
6.2.3	Diagnostica del Modello	38
6.3	Confronto Modelli	38
7	Conclusioni	39
7.1	Bibliografia	39

Abstract

In questo progetto analizziamo la composizione chimica di diversi campioni di vino con l'obiettivo di valutare in che modo alcune sostanze chimiche influenzino il contenuto alcolico. L'analisi prenderà in considerazione sia l'intera popolazione dei campioni sia il ruolo della variabile categorica cultivar, al fine di verificare se il tipo di coltivazione rappresenti un fattore determinante. L'approccio metodologico integra modelli grafici indiretti per individuare dipendenze condizionali, grafi aciclici diretti per esplorare relazioni causali, e regressione lineare multipla per quantificare l'effetto dei predittori chimici sul contenuto alcolico.

1 Introduzione

1.1 Il Dataset Wine

Il dataset Wine è un insieme di dati classico utilizzato in ambito statistico e di machine learning, contiene i risultati di analisi chimiche condotte su 178 campioni di vino provenienti dalla stessa regione italiana ma prodotti da tre diversi coltivatori (cultivar).

Le **13 variabili chimiche** misurate per ciascun campione sono:

- **Alch** (Alcohol): contenuto alcolico
- **Malca** (Malic Acid): acido malico
- **Ash**: ceneri
- **Aloa** (Alkalinity of Ash): alcalinità delle ceneri
- **Mgns** (Magnesium): magnesio
- **Ttlp** (Total Phenols): fenoli totali
- **Flvn** (Flavonoids): flavonoidi
- **Nnfp** (Nonflavanoid Phenols): fenoli non flavonoidi
- **Prnt** (Proanthocyanins): proantocianidine
- **Clri** (Color Intensity): intensità del colore
- **Hue**: tonalità
- **Oodw** (OD280/OD315 of diluted wines): rapporto di assorbanza
- **Prln** (Proline): prolina

Inoltre, il dataset include la variabile categorica **Cult** (Cultivar) che identifica il tipo di coltivazione (1, 2 o 3) da cui proviene ciascun campione.

1.2 Variabile Target: Contenuto Alcolico

In questa analisi, la variabile **Alch** (contenuto alcolico) rappresenta la nostra variabile target. Il contenuto alcolico è una delle caratteristiche più rilevanti nella valutazione della qualità del vino e dipende da molteplici fattori biochimici che intervengono durante il processo di fermentazione e produzione.

Comprendere quali componenti chimici influenzino maggiormente il contenuto alcolico permette di:

1. Identificare le **relazioni causali** tra la composizione chimica e il grado alcolico
2. Costruire **modelli predittivi** per stimare il contenuto alcolico a partire da altre misure chimiche
3. Valutare se e come il **tipo di cultivar** influenzi tali relazioni

1.3 Obiettivi dello Studio

L'obiettivo principale di questo studio è analizzare il contenuto alcolico nel vino utilizzando tecniche statistiche avanzate per comprendere le relazioni tra le variabili chimiche e il ruolo del cultivar. L'analisi si articola in due fasi distinte:

1.3.1 Fase 1: Analisi della Popolazione Globale (senza Cultivar)

Nella prima fase analizziamo l'intero dataset **escludendo la variabile Cult**, concentrandoci esclusivamente sulle relazioni chimiche pure tra le sostanze. Questo approccio permette di:

- Identificare le **dipendenze condizionali** tra le variabili chimiche attraverso modelli grafici indiretti (Gaussian Graphical Models)
- Studiare le **relazioni causali** tra componenti chimici mediante grafi aciclici diretti (DAG)
- Costruire **modelli predittivi** per il contenuto alcolico basati unicamente su fattori chimici
- Comprendere la struttura intrinseca delle relazioni biochimiche indipendentemente dal tipo di coltivazione

1.3.2 Fase 2: Analisi con Cultivar

Nella seconda fase includiamo la variabile **Cult** per valutare l'impatto del tipo di cultivar sulla composizione chimica e sul contenuto alcolico. Questa analisi permette di:

- Verificare se il cultivar modifica le **relazioni di dipendenza** tra le variabili chimiche
- Determinare se il tipo di coltivazione ha un **effetto diretto** sul contenuto alcolico
- Confrontare i modelli con e senza cultivar per valutare il **contributo informativo** di questa variabile categorica
- Esplorare eventuali **pattern di interazione** tra cultivar e componenti chimici

1.3.3 Metodologia

Per raggiungere questi obiettivi utilizzeremo tre approcci statistici complementari:

1. **Modelli Grafici Indiretti (Gaussian Graphical Models)**: per identificare le dipendenze condizionali tra variabili attraverso la matrice di concentrazione (inversa della matrice di covarianza)
2. **Modelli Grafici Diretti (DAG - Directed Acyclic Graphs)**: per esplorare possibili relazioni causali tra le variabili chimiche e il contenuto alcolico
3. **Regressione Lineare Multipla**: per quantificare l'effetto dei predittori chimici sul contenuto alcolico e valutare la capacità predittiva dei modelli

1.4 Software

L'analisi è condotta utilizzando il software **R**, un ambiente open-source ampiamente utilizzato per l'analisi statistica e la modellizzazione dei dati. Sono stati impiegati diversi pacchetti specializzati per l'analisi di modelli grafici gaussiani, l'inferenza causale tramite grafi aciclici diretti, la visualizzazione dei dati e la regressione lineare multipla.

Il codice R Markdown utilizzato per generare questo documento garantisce la **riproducibilità** completa dell'analisi.

2 Osservazioni e Preprocessing dei Dati

Prima di procedere con l'analisi statistica vera e propria, è fondamentale esplorare la struttura del dataset e preparare i dati in modo adeguato per le diverse fasi dell'analisi.

2.1 Visualizzazione Dataset

Il dataset **Wine** è disponibile nel pacchetto **gRbase** di R e contiene informazioni chimiche su 178 campioni di vino italiano. Iniziamo caricando il dataset e osservandone la struttura.

```
# Caricamento dataset Wine
data(wine)

# Visualizzazione delle prime righe
head(wine)
```

```
##   Cult  Alch Mlca  Ash Aloa Mgns Ttlp Flvn Nnfp Prnt Clri  Hue Oodw Prln
## 1   v1 14.23 1.71 2.43 15.6 127 2.80 3.06 0.28 2.29 5.64 1.04 3.92 1065
## 2   v1 13.20 1.78 2.14 11.2 100 2.65 2.76 0.26 1.28 4.38 1.05 3.40 1050
## 3   v1 13.16 2.36 2.67 18.6 101 2.80 3.24 0.30 2.81 5.68 1.03 3.17 1185
## 4   v1 14.37 1.95 2.50 16.8 113 3.85 3.49 0.24 2.18 7.80 0.86 3.45 1480
## 5   v1 13.24 2.59 2.87 21.0 118 2.80 2.69 0.39 1.82 4.32 1.04 2.93 735
## 6   v1 14.20 1.76 2.45 15.2 112 3.27 3.39 0.34 1.97 6.75 1.05 2.85 1450
```

La funzione `head()` mostra le **prime 6 osservazioni** del dataset, permettendoci di vedere i valori “grezzi” delle variabili per i primi campioni di vino. Questo ci consente di verificare immediatamente il formato dei dati e di avere un'idea dei range di valori per ciascuna variabile chimica. Possiamo osservare, ad esempio, che il contenuto alcolico (Alch) varia tra valori intorno a 13-14%, mentre la prolina (Prol) presenta valori nell'ordine delle centinaia.

Per ottenere una visione più completa della distribuzione dei dati, utilizziamo la funzione `summary()`:

```
# Statistiche descrittive per tutte le variabili
summary(wine)
```

```
##   Cult      Alch      Mlca      Ash      Aloa
## v1:59   Min.   :11.03   Min.   :0.740   Min.   :1.360   Min.   :10.60
## v2:71   1st Qu.:12.36   1st Qu.:1.603   1st Qu.:2.210   1st Qu.:17.20
## v3:48   Median :13.05   Median :1.865   Median :2.360   Median :19.50
##          Mean   :13.00   Mean   :2.336   Mean   :2.367   Mean   :19.49
##          3rd Qu.:13.68   3rd Qu.:3.083   3rd Qu.:2.558   3rd Qu.:21.50
##          Max.   :14.83   Max.   :5.800   Max.   :3.230   Max.   :30.00
##      Mgns      Ttlp      Flvn      Nnfp
## Min.   : 70.00   Min.   :0.980   Min.   :0.340   Min.   :0.1300
## 1st Qu.: 88.00   1st Qu.:1.742   1st Qu.:1.205   1st Qu.:0.2700
## Median : 98.00   Median :2.355   Median :2.135   Median :0.3400
## Mean   : 99.74   Mean   :2.295   Mean   :2.029   Mean   :0.3619
## 3rd Qu.:107.00   3rd Qu.:2.800   3rd Qu.:2.875   3rd Qu.:0.4375
## Max.   :162.00   Max.   :3.880   Max.   :5.080   Max.   :0.6600
##      Prnt      Clri      Hue      Oodw
## Min.   :0.410   Min.   :1.280   Min.   :0.4800   Min.   :1.270
## 1st Qu.:1.250   1st Qu.:3.220   1st Qu.:0.7825   1st Qu.:1.938
## Median :1.555   Median :4.690   Median :0.9650   Median :2.780
## Mean   :1.591   Mean   :5.058   Mean   :0.9574   Mean   :2.612
## 3rd Qu.:1.950   3rd Qu.:6.200   3rd Qu.:1.1200   3rd Qu.:3.170
## Max.   :3.580   Max.   :13.000   Max.   :1.7100   Max.   :4.000
##      Prln
## Min.   : 278.0
## 1st Qu.: 500.5
## Median : 673.5
## Mean   : 746.9
## 3rd Qu.: 985.0
```

```
## Max. :1680.0
```

Il `summary()` fornisce una panoramica statistica completa del dataset:

- Per le **variabili numeriche** (Alch, Maac, Ash, ecc.), vengono calcolati:
 - **Min** e **Max**: valori minimo e massimo osservati
 - **1st Qu.** e **3rd Qu.**: primo e terzo quartile (25° e 75° percentile)
 - **Median**: valore mediano (50° percentile)
 - **Mean**: media aritmetica
- Per la **variabile categorica Cult**, viene mostrata la **frequenza** di ciascun livello (cultivar)

Queste statistiche sono fondamentali per identificare eventuali caratteristiche peculiari delle variabili, come la presenza di outlier o distribuzioni asimmetriche.

Esaminiamo ora la struttura formale del dataset:

```
# Struttura del dataset
str(wine)
```

```
## 'data.frame': 178 obs. of 14 variables:
## $ Cult: Factor w/ 3 levels "v1","v2","v3": 1 1 1 1 1 1 1 1 1 1 ...
## $ Alch: num 14.2 13.2 13.2 14.4 13.2 ...
## $ Mlca: num 1.71 1.78 2.36 1.95 2.59 1.76 1.87 2.15 1.64 1.35 ...
## $ Ash : num 2.43 2.14 2.67 2.5 2.87 2.45 2.45 2.61 2.17 2.27 ...
## $ Aloa: num 15.6 11.2 18.6 16.8 21 15.2 14.6 17.6 14 16 ...
## $ Mgns: int 127 100 101 113 118 112 96 121 97 98 ...
## $ Ttlp: num 2.8 2.65 2.8 3.85 2.8 3.27 2.5 2.6 2.8 2.98 ...
## $ Flvn: num 3.06 2.76 3.24 3.49 2.69 3.39 2.52 2.51 2.98 3.15 ...
## $ Nnfp: num 0.28 0.26 0.3 0.24 0.39 0.34 0.3 0.31 0.29 0.22 ...
## $ Prnt: num 2.29 1.28 2.81 2.18 1.82 1.97 1.98 1.25 1.98 1.85 ...
## $ Clri: num 5.64 4.38 5.68 7.8 4.32 6.75 5.25 5.05 5.2 7.22 ...
## $ Hue : num 1.04 1.05 1.03 0.86 1.04 1.05 1.02 1.06 1.08 1.01 ...
## $ Oodw: num 3.92 3.4 3.17 3.45 2.93 2.85 3.58 3.58 2.85 3.55 ...
## $ Prln: int 1065 1050 1185 1480 735 1450 1290 1295 1045 1045 ...
```

```
# Dimensioni del dataset
dim(wine)
```

```
## [1] 178 14
```

La funzione `str()` (structure) rivela che il dataset contiene **178 osservazioni** (campioni di vino) e **14 variabili**. Possiamo notare che:

- Le prime 13 variabili (da **Alch** a **Prol**) sono **variabili numeriche continue** (num) che rappresentano misure chimiche ottenute tramite analisi di laboratorio
- La variabile **Cult** è una variabile **categorica** (Factor) con tre livelli (v1, v2, v3), che identifica il tipo di cultivar da cui proviene ciascun campione

Questa distinzione è cruciale per le analisi successive, poiché le tecniche statistiche appropriate differiscono a seconda della natura delle variabili.

Approfondiamo la distribuzione dei campioni tra i tre cultivar:

```
# Distribuzione dei campioni per cultivar
table(wine$Cult)
```

```
##
## v1 v2 v3
## 59 71 48
```

```
# Proporzioni percentuali
round(prop.table(table(wine$Cult)) * 100, 1)
```

```
##
##   v1   v2   v3
## 33.1 39.9 27.0
```

La tabella di frequenza mostra che:

- Il **cultivar v1** conta 59 campioni (33.1% del totale)
- Il **cultivar v2** è il più rappresentato con 71 campioni (39.9%)
- Il **cultivar v3** presenta 48 campioni (27.0%)

Sebbene i tre cultivar non siano perfettamente bilanciati, tutti presentano un **numero sufficiente di osservazioni** ($n > 30$) per condurre analisi statistiche robuste e ottenere stime affidabili sia per l'intera popolazione che per i singoli gruppi.

2.2 Preparazione dei Dati

Come descritto nella sezione degli obiettivi, l'analisi si articola in **due fasi distinte** che richiedono due versioni del dataset:

2.2.1 Dataset per la Fase 1: Popolazione Globale

Per la prima fase dell'analisi, creiamo un dataset che **esclude la variabile Cult**, contenente esclusivamente le 13 misure chimiche. Questo ci permetterà di studiare le relazioni chimiche “pure” tra le sostanze, indipendentemente dal tipo di coltivazione.

```
# Creazione dataset senza la variabile Cult
wine_no_cult <- wine[, -which(names(wine) == "Cult")]

# Conversione di tutte le colonne a numeric (necessario per bnlearn)
wine_no_cult <- as.data.frame(lapply(wine_no_cult, as.numeric))

# Verifica della struttura
dim(wine_no_cult)
```

```
## [1] 178 13
```

```
names(wine_no_cult)
```

```
## [1] "Alch" "Mlca" "Ash" "Aloa" "Mgns" "Ttlp" "Flvn" "Nnfp" "Prnt" "Clri"
## [11] "Hue" "Oodw" "Prln"
```

Il dataset `wine_no_cult` contiene **13 variabili** (tutte continue) e sarà utilizzato per:

- Analisi esplorativa delle relazioni chimiche
- Costruzione di modelli grafici indiretti (UG)
- Inferenza di grafi causali (DAG) senza l'influenza del cultivar
- Modelli di regressione basati esclusivamente su predittori chimici

2.2.2 Dataset per la Fase 2: Analisi Completa con Cultivar

Per la seconda fase, utilizzeremo il **dataset completo wine** che include la variabile categorica **Cult**. Questo ci permetterà di:

- Valutare l'effetto del tipo di cultivar sulle relazioni tra variabili chimiche

- Verificare se il cultivar influenza direttamente il contenuto alcolico
- Confrontare i modelli con e senza cultivar

Prima di procedere, convertiamo la variabile `Cult` in fattore, se non lo è già, per assicurarci che R la tratti correttamente come variabile categorica nelle analisi successive.

```
# Verifica e conversione di Cult in fattore  
wine$Cult <- as.factor(wine$Cult)
```

```
# Verifica dei livelli  
levels(wine$Cult)
```

```
## [1] "v1" "v2" "v3"
```

Con i dati ora preparati possiamo procedere con l'analisi esplorativa approfondita che ci permetterà di comprendere le distribuzioni delle variabili, le loro correlazioni e le eventuali differenze tra i cultivar.

3 Analisi Esplorativa

L'analisi esplorativa permette di comprendere le distribuzioni, identificare outlier, visualizzare relazioni bivariate, quantificare correlazioni e confrontare i cultivar.

- Comprendere la **distribuzione** delle variabili chimiche e della variabile target (contenuto alcolico)
- Identificare eventuali **outlier** o valori anomali che potrebbero influenzare le analisi successive
- Visualizzare le **relazioni bivariate** tra le variabili attraverso grafici a dispersione
- Quantificare le **correlazioni lineari** tra i predittori chimici e il contenuto alcolico
- Confrontare le **caratteristiche distributive** dei tre cultivar per evidenziare eventuali differenze sistematiche

L'analisi esplorativa fornisce quindi una **base intuitiva** per interpretare i risultati dei modelli più complessi che costruiremo nelle sezioni successive. In particolare, l'esame delle correlazioni tra variabili ci darà indicazioni preliminari su quali componenti chimici potrebbero essere maggiormente associati al contenuto alcolico, mentre il confronto tra cultivar ci permetterà di valutare se il tipo di coltivazione introduce variabilità sistematica nella composizione chimica del vino.

In questa sezione utilizzeremo diverse tecniche di visualizzazione:

1. **Density plots:** per esaminare la forma delle distribuzioni univariate, verificare la presenza di asimmetrie o multimodalità, e confrontare visivamente le distribuzioni del contenuto alcolico tra i tre cultivar
2. **Boxplots:** per identificare la posizione centrale, la dispersione e la presenza di outlier, con particolare attenzione alle differenze del contenuto alcolico tra i cultivar
3. **Scatterplot matrices:** per esplorare le relazioni bivariate tra le variabili chimiche più rilevanti e individuare pattern lineari o non lineari
4. **Matrici di correlazione e heatmap:** per quantificare e visualizzare l'intensità delle associazioni lineari tra tutte le coppie di variabili, sia per l'intera popolazione che separatamente per ciascun cultivar

Questa esplorazione visiva e numerica ci consentirà di formulare **ipotesi informate** sulle relazioni tra variabili che saranno successivamente testate formalmente attraverso modelli grafici e regressione lineare multipla.

3.1 Statistiche Descrittive e Density Plot

Iniziamo l'analisi esplorativa esaminando la distribuzione della nostra **variabile target**: il contenuto alcolico (Alch). La Tabella seguente riporta le principali statistiche descrittive per l'intera popolazione e per ciascun cultivar.

```
# Statistiche per l'intera popolazione
stat_globali <- wine %>%
  summarise(
    Gruppo = "Globale",
    N = n(),
    Media = round(mean(Alch), 2),
    Dev_Std = round(sd(Alch), 2),
    Minimo = round(min(Alch), 2),
    Q1 = round(quantile(Alch, 0.25), 2),
    Mediana = round(median(Alch), 2),
    Q3 = round(quantile(Alch, 0.75), 2),
    Massimo = round(max(Alch), 2)
  )

# Statistiche per cultivar
stat_cultivar <- wine %>%
  group_by(Cult) %>%
  summarise(
    N = n(),
```

```

Media = round(mean(Alch), 2),
Dev_Std = round(sd(Alch), 2),
Minimo = round(min(Alch), 2),
Q1 = round(quantile(Alch, 0.25), 2),
Mediana = round(median(Alch), 2),
Q3 = round(quantile(Alch, 0.75), 2),
Massimo = round(max(Alch), 2)
) %>%
mutate(Gruppo = paste("Cultivar", ifelse(Cult == "v1", "1", ifelse(Cult == "v2", "2", "3")))) %>%
select(Gruppo, N, Media, Dev_Std, Minimo, Q1, Mediana, Q3, Massimo)

# Unione delle tabelle
stat_complete <- bind_rows(stat_globali, stat_cultivar)

# Visualizzazione tabella
knitr::kable(stat_complete, caption = "Statistiche descrittive del contenuto alcolico")

```

Table 1: Statistiche descrittive del contenuto alcolico

Gruppo	N	Media	Dev_Std	Minimo	Q1	Mediana	Q3	Massimo
Globale	178	13.00	0.81	11.03	12.36	13.05	13.68	14.83
Cultivar 1	59	13.74	0.46	12.85	13.40	13.75	14.10	14.83
Cultivar 2	71	12.28	0.54	11.03	11.91	12.29	12.52	13.86
Cultivar 3	48	13.15	0.53	12.20	12.80	13.16	13.50	14.34

Il contenuto alcolico presenta un range complessivo da 11.03% a 14.83% con media globale di 13%. Si osserva una netta differenziazione tra i tre cultivar: il Cultivar 1 mostra i valori medi più elevati, il Cultivar 3 presenta valori intermedi, mentre il Cultivar 2 registra i contenuti alcolici più bassi. Questa separazione è visivamente evidente nella Figura seguente.

```

ggplot(wine, aes(x = Alch)) +
  geom_density(aes(fill = Cult), alpha = 0.6) +
  geom_density(aes(linetype = "Popolazione Generale"), color = "black", size = 0.8) +
  scale_fill_manual(values = c("v1" = "#E69F00", "v2" = "#56B4E9", "v3" = "#009E73"),
                    labels = c("Cultivar 1", "Cultivar 2", "Cultivar 3"),
                    name = NULL) +
  scale_linetype_manual(values = c("Popolazione Generale" = "dashed"),
                       name = NULL) +
  labs(x = "Contenuto Alcolico (%)",
       y = "Densità") +
  theme_minimal() +
  theme(legend.position = "right",
        legend.text = element_text(size = 7),
        legend.key.size = unit(0.4, "cm"))

```




Figure 1: Distribuzione del contenuto alcolico per cultivar e popolazione generale

Le distribuzioni mostrano una chiara separazione tra i tre gruppi con limitata sovrapposizione, suggerendo che il tipo di cultivar rappresenta un fattore determinante per il contenuto alcolico. Questa evidente differenza giustifica il nostro approccio a due fasi: prima analizzeremo le relazioni chimiche senza considerare il cultivar (Fase 1), poi lo includeremo esplicitamente nei modelli per valutarne l'effetto (Fase 2).

3.2 BoxPlot

Per approfondire l'analisi delle distribuzioni, utilizziamo dei boxplot che consentono di visualizzare sinteticamente la posizione centrale, la dispersione e la presenza di eventuali valori anomali del contenuto alcolico. Il confronto tra la popolazione generale e i singoli cultivar evidenzia l'effetto della stratificazione sulla variabilità osservata.

```
# Boxplot popolazione generale
p1 <- ggplot(wine, aes(x = "", y = Alch)) +
  geom_boxplot(fill = "gray70", alpha = 0.7, outlier.colour = "red", outlier.shape = 16,
    outlier.size = 1.5) +
  labs(x = "Popolazione Generale", y = "Contenuto Alcolico (%)") +
  theme_minimal() +
  theme(axis.text.x = element_text(size = 9))

# Boxplot per cultivar
p2 <- ggplot(wine, aes(x = Cult, y = Alch, fill = Cult)) +
  geom_boxplot(alpha = 0.7, outlier.colour = "red", outlier.shape = 16, outlier.size = 1.5) +
  scale_fill_manual(values = c("v1" = "#E69F00", "v2" = "#56B4E9", "v3" = "#009E73")) +
  scale_x_discrete(labels = c("Cultivar 1", "Cultivar 2", "Cultivar 3")) +
  labs(x = "Cultivar", y = "Contenuto Alcolico (%)") +
  theme_minimal() +
  theme(legend.position = "none", axis.text.x = element_text(size = 8))

grid.arrange(p1, p2, ncol = 2, widths = c(1, 2))
```




Figure 2: Boxplot del contenuto alcolico: popolazione generale e per cultivar

Il confronto è illuminante: il boxplot della popolazione generale mostra una variabilità elevata (intervallo 11-15%) che riflette la sovrapposizione delle tre distribuzioni cultivar-specifiche. Quando stratifichiamo per cultivar (pannello destro), osserviamo mediane ben distinte con l'ordinamento già evidenziato (Cultivar 1 > Cultivar 3 > Cultivar 2) e intervalli interquartili notevolmente più ristretti. Questo conferma che il cultivar è un fattore determinante del contenuto alcolico e che ignorarlo nella modellazione comporterebbe una perdita significativa di potere esplicativo. Eventuali valori anomali (punti rossi) indicano osservazioni che si discostano significativamente dalla distribuzione del proprio gruppo.

3.3 Matrici Scatterplot

Le matrici di scatterplot permettono di esplorare simultaneamente le relazioni bivariate tra tutte le variabili chimiche del dataset. Questa visualizzazione completa consente di identificare pattern, correlazioni e potenziali problemi di multicollinearità che influenzeranno le analisi successive.

```
# Matrice di scatterplot completa
plot(wine_no_cult,
     pch = 20,
     cex = 0.3,
     col = rgb(0, 0, 0.8, 0.3))
```




Figure 3: Matrice di scatterplot dell'intera popolazione

La matrice completa rivela la **struttura di dipendenza** tra tutte le variabili chimiche. Osservando la

prima riga/colonna (Alch), emergono correlazioni moderate con Prln (prolina, $r=0.64$) e Clri (intensità del colore, $r=0.55$), che si confermano come i predittori candidati principali per il contenuto alcolico. Si evidenzia una **forte multicollinearità** in diversi cluster di variabili: i composti fenolici (Flvn-Ttlp $r=0.86$, Flvn-Oodw $r=0.79$) mostrano intercorrelazioni elevate, così come alcune misure chimiche secondarie. Questi pattern richiederanno particolare attenzione nella fase di modellazione per evitare problemi di instabilità. Gli scatterplot mostrano prevalentemente relazioni lineari, validando l'appropriatezza di approcci basati su modelli gaussiani.

3.4 Matrice di Correlazione

La matrice di correlazione quantifica l'intensità e la direzione delle relazioni lineari tra tutte le coppie di variabili chimiche, fornendo una sintesi numerica dei pattern osservati negli scatterplot.

3.4.1 Correlazioni - Intera Popolazione

Analizziamo la struttura di correlazione dell'intera popolazione, senza distinzione per cultivar, per identificare le variabili più associate al contenuto alcolico e individuare eventuali problemi di multicollinearità.

```
# Calcolo della matrice di correlazione
cor_matrix <- cor(wine_no_cult)

# Visualizzazione con corrplot
corrplot(cor_matrix,
  method = "color",
  type = "upper",
  order = "original",
  tl.col = "black",
  tl.cex = 0.7,
  tl.srt = 45,
  addCoef.col = "black",
  number.cex = 0.5,
  col = colorRampPalette(c("#6D9EC1", "white", "#E46726"))(200),
  mar = c(0, 0, 0, 0))
```




Figure 4: Matrice di correlazione - Intera popolazione

Le variabili più fortemente correlate con Alch sono Prln ($r=0.64$), Clri ($r=0.55$), Ttlp ($r=0.29$) e Mgns ($r=0.27$), confermando la prolina e l'intensità del colore come predittori candidati principali. Si osserva una **forte multicollinearità** tra Flvn-Ttlp ($r=0.86$) e Flvn-Oodw ($r=0.79$), suggerendo che questi composti fenolici condividono informazione ridondante. Le correlazioni negative sono generalmente deboli, con Aloa-Alch ($r=-0.31$) e Nnfp-Alch ($r=-0.16$) come più rilevanti. Questa struttura di dipendenza guiderà la selezione delle variabili nei modelli successivi.

3.4.2 Correlazioni per Cultivar - Confronto

Verifichiamo se le relazioni lineari tra variabili rimangono costanti attraverso i tre cultivar o se il tipo di coltivazione modifica la struttura di correlazione.

```
# Calcolo correlazioni con Alch per ciascun cultivar
wine_c1 <- wine %>% filter(Cult == "v1") %>% select(-Cult)
wine_c2 <- wine %>% filter(Cult == "v2") %>% select(-Cult)
wine_c3 <- wine %>% filter(Cult == "v3") %>% select(-Cult)

cor_alch_c1 <- cor(wine_c1)[, "Alch"]
cor_alch_c2 <- cor(wine_c2)[, "Alch"]
cor_alch_c3 <- cor(wine_c3)[, "Alch"]

# Creazione dataframe per visualizzazione
df_comp <- data.frame(
  Variabile = names(cor_alch_c1)[names(cor_alch_c1) != "Alch"],
  Cultivar_1 = cor_alch_c1[names(cor_alch_c1) != "Alch"],
  Cultivar_2 = cor_alch_c2[names(cor_alch_c2) != "Alch"],
  Cultivar_3 = cor_alch_c3[names(cor_alch_c3) != "Alch"]
)

# Reshape per ggplot
df_long <- df_comp %>%
  pivot_longer(cols = starts_with("Cultivar"),
    names_to = "Cultivar",
    values_to = "Correlazione") %>%
  mutate(Cultivar = gsub("Cultivar_", "Cultivar ", Cultivar))

# Grafico a punti
ggplot(df_long, aes(x = Variabile, y = Correlazione, color = Cultivar, shape = Cultivar)) +
  geom_point(size = 2.5, alpha = 0.8) +
  geom_hline(yintercept = 0, linetype = "dashed", color = "gray50") +
  scale_color_manual(values = c("Cultivar 1" = "#E69F00",
                                "Cultivar 2" = "#56B4E9",
                                "Cultivar 3" = "#009E73")) +
  scale_shape_manual(values = c("Cultivar 1" = 16, "Cultivar 2" = 17, "Cultivar 3" = 15)) +
  labs(x = "Variabile",
    y = "Correlazione con Alch",
    color = NULL,
    shape = NULL) +
  theme_minimal() +
  theme(axis.text.x = element_text(angle = 45, hjust = 1, size = 8),
    legend.position = "top")
```




Figure 5: Confronto correlazioni con Alch per cultivar

Il confronto rivela **eterogeneità marcata** nelle relazioni lineari tra cultivar. Poche variabili mostrano stabilità: **Ash** e **Hue** presentano correlazioni simili attraverso i tre gruppi (rispettivamente ~ 0.2 e ~ 0). Al contrario, si osservano **variazioni sostanziali** per **Prnt** (range -0.2 a $+0.3$), **Aloa** (-0.3 a $+0.2$), **Flvn**, **Ttlp** e **Prln**, dove Cultivar 2 mostra sistematicamente correlazioni prossime allo zero o negative, mentre Cultivar 1 (e in parte 3) presentano valori positivi moderati-forti. Questa eterogeneità indica che il cultivar modifica significativamente la struttura di dipendenza lineare, giustificando l'inclusione di termini di interazione o modelli cultivar-specifici nelle analisi predittive.

3.5 Heatmap delle Correlazioni

Le heatmap con clustering gerarchico offrono una rappresentazione complementare rispetto alla matrice di correlazione standard, raggruppando le variabili in base alla similarità dei loro profili di correlazione. Questo permette di identificare **cluster di variabili** chimicamente correlate e di comprendere la struttura latente del dataset.

In questa sezione presentiamo un'unica heatmap riferita all'**intera popolazione**, poiché il suo valore aggiunto rispetto alle analisi precedenti risiede specificamente nel **clustering gerarchico**, che riordina le variabili evidenziando raggruppamenti non immediatamente visibili nella matrice di correlazione standard. Il confronto delle correlazioni tra i singoli cultivar è stato già ampiamente trattato nella sezione precedente tramite il grafico a punti, che risulta più efficace per mettere in luce le differenze cultivar-specifiche senza ridondanza. Replicare la heatmap per ciascun cultivar non aggiungerebbe informazione sostanziale rispetto a quanto già emerso.

3.5.1 Heatmap - Intera Popolazione

Costruiamo quindi una heatmap della matrice di correlazione dell'intera popolazione, applicando il clustering gerarchico sia sulle righe che sulle colonne per evidenziare i raggruppamenti naturali tra le variabili chimiche.

```
# Matrice di correlazione (già calcolata in precedenza)
cor_pop <- cor(wine_no_cult)

# Heatmap con clustering gerarchico
pheatmap(cor_pop,
          display_numbers = TRUE,
```

```

number_format = "%.2f",
fontsize_number = 7,
fontsize = 9,
color = colorRampPalette(c("#6D9EC1", "white", "#E46726"))(100),
breaks = seq(-1, 1, length.out = 101),
clustering_method = "ward.D2",
clustering_distance_rows = as.dist(1 - abs(cor_pop)),
clustering_distance_cols = as.dist(1 - abs(cor_pop)),
border_color = "grey90",
main = ""

```




Figure 6: Heatmap con clustering gerarchico della matrice di correlazione - Intera popolazione

Il clustering gerarchico rivela una struttura a **blocchi** ben definita nella matrice di correlazione. Il dendrogramma separa le variabili in quattro raggruppamenti principali:

- Un primo cluster comprende i **composti fenolici** (Flvn, Ttlp, Oodw e Prnt), caratterizzato da forti correlazioni positive interne (in particolare Flvn-Ttlp $r=0.86$ e Flvn-Oodw $r=0.79$). Queste variabili condividono un profilo chimico legato ai processi di maturazione e alle proprietà antiossidanti del vino.
- Un secondo cluster raggruppa **Mlca, Hue e Nnfp**. Si tratta di variabili con profili di correlazione atipici rispetto ai cluster adiacenti: **Hue** presenta correlazioni positive con i fenolici ($r=0.54$ con Flvn) ma è più debolmente connessa al blocco Alch-Prln, mentre **Nnfp** (fenoli non-flavonoidi), pur appartenendo alla famiglia fenolica, si correla negativamente con i flavonoidi ($r=-0.54$), suggerendo un rapporto di

compensazione nella composizione fenolica. **Mlca** (acido malico) si associa negativamente sia a Hue ($r=-0.56$) sia ai fenolici, collocandosi in una posizione intermedia nel dendrogramma.

- Un terzo cluster raggruppa le variabili **Mgns**, **Clri**, **Alch** e **Prln**, legate alla struttura alcolica e cromatica del vino. All'interno di questo blocco, le correlazioni più forti con il contenuto alcolico sono quelle con **Prln** ($r=0.64$) e **Clri** ($r=0.55$), che si confermano come i predittori candidati principali. La prolina, un amminoacido la cui concentrazione aumenta con la maturazione dell'uva, è anche moderatamente correlata con l'intensità del colore ($r=0.32$) e il magnesio ($r=0.39$).
- Le variabili **Ash** e **Aloa** formano una coppia a sé stante, legata alla componente minerale del vino, con relazioni più deboli e indipendenti rispetto ai cluster principali.

Come già evidenziato dal confronto delle correlazioni per cultivar nella sezione precedente, questa struttura a blocchi rappresenta una sintesi della popolazione globale che maschera dinamiche cultivar-specifiche, rafforzando la necessità di considerare il cultivar come variabile esplicativa nei modelli successivi.

3.6 Sintesi dell'Analisi Esplorativa

L'analisi esplorativa ha permesso di delineare un quadro chiaro della struttura del dataset e delle relazioni tra le variabili chimiche. I risultati principali possono essere riassunti nei seguenti punti:

- **Variabile target (Alch):** il contenuto alcolico presenta una distribuzione compresa tra 11% e 15% circa, con una media globale intorno a 13%. La stratificazione per cultivar rivela tre distribuzioni ben separate (Cultivar 1 > Cultivar 3 > Cultivar 2), con intervalli interquartili nettamente più ristretti rispetto alla popolazione globale.
- **Predittori principali:** le variabili più fortemente correlate con il contenuto alcolico sono **Prln** ($r=0.64$) e **Clri** ($r=0.55$), seguite a distanza da **Ttlp** ($r=0.29$) e **Mgns** ($r=0.27$). Questi predittori candidati guideranno la costruzione dei modelli nelle sezioni successive.
- **Multicollinearità:** il dataset presenta cluster di variabili fortemente intercorrelate, in particolare i composti fenolici (**Flvn-Ttlp** $r=0.86$, **Flvn-Oodw** $r=0.79$). Questa ridondanza informativa dovrà essere tenuta in considerazione nella fase di modellazione per evitare problemi di instabilità nelle stime.
- **Eterogeneità tra cultivar:** il confronto delle correlazioni ha evidenziato che le relazioni lineari tra variabili chimiche variano significativamente tra i tre cultivar. Il Cultivar 2, in particolare, mostra correlazioni sistematicamente più deboli con il contenuto alcolico rispetto agli altri due gruppi. Questa eterogeneità giustifica l'approccio a due fasi adottato nell'analisi: nella **Fase 1** si studiano le relazioni chimiche pure sull'intera popolazione escludendo il cultivar, per cogliere la struttura di dipendenza intrinseca tra le sostanze; nella **Fase 2** si include il cultivar come variabile esplicativa, per valutare se e come il tipo di coltivazione modifichi tali relazioni e contribuisca alla previsione del contenuto alcolico.

Questi risultati forniscono le basi per le analisi successive: i modelli grafici indiretti (Capitolo 4) e diretti (Capitolo 5) permetteranno di distinguere le correlazioni marginali qui osservate dalle **dipendenze condizionali** e dalle **relazioni causali** tra le variabili, mentre la regressione lineare multipla (Capitolo 6) quantificherà formalmente il contributo di ciascun predittore.

4 Modelli Grafici Indiretti

4.1 Introduzione ai Modelli Grafici Gaussiani

I modelli grafici gaussiani (Gaussian Graphical Models, GGM) rappresentano uno strumento fondamentale per lo studio delle **dipendenze condizionali** tra variabili continue. A differenza delle correlazioni marginali analizzate nel capitolo precedente, che misurano l'associazione diretta tra coppie di variabili, i GGM permettono di identificare quali relazioni persistono **anche dopo aver controllato per l'effetto di tutte le altre variabili**.

Il principio chiave alla base dei GGM risiede nella **matrice di concentrazione** K , definita come l'inversa della matrice di covarianza:

$$K = \Sigma^{-1}$$

dove Σ è la matrice di covarianza del vettore aleatorio $X = (X_1, X_2, \dots, X_p)$. Sotto l'assunzione di normalità multivariata, gli elementi fuori diagonale della matrice di concentrazione hanno un'interpretazione diretta: l'elemento k_{ij} è proporzionale alla **correlazione parziale** tra X_i e X_j , condizionatamente a tutte le altre variabili. In particolare, la correlazione parziale tra X_i e X_j è data da:

$$\rho_{ij \cdot \text{rest}} = -\frac{k_{ij}}{\sqrt{k_{ii} \cdot k_{jj}}}$$

Questa proprietà porta alla regola fondamentale dei GGM: se $k_{ij} = 0$, allora X_i e X_j sono **condizionalmente indipendenti** dato il resto delle variabili. In termini grafici, ciò equivale all'**assenza di un arco** tra i nodi i e j nel grafo indiretto.

Il **grafo indiretto** (Undirected Graph, UG) risultante è quindi un grafo $G = (V, E)$ dove:

- $V = \{1, 2, \dots, p\}$ è l'insieme dei nodi, ciascuno corrispondente a una variabile
- $E \subseteq V \times V$ è l'insieme degli archi, dove $(i, j) \in E$ se e solo se $k_{ij} \neq 0$

Questo grafo codifica la **struttura di indipendenza condizionale** del vettore aleatorio: la presenza di un arco tra due nodi indica una dipendenza diretta che non è spiegabile attraverso le altre variabili del sistema. Un grafo con pochi archi (sparso) suggerisce che molte relazioni osservate nelle correlazioni marginali sono in realtà **spurie**, mediate da variabili intermedie.

Nel nostro contesto, i GGM ci permetteranno di rispondere a una domanda cruciale: quali variabili chimiche hanno una **relazione diretta** con il contenuto alcolico, e quali invece sono correlate ad esso solo indirettamente, attraverso la mediazione di altre sostanze?

4.2 Matrice di Concentrazione - Intera Popolazione

Come introdotto nella sezione precedente, la matrice di concentrazione $K = \Sigma^{-1}$ è lo strumento chiave per identificare le dipendenze condizionali tra le variabili. Calcoliamo innanzitutto la **matrice di covarianza campionaria** S e la sua inversa K per le 13 variabili chimiche del dataset (escludendo il cultivar).

```
# Matrice di covarianza campionaria
S <- cov(wine_no_cult)

# Matrice di concentrazione (inversa della covarianza)
K <- solve(S)

# Assegnazione dei nomi delle variabili
colnames(K) <- rownames(K) <- colnames(wine_no_cult)

# Visualizzazione della matrice di concentrazione
round(K, 3)
```

```
##      Alch  Mlca      Ash  Aloa  Mgns  Ttlp  Flvn      Nnfp  Prnt  Clri
## Alch  3.733 -0.491  -0.515  0.141  0.000 -0.194 -0.034   0.776  0.569 -0.609
## Mlca -0.491  1.327  -0.676 -0.029  0.002  0.033  0.297  -0.967 -0.230  0.130
## Ash  -0.515 -0.676  29.037 -1.423 -0.127  0.097 -3.474 -16.360  2.960 -0.436
## Aloa  0.141 -0.029 -1.423  0.201  0.002  0.018  0.164  -0.011 -0.139 -0.010
## Mgns  0.000  0.002  -0.127  0.002  0.007 -0.011  0.025   0.257 -0.039  0.000
## Ttlp -0.194  0.033   0.097  0.018 -0.011 11.066 -4.973  -2.564 -0.767 -0.302
## Flvn -0.034  0.297  -3.474  0.164  0.025 -4.973  7.045   7.047 -2.001 -0.001
## Nnfp  0.776 -0.967 -16.360 -0.011  0.257 -2.564  7.047 115.981 -1.429 -0.297
## Prnt  0.569 -0.230  2.960 -0.139 -0.039 -0.767 -2.001  -1.429  6.031 -0.298
## Clri -0.609  0.130  -0.436 -0.010  0.000 -0.302 -0.001  -0.297 -0.298  0.563
## Hue  -0.810  3.231  -0.036  0.080 -0.026  0.373 -3.091 -12.284  0.035  2.375
## Odw  -0.600 -0.023  -0.661 -0.039  0.029 -1.550 -2.260   5.137 -0.644  0.859
## Prln -0.004  0.000  -0.007  0.001  0.000 -0.001 -0.001   0.002  0.000 -0.001
##      Hue  Odw  Prln
## Alch -0.810 -0.600 -0.004
## Mlca  3.231 -0.023  0.000
## Ash  -0.036 -0.661 -0.007
## Aloa  0.080 -0.039  0.001
## Mgns -0.026  0.029  0.000
## Ttlp  0.373 -1.550 -0.001
## Flvn -3.091 -2.260 -0.001
## Nnfp -12.284  5.137  0.002
## Prnt  0.035 -0.644  0.000
## Clri  2.375  0.859 -0.001
## Hue  48.836 -0.532 -0.006
## Odw  -0.532  7.510 -0.001
## Prln -0.006 -0.001  0.000
```

La matrice di concentrazione presenta valori di **ordini di grandezza molto diversi** sugli elementi diagonali (ad esempio, $k_{Prln,Prln}$ è molto piccolo rispetto a $k_{Ash,Ash}$), riflettendo le differenti scale di misura delle variabili chimiche. Questo rende difficile interpretare direttamente i valori fuori diagonale k_{ij} : un valore apparentemente piccolo potrebbe in realtà indicare una forte dipendenza condizionale se rapportato agli elementi diagonali corrispondenti. Per questa ragione, è necessario **standardizzare** la matrice di concentrazione, ottenendo le correlazioni parziali.

4.2.1 Correlazioni Parziali - Intera Popolazione

Le correlazioni parziali si ottengono dalla matrice di concentrazione mediante la formula di standardizzazione:

$$\rho_{ij\text{-rest}} = -\frac{k_{ij}}{\sqrt{k_{ii} \cdot k_{jj}}}$$

che produce valori nell'intervallo $[-1, 1]$, direttamente confrontabili tra tutte le coppie di variabili, indipendentemente dalla loro scala di misura. Un valore prossimo a zero indica **indipendenza condizionale** (assenza di relazione diretta), mentre valori elevati in valore assoluto indicano una **dipendenza condizionale forte**.

```
# Calcolo delle correlazioni parziali dalla matrice di concentrazione
# rho_ij = -K_ij / sqrt(K_ii * K_jj)
D <- diag(1 / sqrt(diag(K)))
P <- -D %*% K %*% D
diag(P) <- 1
colnames(P) <- rownames(P) <- colnames(wine_no_cult)

# Visualizzazione con corrplot
corrplot(P,
  method = "color",
  type = "upper",
  order = "original",
```

```

tl.col = "black",
tl.cex = 0.7,
tl.srt = 45,
addCoef.col = "black",
number.cex = 0.5,
col = colorRampPalette(c("#6D9EC1", "white", "#E46726"))(200),
mar = c(0, 0, 0, 0)

```




Figure 7: Matrice delle correlazioni parziali - Intera popolazione

Il confronto tra la matrice delle correlazioni parziali (qui sopra) e la matrice delle correlazioni marginali (sezione 3.4) è estremamente informativo: molte delle correlazioni marginali osservate nell'analisi esplorativa **scompaiono o si riducono drasticamente** una volta controllato l'effetto delle altre variabili. Questo indica che buona parte delle associazioni bivariate erano **spurie**, mediate da variabili intermedie.

Per il contenuto alcolico (**Alch**), le dipendenze condizionali più rilevanti sono:

- **Clri** ($\rho_{\text{parz}} = 0.42$): l'intensità del colore è la variabile con la **correlazione parziale più forte** con Alch, sebbene ridotta rispetto alla correlazione marginale ($r=0.55$). Questo indica che, pur perdendo parte dell'associazione per effetto di mediazione, Clri mantiene un **legame diretto** importante con il contenuto alcolico.
- **Prln** ($\rho_{\text{parz}} = 0.37$): la prolina mantiene la seconda correlazione parziale più elevata, confermando una **relazione diretta** con il contenuto alcolico anche dopo aver controllato per tutte le altre variabili chimiche. Questo legame riflette il ruolo della prolina come indicatore di maturazione dell'uva e del potenziale alcolico.
- **Mlca** ($\rho_{\text{parz}} = 0.22$): l'acido malico presenta un risultato interessante. La sua correlazione marginale con Alch era molto debole ($r=0.09$), mentre la correlazione parziale è **più che raddoppiata**. Questo rafforzamento indica un **effetto di soppressione**: l'influenza di altre variabili (in particolare quelle fenoliche e l'intensità del colore) mascherava parzialmente il legame positivo diretto tra acido malico e contenuto alcolico, che emerge più chiaramente solo dopo aver condizionato su tutte le altre variabili.
- **Aloa** ($\rho_{\text{parz}} = -0.16$): l'alcalinità delle ceneri mostra una correlazione parziale negativa, indicando una **dipendenza condizionale inversa** con il contenuto alcolico: a parità di tutte le altre variabili chimiche, valori più alti di alcalinità sono associati a un contenuto alcolico inferiore.

D'altra parte, variabili che nell'analisi esplorativa mostravano correlazioni marginali apprezzabili con Alch perdono gran parte della loro associazione una volta controllate le altre variabili:

- **Mgns** ($\rho_{\text{parz}} = 0$): il magnesio, che presentava una correlazione marginale di 0.27, mostra una correlazione parziale prossima allo zero, indicando **indipendenza condizionale** — il legame osservato era in realtà interamente mediato da altre variabili chimiche.
- **TtIp** ($\rho_{\text{parz}} = 0.03$): i fenoli totali (r marginale = 0.29) mostrano anch'essi una correlazione parziale quasi nulla, confermando che la loro associazione con il contenuto alcolico era **spuria**, mediata da variabili come i flavonoidi e la prolina.
- **Flvn** ($\rho_{\text{parz}} = 0.01$): analogamente, i flavonoidi perdono completamente la loro associazione con Alch nelle correlazioni parziali, nonostante una correlazione marginale moderata.

```
# Confronto correlazioni marginali vs parziali con Alch
vars <- colnames(wine_no_cult)[colnames(wine_no_cult) != "Alch"]
df_confronto <- data.frame(
  Variabile = vars,
  Marginale = cor_matrix["Alch", vars],
  Parziale = P["Alch", vars]
)

df_conf_long <- df_confronto %>%
  pivot_longer(cols = c(Marginale, Parziale),
    names_to = "Tipo",
    values_to = "Correlazione")

ggplot(df_conf_long, aes(x = Variabile, y = Correlazione, fill = Tipo)) +
  geom_bar(stat = "identity", position = "dodge", alpha = 0.8, width = 0.6) +
  geom_hline(yintercept = 0, linetype = "dashed", color = "gray50") +
  scale_fill_manual(values = c("Marginale" = "#E46726", "Parziale" = "#6D9EC1"),
    name = NULL) +
  labs(x = "Variabile", y = "Correlazione con Alch") +
  theme_minimal() +
  theme(axis.text.x = element_text(angle = 45, hjust = 1, size = 8),
    legend.position = "top")
```




Figure 8: Confronto tra correlazioni marginali e parziali con Alch

Il grafico di confronto evidenzia chiaramente il **fenomeno di riduzione** delle correlazioni passando dalle marginali alle parziali: la maggior parte delle variabili mostra correlazioni parziali significativamente minori (in valore assoluto) rispetto alle correlazioni marginali. Questo è coerente con la presenza di multicollinearità nel dataset, già identificata nella heatmap (sezione 3.5). Le variabili che mantengono una dipendenza condizionale apprezzabile con Alch sono candidate naturali per la costruzione del grafo indiretto e per l'inclusione nei modelli di regressione.

Osserviamo inoltre che all'interno del cluster fenolico, la forte multicollinearità interna (Flvn-Ttlp $r=0.86$) viene "decomposta" nelle correlazioni parziali: **Flvn** e **Ttlp** mostrano una correlazione parziale reciproca ancora elevata ($\rho_{\text{parz}} = 0.56$), confermando un legame diretto tra queste due variabili, ma il loro legame con Alch si riduce considerevolmente, suggerendo che l'informazione che portano sul contenuto alcolico è in gran parte indirettamente mediata.

4.3 Selezione del Modello - Intera Popolazione

La matrice delle correlazioni parziali calcolata nella sezione precedente rappresenta il modello **saturo**, in cui tutti i 78 archi possibili sono presenti. Tuttavia, molte correlazioni parziali sono prossime a zero, suggerendo che il grafo completo è sovrapparametrizzato. La **selezione del modello** ha l'obiettivo di identificare un grafo **parsimonioso** che mantenga solo gli archi corrispondenti a dipendenze condizionali statisticamente significative, rimuovendo quelli che non apportano informazione rilevante.

Per la selezione utilizziamo il pacchetto **gRim**, che implementa i **modelli grafici di concentrazione** (concentration graph models). L'approccio prevede:

1. La stima del **modello saturo** tramite la funzione `cmod()`, che assume distribuzione normale multivariata e parametrizza il modello attraverso la matrice di concentrazione
2. L'applicazione di una procedura di **selezione all'indietro** (backward stepwise) basata sul criterio **BIC** (Bayesian Information Criterion), che rimuove iterativamente gli archi il cui contributo non è giustificato dal guadagno in verosimiglianza, penalizzando la complessità del modello

Il criterio BIC è definito come:

$$BIC = -2 \cdot \ell(\hat{\theta}) + k \cdot \ln(n)$$

dove $\ell(\hat{\theta})$ è la log-verosimiglianza massimizzata, k è il numero di parametri e n è il numero di osservazioni. La penalizzazione $k \cdot \ln(n)$ rende il BIC più conservativo rispetto all'AIC, favorendo modelli più parsimoniosi.

```
# Modello saturo: tutti gli archi presenti
mod_saturo <- cmod(~.^., data = wine_no_cult)
```

```
# Informazioni sul modello saturo
cat("Numero di variabili:", length(mod_saturo$varNames), "\n")
```

```
## Numero di variabili: 13
```

```
cat("Numero di archi:", length(edgeList(mod_saturo$modelinfo$ug)), "\n")
```

```
## Numero di archi: 78
```

```
cat("Devianza:", round(mod_saturo$fitinfo$dev, 3), "\n")
```

```
## Devianza: 0
```

```
cat("Gradi di libertà:", mod_saturo$fitinfo$dimension["df"], "\n")
```

```
## Gradi di libertà: 0
```

Il modello saturo stima tutti i $\binom{13}{2} = 78$ parametri di dipendenza condizionale (più i 13 parametri diagonali). I risultati confermano le proprietà teoriche attese:

- **Devianza = 0:** la devianza misura la discrepanza tra la matrice di covarianza stimata dal modello e quella campionaria. Nel modello saturo, la matrice di covarianza stimata coincide *esattamente* con quella campionaria S , poiché nessun vincolo $k_{ij} = 0$ è imposto sulla matrice di concentrazione. Di conseguenza, la discrepanza è nulla.
- **Gradi di libertà = 0:** i gradi di libertà corrispondono al numero di vincoli imposti rispetto al modello saturo, ossia al numero di archi rimossi. Poiché nessun arco è stato eliminato, non vi sono vincoli e i g.d.l. sono zero.

Questo modello rappresenta il punto di partenza della procedura di selezione: ogni modello ridotto sarà valutato in termini di quanta devianza aggiunge (perdita di fit) rispetto a quanti parametri risparmia (guadagno in parsimonia). Applichiamo ora la selezione backward con criterio BIC:

```
# Selezione backward con criterio BIC
# Nota: l'output mostra "change.AIC" per convenzione interna di gRim,
# ma il criterio effettivo è il BIC grazie al parametro k = log(n)
mod_selezionato <- backward(mod_saturo, k = log(nrow(wine_no_cult)))
```

```
## change.AIC -5.1818 Edge deleted: Alch,Mgns
## change.AIC -5.1739 Edge deleted: Flvn,Alch
## change.AIC -5.1796 Edge deleted: Flvn,Clri
## change.AIC -5.1687 Edge deleted: Mgns,Clri
## change.AIC -5.1144 Edge deleted: Mlca,Mgns
## change.AIC -5.0101 Edge deleted: Aloa,Clri
## change.AIC -4.9110 Edge deleted: Ttlp,Mgns
## change.AIC -4.8520 Edge deleted: Nnfp,Clri
## change.AIC -5.0558 Edge deleted: Alch,Nnfp
## change.AIC -4.6096 Edge deleted: Aloa,Mgns
## change.AIC -5.0755 Edge deleted: Aloa,Nnfp
## change.AIC -4.4066 Edge deleted: Ttlp,Nnfp
## change.AIC -4.3701 Edge deleted: Hue,Mgns
## change.AIC -4.0658 Edge deleted: Mlca,Nnfp
## change.AIC -3.8387 Edge deleted: Flvn,Mgns
## change.AIC -2.6799 Edge deleted: Mlca,Flvn
## change.AIC -4.2423 Edge deleted: Mlca,Aloa
## change.AIC -4.6866 Edge deleted: Mlca,Prnt
## change.AIC -4.8547 Edge deleted: Oodw,Mlca
## change.AIC -2.7567 Edge deleted: Prln,Mlca
## change.AIC -1.8520 Edge deleted: Hue,Nnfp
## change.AIC -1.1701 Edge deleted: Aloa,Flvn
## change.AIC -4.9462 Edge deleted: Oodw,Aloa
## change.AIC -3.8873 Edge deleted: Prnt,Aloa
## change.AIC -2.2880 Edge deleted: Hue,Aloa
## change.AIC -2.0851 Edge deleted: Alch,Prnt
## change.AIC -2.9972 Edge deleted: Oodw,Alch
## change.AIC -2.3813 Edge deleted: Prnt,Clri
## change.AIC -3.3500 Edge deleted: Prnt,Hue
## change.AIC -2.1642 Edge deleted: Ttlp,Prnt
## change.AIC -2.0148 Edge deleted: Alch,Aloa
## change.AIC -0.6874 Edge deleted: Clri,Mlca
## change.AIC -3.6232 Edge deleted: Alch,Mlca
## change.AIC -5.1481 Edge deleted: Ash,Alch
## change.AIC -5.1200 Edge deleted: Hue,Alch
## change.AIC -3.8137 Edge deleted: Ttlp,Alch
## change.AIC -1.2928 Edge deleted: Ash,Clri
## change.AIC -0.9227 Edge deleted: Ttlp,Mlca
## change.AIC -1.2402 Edge deleted: Ash,Mlca
## change.AIC -2.1226 Edge deleted: Ash,Hue
```

```
## change.AIC -0.1929 Edge deleted: Prnt,Mgns
## change.AIC -5.1797 Edge deleted: Prnt,Oodw
## change.AIC -5.1740 Edge deleted: Nnfp,Prnt
## change.AIC -5.0279 Edge deleted: Prln,Prnt
## change.AIC -3.8301 Edge deleted: Ash,Prnt
```

L'output della procedura backward mostra, per ogni iterazione, l'arco eliminato e la variazione del criterio informativo (etichettata `change.AIC` per convenzione interna del pacchetto, ma corrispondente al **BIC** grazie al parametro $k = \log(n)$). Tutti i 45 valori di variazione sono **negativi**, confermando che ogni singola rimozione ha migliorato il BIC. La procedura si arresta automaticamente quando nessuna ulteriore eliminazione produrrebbe un miglioramento.

Analizzando l'ordine di eliminazione, osserviamo che:

- I **primi archi rimossi** presentano le variazioni BIC più marcate (intorno a -5.18), indicando dipendenze condizionali estremamente deboli. Tra questi figurano archi come Alch-Mgns, Flvn-Alch e Flvn-Clri, coerentemente con le correlazioni parziali prossime allo zero osservate nella sezione precedente.
- Gli **ultimi archi rimossi** mostrano variazioni BIC più contenute (intorno a -0.19 per Prnt-Mgns), segnalando dipendenze condizionali al limite della significatività. Questo è un segnale che la procedura si è avvicinata alla soglia oltre la quale la rimozione non sarebbe più vantaggiosa.
- Le variabili **Mlca** e **Aloa** perdono la maggior parte delle loro connessioni (Mlca-Mgns, Mlca-Aloa, Mlca-Prnt, Mlca-Flvn, ecc.), confermandone la relativa indipendenza dalla struttura chimica principale del dataset.

Esaminiamo ora gli archi mantenuti nel modello selezionato:

```
# Estrazione del grafo indiretto dal modello selezionato
ug_sel <- mod_selezionato$modelinfo$ug
archi_sel <- edgeList(ug_sel)
n_archi_sel <- length(archi_sel)

cat("Numero di archi nel modello selezionato:", n_archi_sel, "\n")
```

```
## Numero di archi nel modello selezionato: 33
```

```
cat("Numero di archi nel modello saturo: 78\n")
```

```
## Numero di archi nel modello saturo: 78
```

```
cat("Archi rimossi:", 78 - n_archi_sel, "\n")
```

```
## Archi rimossi: 45
```

Il modello selezionato mantiene **33 archi** su 78 possibili, con una riduzione del **58%** dei parametri. La procedura backward ha rimosso 45 archi corrispondenti a dipendenze condizionali non giustificate dal BIC. Questo risultato è coerente con la matrice delle correlazioni parziali analizzata nella sezione precedente, dove molte coppie di variabili mostravano valori prossimi allo zero.

Per quanto riguarda la variabile target **Alch**, il modello selezionato mantiene solo **2 archi diretti**: Alch-Clri e Alch-Prln, confermando che intensità del colore e prolina sono le uniche variabili chimiche con una **dipendenza condizionale diretta** con il contenuto alcolico. Tutti gli altri legami osservati nelle correlazioni marginali (Mgns, Ttlp, Flvn, ecc.) risultano **mediati** da variabili intermedie e vengono correttamente eliminati dal modello.

La struttura complessiva del grafo evidenzia anche cluster di variabili densamente connesse (ad esempio il blocco Ash-Flvn-Nnfp-Oodw-Prln-Ttlp) e variabili più periferiche con poche connessioni (come Mlca, connessa

solo a Hue).

Per valutare formalmente la bontà del modello selezionato, eseguiamo un **test del rapporto di verosimiglianza** (Likelihood Ratio Test, LRT) confrontandolo con il modello saturo. Sotto H_0 (il modello ridotto è adeguato), la statistica test $\Delta D = D_{\text{ridotto}} - D_{\text{saturo}}$ segue approssimativamente una distribuzione χ^2 con gradi di libertà pari al numero di archi rimossi:

```
# Test del rapporto di verosimiglianza: modello selezionato vs saturo
# Estrazione devianza e gradi di libertà
dev_sel <- mod_selezionato$fitinfo$dev
dev_sat <- mod_saturo$fitinfo$dev
df_sel <- mod_selezionato$fitinfo$dimension["df"]
df_sat <- mod_saturo$fitinfo$dimension["df"]

# Statistica test e p-value
delta_dev <- dev_sel - dev_sat
delta_df <- df_sel - df_sat
p_value <- 1 - pchisq(delta_dev, df = delta_df)

cat("Devianza modello selezionato:", round(dev_sel, 3), "\n")
```

```
## Devianza modello selezionato: 69.435
```

```
cat("Devianza modello saturo:", round(dev_sat, 3), "\n")
```

```
## Devianza modello saturo: 0
```

```
cat("Delta devianza:", round(delta_dev, 3), "\n")
```

```
## Delta devianza: 69.435
```

```
cat("Gradi di libertà:", delta_df, "\n")
```

```
## Gradi di libertà: 45
```

```
cat("P-value:", round(p_value, 4), "\n")
```

```
## P-value: 0.0112
```

Il test di devianza verifica l'ipotesi nulla H_0 : "il modello ridotto è adeguato" contro H_1 : "il modello saturo è necessario". Il p-value ottenuto è inferiore a 0.05, indicando che il test del rapporto di verosimiglianza **rigetta** H_0 : dal punto di vista del puro adattamento ai dati, la rimozione di 45 archi comporta una perdita di fit statisticamente significativa.

Tuttavia, questo risultato **non invalida** la selezione operata dal BIC. I due criteri rispondono a domande diverse: il LRT misura esclusivamente la bontà di adattamento, mentre il BIC bilancia il fit con la **parsimonia** del modello, penalizzando la complessità con un termine $k \cdot \ln(n)$ più severo. È un fenomeno atteso che il LRT e il BIC possano non concordare, soprattutto quando il numero di parametri rimossi è elevato: il BIC accetta una lieve perdita di adattamento se il guadagno in semplicità è sostanziale. Nel nostro caso, il modello BIC-selezionato riduce il numero di archi da 78 a 33 (una riduzione del 58%), ottenendo un grafo **interpretabile** che mantiene solo le dipendenze condizionali più rilevanti. Questa scelta è appropriata ai fini della nostra analisi, il cui obiettivo primario è identificare la struttura di dipendenza essenziale piuttosto che massimizzare il fit.

4.4 Grafo Indiretto - Interà Popolazione

Il modello selezionato nella sezione precedente definisce un **grafo indiretto** (Undirected Graph, UG) in cui ogni arco rappresenta una dipendenza condizionale statisticamente rilevante tra due variabili. Visualizziamo questo grafo per ottenere una rappresentazione intuitiva della struttura di dipendenza tra le 13 variabili chimiche.

```
# Estrazione del grafo dal modello selezionato
ug_plot <- mod_selezionato$modelinfo$ug

# Calcolo del grado di ciascun nodo per dimensionamento
gradi <- igraph::degree(ug_plot)

# Identificazione dei vicini di Alch per la colorazione
vicini_alch <- names(neighbors(ug_plot, "Alch"))

# Colorazione dei nodi
colori_nodi <- ifelse(V(ug_plot)$name == "Alch", "#E46726",
                     ifelse(V(ug_plot)$name %in% vicini_alch, "#FFD700", "#6D9EC1"))

# Layout Kamada-Kawai per disposizione compatta e leggibile
set.seed(42)
layout_kk <- layout_with_kk(ug_plot)

# Margini ridotti per massimizzare lo spazio del grafo
par(mar = c(1, 1, 0.5, 1))

# Plot del grafo
plot(ug_plot,
     layout = layout_kk,
     vertex.size = 7 + gradi * 1.5,
     vertex.color = colori_nodi,
     vertex.frame.color = "gray30",
     vertex.label.cex = 0.7,
     vertex.label.color = "black",
     vertex.label.font = 2,
     edge.color = "gray50",
     edge.width = 1.3,
     main = "")

# Legenda
legend("bottomleft",
      legend = c("Alch (target)", "Vicini diretti di Alch", "Altre variabili"),
      fill = c("#E46726", "#FFD700", "#6D9EC1"),
      cex = 0.6,
      bty = "n")
```




Figure 9: Grafo indiretto (UG) del modello selezionato - Intera popolazione

Il grafo indiretto rivela una struttura di dipendenza ricca e informativa. Analizziamone i principali aspetti.

Posizione della variabile target. Il contenuto alcolico (**Alch**) è connesso a sole 2 variabili: **Clri** (intensità del colore) e **Prln** (prolina). Questo significa che, condizionatamente a tutte le altre variabili chimiche, Alch è **indipendente** dalle restanti 10 variabili. In termini probabilistici, conoscere i valori di Clri e Prln rende le altre 10 variabili irrilevanti per predire il contenuto alcolico. Questo risultato ha una chiara implicazione per la modellazione predittiva: un modello di regressione per Alch dovrebbe includere almeno Clri e Prln come predittori.

Hub centrali. Il grafo presenta nodi ad alta connettività che fungono da **hub** nella struttura di dipendenza:

```
# Tabella dei gradi dei nodi (ordinata per grado decrescente)
df_gradi <- data.frame(
  Variabile = names(sort(gradi, decreasing = TRUE)),
  Grado = as.integer(sort(gradi, decreasing = TRUE))
)
knitr::kable(df_gradi, caption = "Grado di connettività dei nodi nel grafo selezionato")
```

Table 2: Grado di connettività dei nodi nel grafo selezionato

Variabile	Grado
Prln	10
Oodw	8
Ash	7
Flvn	7
Ttlp	7
Hue	6
Nnfp	5
Clri	5
Mgns	4
Aloa	3
Alch	2
Prnt	1
Mlca	1

La variabile con il grado più elevato è **Prln** (prolina), che si conferma come un **hub centrale** nella rete di dipendenze chimiche, connessa a un gran numero di variabili. Questo ruolo di hub è coerente con il fatto che la prolina è un amminoacido la cui concentrazione è influenzata da molteplici processi biochimici durante la maturazione dell'uva. Seguono **Oodw** (rapporto di assorbanza), **Ash** (ceneri) e **Ttlp/Flvn** (composti fenolici), che formano il nucleo più densamente connesso del grafo.

Al contrario, **Alch** (grado 2), **Mlca** (grado 1) e **Prnt** (grado 1) sono variabili **periferiche**: Mlca è connessa unicamente a Hue, e Prnt solo a Flvn. Questa perifericità indica che queste variabili hanno poche dipendenze condizionali dirette con il resto del sistema chimico, e la loro informazione è in gran parte assorbita indirettamente dalle variabili più centrali.

Cluster di variabili. Il grafo evidenzia due raggruppamenti principali:

- Un **cluster denso centrale** formato da Ash, Flvn, Nnfp, Oodw, Prln, Ttlp, Mgns e Hue, che rappresenta il nucleo delle relazioni chimiche fondamentali. All'interno di questo cluster, le variabili sono fortemente interconnesse, riflettendo la dipendenza condizionale reciproca tra composti fenolici, minerali e indicatori di assorbanza.
- Una **periferia** composta da Alch (connessa solo a Clri e Prln), Mlca (connessa solo a Hue) e Prnt (connessa solo a Flvn), che rappresentano variabili con poche dipendenze dirette.

Ruolo di mediazione. La struttura del grafo suggerisce che **Prln** e **Clri** agiscono come **mediatori** tra il contenuto alcolico e il resto del sistema chimico. Ad esempio, la correlazione marginale tra Alch e Mgns ($r=0.27$) non corrisponde a un arco nel grafo: l'associazione osservata è interamente mediata da Prln, che è connessa sia a Mgns che ad Alch. Analogamente, il legame marginale tra Alch e Ttlp ($r=0.29$) transita attraverso Prln e il cluster fenolico.

4.5 Grafo Indiretto - Con Cultivar

Includiamo ora la variabile **Cult** per valutare come il tipo di coltivazione modifichi la rete di dipendenze condizionali. Per compatibilità con i modelli grafici gaussiani, convertiamo Cult in **due variabili dummy**: Cult_v2 e Cult_v3 (con v1 come livello di riferimento). Il modello saturo con 15 variabili ha $\binom{15}{2} = 105$ archi.

```
# Creazione di variabili dummy per Cult
wine_dummy <- wine %>%
  mutate(Cult_v2 = as.numeric(Cult == "v2"),
         Cult_v3 = as.numeric(Cult == "v3")) %>%
  select(-Cult)

# Modello saturo e selezione backward con BIC
mod_saturo_cult <- cmod(~.^., data = wine_dummy)
mod_sel_cult <- backward(mod_saturo_cult, k = log(nrow(wine_dummy)))
```

```
cat("Modello saturo: 105 archi possibili\n")
```

```
## Modello saturo: 105 archi possibili
```

```
cat("Modello selezionato:", length(edgeList(mod_sel_cult$modelinfo$ug)), "archi\n")
```

```
## Modello selezionato: 60 archi
```

```
cat("Archi rimossi:", 105 - length(edgeList(mod_sel_cult$modelinfo$ug)), "\n")
```

```
## Archi rimossi: 45
```

La selezione BIC mantiene un sottoinsieme parsimonioso di archi. Analizziamo quali variabili sono connesse alle dummy cultivar e ad Alch:

```
ug_sel_cult <- mod_sel_cult$modelinfo$ug
archi_sel_cult <- edgeList(ug_sel_cult)
```

Archi con le dummy cultivar

```
archi_cult_v2 <- archi_sel_cult[sapply(archi_sel_cult, function(x) "Cult_v2" %in% x)]
archi_cult_v3 <- archi_sel_cult[sapply(archi_sel_cult, function(x) "Cult_v3" %in% x)]
```

```
cat("Archi Cult_v2 (", length(archi_cult_v2), "):",
    if(length(archi_cult_v2) > 0) {
      archi_str <- sapply(archi_cult_v2, function(x) paste(x, collapse = "-"))
      paste(strwrap(paste(archi_str, collapse = ", "), width = 80), collapse = "\n ")
    } else "Nessuno", "\n\n")
```

```
## Archi Cult_v2 ( 13 ): Aloa-Cult_v2, Ttlp-Cult_v2, Flvn-Cult_v2, Nnfp-Cult_v2, Clri-Cult_v2,
## Cult_v2-Cult_v3, Cult_v2-Mgns, Cult_v2-Oodw, Cult_v2-Prnt, Cult_v2-Ash,
## Cult_v2-Prln, Cult_v2-Mlca, Cult_v2-Alch
```

```
cat("Archi Cult_v3 (", length(archi_cult_v3), "):",
    if(length(archi_cult_v3) > 0) {
      archi_str <- sapply(archi_cult_v3, function(x) paste(x, collapse = "-"))
      paste(strwrap(paste(archi_str, collapse = ", "), width = 80), collapse = "\n ")
    } else "Nessuno", "\n\n")
```

```
## Archi Cult_v3 ( 12 ): Aloa-Cult_v3, Ttlp-Cult_v3, Flvn-Cult_v3, Nnfp-Cult_v3, Clri-Cult_v3,
## Cult_v2-Cult_v3, Cult_v3-Mgns, Cult_v3-Oodw, Cult_v3-Prln, Cult_v3-Mlca,
## Cult_v3-Hue, Cult_v3-Alch
```

Archi con Alch

```
archi_alch_cult <- archi_sel_cult[sapply(archi_sel_cult, function(x) "Alch" %in% x)]
cat("Archi Alch (", length(archi_alch_cult), "):",
    paste(sapply(archi_alch_cult, function(x) paste(x, collapse = "-")), collapse = ", "), "\n")
```

```
## Archi Alch ( 3 ): Clri-Alch, Cult_v2-Alch, Cult_v3-Alch
```

Estrazione del grafo

```
ug_plot_cult <- mod_sel_cult$modelinfo$ug
```

Calcolo del grado di ciascun nodo

```
gradi_cult <- igraph::degree(ug_plot_cult)
```

Identificazione dei vicini di Alch e delle variabili dummy cultivar

```
vicini_alch_cult <- names(neighbors(ug_plot_cult, "Alch"))
vicini_cult_v2 <- if("Cult_v2" %in% V(ug_plot_cult)$name) {
  names(neighbors(ug_plot_cult, "Cult_v2"))
} else { character(0) }
vicini_cult_v3 <- if("Cult_v3" %in% V(ug_plot_cult)$name) {
  names(neighbors(ug_plot_cult, "Cult_v3"))
} else { character(0) }
vicini_cult <- unique(c(vicini_cult_v2, vicini_cult_v3))
```

Colorazione dei nodi

```
colori_nodi_cult <- ifelse(V(ug_plot_cult)$name == "Alch", "#E46726",
  ifelse(V(ug_plot_cult)$name %in% c("Cult_v2", "Cult_v3"), "#9370DB",
  ifelse(V(ug_plot_cult)$name %in% vicini_alch_cult, "#FFD700",
```

```

        ifelse(V(ug_plot_cult)$name %in% vicini_cult, "#98FB98", "#6D9EC1"))))

# Layout Kamada-Kawai
set.seed(123)
layout_kk_cult <- layout_with_kk(ug_plot_cult)

# Aggiustamento manuale: sposta Alch più in basso per distanziare i suoi archi
idx_alch <- which(V(ug_plot_cult)$name == "Alch")
layout_kk_cult[idx_alch, 2] <- layout_kk_cult[idx_alch, 2] - 1.8

# Margini ridotti
par(mar = c(1, 1, 0.5, 1))

# Plot del grafo
plot(ug_plot_cult,
     layout = layout_kk_cult,
     vertex.size = 7 + gradi_cult * 1.5,
     vertex.color = colori_nodi_cult,
     vertex.frame.color = "gray30",
     vertex.label.cex = 0.7,
     vertex.label.color = "black",
     vertex.label.font = 2,
     edge.color = "gray50",
     edge.width = 1.3,
     main = "")

# Legenda
legend("bottomleft",
      legend = c("Alch (target)", "Cult_v2/v3 (cultivar)",
                 "Vicini di Alch", "Vicini di Cultivar", "Altre variabili"),
      fill = c("#E46726", "#9370DB", "#FFD700", "#98FB98", "#6D9EC1"),
      cex = 0.6,
      bty = "n")

```




Figure 10: Grafo indiretto (UG) con cultivar - Modello selezionato con BIC

Il grafo mostra come le dummy cultivar si integrino nella rete di dipendenze. Un confronto quantitativo con

il modello senza cultivar rivela quali archi sono modificati dall'inclusione del tipo di coltivazione:

```
archi_no_cult <- edgeList(ug_sel)
archi_si_cult <- edgeList(ug_sel_cult)
archi_si_cult_no_cult <- archi_si_cult[!sapply(archi_si_cult,
      function(x) any(c("Cult_v2", "Cult_v3") %in% x))]

archi_to_string <- function(archi_list) {
  sapply(archi_list, function(x) paste(sort(x), collapse = "-"))
}

set_no_cult <- archi_to_string(archi_no_cult)
set_si_cult <- archi_to_string(archi_si_cult_no_cult)

cat("Archi comuni:", length(intersect(set_no_cult, set_si_cult)), "\n")
```

```
## Archi comuni: 19
```

```
cat("Solo SENZA cultivar:", length(setdiff(set_no_cult, set_si_cult)), "\n")
```

```
## Solo SENZA cultivar: 14
```

```
cat("Solo CON cultivar:", length(setdiff(set_si_cult, set_no_cult)), "\n")
```

```
## Solo CON cultivar: 17
```

La connettività dei nodi confrontata tra i due modelli evidenzia come il cultivar redistribuisca le dipendenze:

```
# Tabella dei gradi (ordinata)
df_gradi_cult <- data.frame(
  Variabile = names(sort(gradi_cult, decreasing = TRUE)),
  Grado = as.integer(sort(gradi_cult, decreasing = TRUE))
)

# Calcolo della variazione di grado rispetto al modello senza cultivar
# (per le variabili chimiche, escludendo Cult_v2 e Cult_v3 che non erano presenti)
df_gradi_cult$Grado_NoCult <- NA
for(i in seq_len(nrow(df_gradi_cult))) {
  var <- df_gradi_cult$Variabile[i]
  if(!var %in% c("Cult_v2", "Cult_v3") && var %in% names(gradi)) {
    df_gradi_cult$Grado_NoCult[i] <- gradi[var]
  }
}
df_gradi_cult$Delta <- df_gradi_cult$Grado - df_gradi_cult$Grado_NoCult

knitr::kable(df_gradi_cult, caption = "Grado di connettività nel modello con cultivar")
```

Table 3: Grado di connettività nel modello con cultivar

Variabile	Grado	Grado_NoCult	Delta
Clri	13	5	8
Cult_v2	13	NA	NA
Cult_v3	12	NA	NA
Aloa	10	3	7
Nnfp	10	5	5

Variabile	Grado	Grado_NoCult	Delta
Flvn	9	7	2
Mgns	9	4	5
Ttlp	7	7	0
Prnt	7	1	6
Oodw	6	8	-2
Ash	6	7	-1
Prln	6	10	-4
Mlca	5	1	4
Hue	4	6	-2
Alch	3	2	1

La colonna **Delta** mostra come cambia la connettività delle variabili chimiche con l'inclusione del cultivar. Le dummy Cult_v2 e Cult_v3 con grado elevato indicano che il cultivar introduce nuova informazione strutturale; un grado basso suggerisce invece che le differenze sono in gran parte mediate dalle variabili chimiche.

In sintesi, l'inclusione del cultivar modifica profondamente la struttura del grafo: alcune relazioni del modello senza cultivar erano spurie e mediate dal tipo di coltivazione. **Crucialmente, il modello selezionato include archi diretti Cult_v2-Alch e Cult_v3-Alch**, indicando che il tipo di coltivazione ha un effetto diretto sul contenuto alcolico indipendentemente dalle altre variabili chimiche. Oltre a Clri e Prln (già presenti nel modello senza cultivar), anche le cultivar v2 e v3 sono quindi predittori diretti di Alch, un risultato rilevante per il modello di regressione lineare (Capitolo 6).

4.6 Sintesi dei Modelli Grafici Indiretti

L'analisi dei modelli grafici indiretti ha rivelato la struttura di dipendenze condizionali tra le variabili chimiche del vino, sia nell'intera popolazione che includendo il tipo di cultivar.

Modello senza cultivar (sezione 4.4). Il grafo selezionato con BIC mantiene 33 archi su 78 possibili, con una riduzione del 58% dei parametri. La variabile target **Alch** è connessa unicamente a **Clri** e **Prln**, indicando che, condizionatamente a tutte le altre variabili, solo queste due sono direttamente rilevanti per il contenuto alcolico. Il grafo presenta un cluster denso centrale composto da variabili fenoliche e minerali (Ash, Flvn, Oodw, Ttlp, Mgns), mentre Alch, Mlca e Prnt occupano posizioni periferiche. **Prln** emerge come hub centrale, confermando il suo ruolo di mediatore tra Alch e il resto del sistema chimico.

Modello con cultivar (sezione 4.5). L'inclusione delle variabili dummy **Cult_v2** e **Cult_v3** modifica sostanzialmente la rete di dipendenze. Il modello selezionato include connessioni dirette **Cult_v2-Alch** e **Cult_v3-Alch**, indicando che il tipo di coltivazione ha un **effetto diretto** sul contenuto alcolico, indipendente dalle altre variabili chimiche. Alch è quindi connessa a **3 variabili**: Clri, Cult_v2 e Cult_v3. Significativamente, la connessione Alch-Prln presente nel modello senza cultivar scompare, suggerendo che l'associazione tra prolina e contenuto alcolico era in parte mediata dal tipo di coltivazione.

Implicazioni principali:

1. Alcune relazioni del modello senza cultivar erano spurie, dovute al confondimento con il tipo di coltivazione.
2. Le cultivar introducono nuova informazione strutturale: hanno un effetto autonomo sulla composizione del vino.
3. Per la regressione lineare (Capitolo 6), il cultivar dovrebbe essere incluso come predittore diretto di Alch insieme a Clri e Prln.
4. I modelli indiretti identificano dipendenze condizionali ma non orientano gli archi. Nel Capitolo 5 esploreremo i grafi aciclici diretti (DAG) per identificare relazioni causali.

5 Modelli Grafici Diretti (DAG)

Nel Capitolo 4 abbiamo utilizzato grafi indiretti (UG) per identificare le **dipendenze condizionali** tra le variabili chimiche del vino. I grafi indiretti, tuttavia, non forniscono informazioni sulla **direzione** delle relazioni: un arco tra due variabili indica una dipendenza, ma non specifica quale variabile influenza l'altra.

In questo capitolo utilizziamo i **grafi aciclici diretti** (Directed Acyclic Graphs, DAG) per orientare gli archi e identificare **relazioni causali** tra le variabili. I DAG permettono di rappresentare una struttura di dipendenza più ricca, in cui ogni arco orientato $X \rightarrow Y$ suggerisce che X ha un'influenza diretta su Y , condizionatamente alle altre variabili del grafo. La proprietà di aciclicità garantisce l'assenza di loop causali, rendendo il modello interpretabile in termini di relazioni gerarchiche.

La strategia di analisi rispecchia quella del capitolo precedente:

1. **DAG per l'intera popolazione** (senza cultivar): esploriamo prima un DAG libero, poi un DAG vincolato con **Alch come variabile target** (sink), per identificare i predittori diretti del contenuto alcolico.
2. **DAG con cultivar**: includiamo le variabili dummy Cult_v2 e Cult_v3 e valutiamo come il tipo di coltivazione modifichi la struttura causale. Analizziamo un DAG libero e poi un DAG con **Cult come variabile esogena** (source) e **Alch come target** (sink).

I DAG vengono stimati mediante **modelli di regressione gaussiana** per grafi diretti, utilizzando criteri di informazione (AIC o BIC) per la selezione del modello. A differenza dei grafi indiretti, i DAG richiedono l'orientamento degli archi, che può essere guidato da conoscenze a priori (variabili esogene/endogene) o da procedure di ricerca automatica.

5.1 DAG - Intera Popolazione

5.1.1 DAG Libero

Costruiamo un DAG senza vincoli di orientamento utilizzando una **procedura di selezione stepwise** guidata dal criterio BIC. Partiamo dal modello vuoto (nessun arco) e aggiungiamo iterativamente archi orientati che migliorano significativamente il fit del modello.

```
# Apprendimento di struttura DAG da dati continui usando algoritmo Hill-Climbing
# con score BIC (Bayesian Information Criterion)
dag_libero <- hc(wine_no_cult, score = "bic-g")

# Numero di archi selezionati
n_archi_dag <- narcs(dag_libero)
cat("Numero di archi nel DAG libero:", n_archi_dag, "\n")
```

```
## Numero di archi nel DAG libero: 24
```

```
# Conversione in oggetto igraph per la visualizzazione
dag_igraph <- as.igraph(dag_libero)
```

Il DAG libero selezionato contiene un sottoinsieme di archi orientati che rappresentano dipendenze causali dirette. Visualizziamo il grafo:

```
# Identificazione dei genitori (cause dirette) e figli (effetti diretti) di Alch
genitori_alch <- parents(dag_libero, "Alch")
figli_alch <- children(dag_libero, "Alch")

# Colorazione dei nodi
colori_nodi_dag <- ifelse(V(dag_igraph)$name == "Alch", "#E46726",
  ifelse(V(dag_igraph)$name %in% genitori_alch, "#FFD700",
    ifelse(V(dag_igraph)$name %in% figli_alch, "#90EE90", "#6D9EC1")))
```

```

# Layout gerarchico (sugiyama layout per DAG)
set.seed(456)
layout_dag <- layout_with_sugiyama(dag_igraph)$layout

# Margini ridotti
par(mar = c(1, 1, 0.5, 1))

# Plot del DAG
plot(dag_igraph,
     layout = layout_dag,
     vertex.size = 8,
     vertex.color = colori_nodi_dag,
     vertex.frame.color = "gray30",
     vertex.label.cex = 0.7,
     vertex.label.color = "black",
     vertex.label.font = 2,
     edge.color = "gray50",
     edge.width = 1.5,
     edge.arrow.size = 0.5,
     edge.curved = 0.1,
     main = "")

# Legenda
legend("bottomleft",
      legend = c("Alch (target)", "Genitori di Alch", "Figli di Alch", "Altre variabili"),
      fill = c("#E46726", "#FFD700", "#90EE90", "#6D9EC1"),
      cex = 0.6,
      bty = "n")

```




Figure 11: DAG libero - Interza popolazione

Il DAG libero rivela la struttura di dipendenza causale tra le variabili. Analizziamo i genitori e i figli di Alch:

```
cat("Genitori di Alch (predittori diretti):",  
    if(length(genitori_alch) > 0) paste(genitori_alch, collapse = ", ") else "Nessuno", "\n")
```

```
## Genitori di Alch (predittori diretti): Nessuno
```

```
cat("Figli di Alch (variabili causate da Alch):",  
    if(length(figli_alch) > 0) paste(figli_alch, collapse = ", ") else "Nessuno", "\n")
```

```
## Figli di Alch (variabili causate da Alch): Clri, Hue, Prln
```

Il DAG libero identifica quali variabili sono **cause dirette** del contenuto alcolico (genitori) e quali sono **effetti diretti** (figli). A differenza del grafo indiretto, il DAG specifica la direzione delle relazioni, fornendo un'interpretazione causale più ricca.

Tuttavia, il risultato ottenuto solleva una questione importante: **Alch non ha genitori ma ha tre figli** (Clri, Hue, Prln). Questo suggerisce che l'algoritmo ha interpretato il contenuto alcolico come una "causa" piuttosto che come un "effetto" delle altre proprietà chimiche. Questa orientazione, sebbene statisticamente ottimale secondo il criterio BIC applicato ai dati osservazionali, è **contro-intuitiva dal punto di vista del dominio enologico**: ci aspetteremmo che variabili come la prolina, i fenoli o l'acidità influenzino il contenuto alcolico durante il processo di fermentazione, non viceversa.

Questo illustra un **limite fondamentale dell'inferenza causale puramente data-driven**: senza vincoli basati sulla conoscenza del dominio, l'algoritmo può orientare gli archi in qualsiasi direzione che massimizzi il fit statistico, producendo strutture causali plausibili dal punto di vista matematico ma non necessariamente interpretabili. Per questo motivo, nella prossima sezione imponiamo vincoli espliciti per garantire che Alch sia modellato come variabile target.

5.1.2 DAG con Alch Target

Per imporre questa struttura causale basata sulla conoscenza del dominio, costruiamo un **DAG vincolato** dove Alch può essere solo un **node sink** (ricevere archi ma non emetterne). Questo significa che Alch può avere solo genitori (predittori diretti) ma non figli.

```
# Creazione della blacklist: Alch non può essere genitore di nessuna variabile  
altre_vars <- setdiff(names(wine_no_cult), "Alch")  
blacklist_alch <- data.frame(  
  from = rep("Alch", length(altre_vars)),  
  to = altre_vars  
)
```

```
# Apprendimento DAG con vincolo: Alch come sink node  
dag_target <- hc(wine_no_cult, score = "bic-g", blacklist = blacklist_alch)
```

```
# Numero di archi selezionati  
n_archi_target <- narcs(dag_target)  
cat("Numero di archi nel DAG vincolato:", n_archi_target, "\n")
```

```
## Numero di archi nel DAG vincolato: 23
```

```
cat("Numero di archi nel DAG libero:", n_archi_dag, "\n")
```

```
## Numero di archi nel DAG libero: 24
```

```
# Conversione in oggetto igraph
dag_target_igraph <- as.igraph(dag_target)
```

Il vincolo imposto modifica la struttura appresa: l'algoritmo deve ora trovare la migliore configurazione di archi compatibile con l'assunzione che Alch sia una variabile risposta. Visualizziamo il DAG vincolato:

```
# Identificazione dei genitori di Alch (ora non può avere figli per costruzione)
genitori_alch_target <- parents(dag_target, "Alch")
# Colorazione dei nodi
colori_nodi_target <- ifelse(V(dag_target_igraph)$name == "Alch", "#E46726",
                             ifelse(V(dag_target_igraph)$name %in% genitori_alch_target,
                                     "#FFD700", "#6D9EC1"))

# Layout gerarchico
set.seed(789)
layout_target <- layout_with_sugiyama(dag_target_igraph)$layout
# Margini ridotti
par(mar = c(1, 1, 0.5, 1))
# Plot del DAG
plot(dag_target_igraph,
     layout = layout_target,
     vertex.size = 8,
     vertex.color = colori_nodi_target,
     vertex.frame.color = "gray30",
     vertex.label.cex = 0.7,
     vertex.label.color = "black",
     vertex.label.font = 2,
     edge.color = "gray50",
     edge.width = 1.5,
     edge.arrow.size = 0.5,
     edge.curved = 0.1,
     main = "")
# Legenda
legend("bottomright",
      legend = c("Alch (target)", "Predittori diretti di Alch", "Altre variabili"),
      fill = c("#E46726", "#FFD700", "#6D9EC1"),
      cex = 0.6,
      bty = "n")
```




Figure 12: DAG vincolato con Alch come sink - Intera popolazione

Analizziamo i predittori diretti di Alch nel modello vincolato:

```
cat("Predittori diretti di Alch:",  
    if(length(genitori_alch_target) > 0)  
      paste(genitori_alch_target, collapse = ", ") else "Nessuno", "\n")
```

```
## Predittori diretti di Alch: Clri, Prln
```

Il DAG vincolato identifica le variabili che hanno un **effetto causale diretto** sul contenuto alcolico, secondo la struttura ottimale compatibile con il vincolo imposto. Queste variabili rappresentano i candidati naturali per un modello di regressione che mira a predire il contenuto alcolico.

Confronto tra DAG libero e DAG vincolato:

Imporre il vincolo che Alch sia un nodo sink ha modificato sostanzialmente la struttura del grafo:

- **Numero di archi:** Il DAG vincolato contiene un numero diverso di archi rispetto al DAG libero, riflettendo la riorganizzazione della struttura causale per rispettare il vincolo imposto.
- **Predittori di Alch:** Nel DAG libero, Alch non aveva genitori (predittori diretti), mentre nel DAG vincolato l'algoritmo ha identificato un insieme specifico di variabili come cause dirette del contenuto alcolico. Questi predittori rappresentano le variabili chimiche che, condizionatamente alle altre, hanno l'influenza più forte su Alch.
- **Interpretabilità:** Il DAG vincolato fornisce una struttura causale **più interpretabile e coerente** con la conoscenza enologica, dove il contenuto alcolico è chiaramente una variabile risposta influenzata da proprietà chimiche misurabili, piuttosto che una causa di esse.

Questa analisi dimostra l'importanza di **integrare conoscenza del dominio** nell'inferenza causale: i vincoli espliciti guidano l'algoritmo verso strutture causali più plausibili e utili per l'interpretazione scientifica e la modellazione predittiva.

Collegamento con i Grafi Indiretti (Capitolo 4):

Prima di procedere con l'analisi che include il cultivar, è utile confrontare i risultati tra grafi indiretti (UG) e grafi diretti (DAG):

- Nel **Capitolo 4** (grafi indiretti), abbiamo identificato le variabili connesse ad Alch tramite archi non orientati, che indicano dipendenze condizionali ma non specificano la direzione della relazione causale.
- In questo capitolo, il **DAG vincolato** fornisce informazioni più specifiche: identifica non solo quali variabili sono dipendenti da Alch, ma anche la **direzione causale**, specificando quali variabili agiscono come predittori diretti del contenuto alcolico.
- Confrontando i due grafi, possiamo osservare che alcune variabili connesse ad Alch nel grafo indiretto sono state identificate come **genitori diretti** nel DAG, mentre altre potrebbero influenzare Alch solo indirettamente, attraverso catene causali mediate da altre variabili.

5.2 DAG - Con Cultivar

5.2.1 DAG Libero con Cultivar

5.2.2 DAG con Cult Esogena e Alch Target

5.3 Sintesi dei Modelli Grafici Diretti

6 Modello Predittivo

6.1 Intera Popolazione

6.1.1 Definizione Modelli Base

6.1.2 Selezione con BIC

6.1.3 Diagnostica del Modello

6.1.4 Verifica Multicollinearità

6.2 Wine Dataset con Cultivar

6.2.1 Definizione Modelli Base

6.2.2 Selezione con BIC

6.2.3 Diagnostica del Modello

6.3 Confronto Modelli

7 Conclusioni

7.1 Bibliografia