

Analisi Statistica del Contenuto Alcolico nel Vino

Modelli Grafici e Predittivi sul Wine Dataset

Eros Pinzani

Contents

Abstract	3
1 Introduzione	3
1.1 Il Dataset Wine	3
1.2 Variabile Target: Contenuto Alcolico	3
1.3 Obiettivi dello Studio	3
1.3.1 Fase 1: Analisi della Popolazione Globale (senza Cultivar)	4
1.3.2 Fase 2: Analisi con Cultivar	4
1.3.3 Metodologia	4
1.4 Software	4
2 Osservazioni e Preprocessing dei Dati	5
2.1 Visualizzazione Dataset	5
2.2 Preparazione dei Dati	7
2.2.1 Dataset per la Fase 1: Popolazione Globale	7
2.2.2 Dataset per la Fase 2: Analisi Completa con Cultivar	7
3 Analisi Esplorativa	9
3.1 Statistiche Descrittive e Density Plot	9
3.2 BoxPlot	11
3.3 Matrici Scatterplot	12
3.4 Matrice di Correlazione	13
3.4.1 Correlazioni - Intera Popolazione	13
3.4.2 Correlazioni per Cultivar - Confronto	14
3.5 Heatmap delle Correlazioni	15
3.5.1 Heatmap - Intera Popolazione	15
3.6 Sintesi dell'Analisi Esplorativa	17
4 Modelli Grafici Indiretti	18
4.1 Introduzione ai Modelli Grafici Gaussiani	18
4.2 Matrice di Concentrazione - Intera Popolazione	18
4.2.1 Correlazioni Parziali - Intera Popolazione	19
4.3 Selezione del Modello - Intera Popolazione	22
4.4 Grafo Indiretto - Intera Popolazione	26
4.5 Grafo Indiretto - Con Cultivar	28
4.6 Sintesi dei Modelli Grafici Indiretti	32
5 Modelli Grafici Diretti (DAG)	33
5.1 DAG - Intera Popolazione	33
5.1.1 DAG Libero	33
5.1.2 DAG con Alch Target	35

5.2	DAG - Con Cultivar	37
5.2.1	DAG Libero con Cultivar	37
5.2.2	DAG con Cult Esogena e Alch Target	40
5.3	Sintesi dei Modelli Grafici Diretti	43
5.3.1	Confronto tra Modelli e Principali Scoperte	43
5.3.2	Collegamento con i Grafi Indiretti (Capitolo 4)	44
5.3.3	Implicazioni per la Modellazione Predittiva (Capitolo 6)	44
6	Regressione Lineare Multipla	45
6.1	Il Modello di Regressione Lineare Multipla	45
6.1.1	Formulazione del Modello	45
6.1.2	Stima dei Parametri	45
6.2	Approccio Metodologico	46
6.3	Collegamento con i Modelli Grafici	47
6.4	Analisi sulla Popolazione Globale	47
6.4.1	Confronto con i Modelli Grafici	51
6.5	Wine Dataset con Cultivar	52
6.5.1	Confronto con i Modelli Grafici (con Cultivar)	56
7	Conclusioni	58
8	Riferimenti bibliografici	59

Abstract

In questo progetto analizziamo la composizione chimica di diversi campioni di vino con l'obiettivo di valutare in che modo alcune sostanze chimiche influenzino il contenuto alcolico. L'analisi prenderà in considerazione sia l'intera popolazione dei campioni sia il ruolo della variabile categorica cultivar, al fine di verificare se il tipo di coltivazione rappresenti un fattore determinante. L'approccio metodologico integra modelli grafici indiretti per individuare dipendenze condizionali, grafi aciclici diretti per esplorare relazioni causali, e regressione lineare multipla per quantificare l'effetto dei predittori chimici sul contenuto alcolico.

1 Introduzione

1.1 Il Dataset Wine

Il dataset Wine è un insieme di dati classico utilizzato in ambito statistico e di machine learning, contiene i risultati di analisi chimiche condotte su 178 campioni di vino provenienti dalla stessa regione italiana ma prodotti da tre diversi coltivatori (cultivar).

Le **13 variabili chimiche** misurate per ciascun campione sono:

- **Alch** (Alcohol): contenuto alcolico
- **Malca** (Malic Acid): acido malico
- **Ash**: ceneri
- **Aloa** (Alkalinity of Ash): alcalinità delle ceneri
- **Mgns** (Magnesium): magnesio
- **Ttlp** (Total Phenols): fenoli totali
- **Flvn** (Flavonoids): flavonoidi
- **Nnfp** (Nonflavanoid Phenols): fenoli non flavonoidi
- **Prnt** (Proanthocyanins): proantocianidine
- **Clri** (Color Intensity): intensità del colore
- **Hue**: tonalità
- **Oodw** (OD280/OD315 of diluted wines): rapporto di assorbanza
- **Prln** (Proline): prolina

Inoltre, il dataset include la variabile categorica **Cult** (Cultivar) che identifica il tipo di coltivazione (1, 2 o 3) da cui proviene ciascun campione.

1.2 Variabile Target: Contenuto Alcolico

In questa analisi, la variabile **Alch** (contenuto alcolico) rappresenta la nostra variabile target. Il contenuto alcolico è una delle caratteristiche più rilevanti nella valutazione della qualità del vino e dipende da molteplici fattori biochimici che intervengono durante il processo di fermentazione e produzione.

Comprendere quali componenti chimici influenzino maggiormente il contenuto alcolico permette di:

1. Identificare le **relazioni causali** tra la composizione chimica e il grado alcolico
2. Costruire **modelli predittivi** per stimare il contenuto alcolico a partire da altre misure chimiche
3. Valutare se e come il **tipo di cultivar** influenzi tali relazioni

1.3 Obiettivi dello Studio

L'obiettivo principale di questo studio è analizzare il contenuto alcolico nel vino utilizzando tecniche statistiche avanzate per comprendere le relazioni tra le variabili chimiche e il ruolo del cultivar. L'analisi si articola in due fasi distinte:

1.3.1 Fase 1: Analisi della Popolazione Globale (senza Cultivar)

Nella prima fase analizziamo l'intero dataset **escludendo la variabile Cult**, concentrandoci esclusivamente sulle relazioni chimiche pure tra le sostanze. Questo approccio permette di:

- Identificare le **dipendenze condizionali** tra le variabili chimiche attraverso modelli grafici indiretti (Gaussian Graphical Models)
- Studiare le **relazioni causali** tra componenti chimici mediante grafi aciclici diretti (DAG)
- Costruire **modelli predittivi** per il contenuto alcolico basati unicamente su fattori chimici
- Comprendere la struttura intrinseca delle relazioni biochimiche indipendentemente dal tipo di coltivazione

1.3.2 Fase 2: Analisi con Cultivar

Nella seconda fase includiamo la variabile **Cult** per valutare l'impatto del tipo di cultivar sulla composizione chimica e sul contenuto alcolico. Questa analisi permette di:

- Verificare se il cultivar modifica le **relazioni di dipendenza** tra le variabili chimiche
- Determinare se il tipo di coltivazione ha un **effetto diretto** sul contenuto alcolico
- Confrontare i modelli con e senza cultivar per valutare il **contributo informativo** di questa variabile categorica
- Esplorare eventuali **pattern di interazione** tra cultivar e componenti chimici

1.3.3 Metodologia

Per raggiungere questi obiettivi utilizzeremo tre approcci statistici complementari:

1. **Modelli Grafici Indiretti (Gaussian Graphical Models)**: per identificare le dipendenze condizionali tra variabili attraverso la matrice di concentrazione (inversa della matrice di covarianza)
2. **Modelli Grafici Diretti (DAG - Directed Acyclic Graphs)**: per esplorare possibili relazioni causali tra le variabili chimiche e il contenuto alcolico
3. **Regressione Lineare Multipla**: per quantificare l'effetto dei predittori chimici sul contenuto alcolico e valutare la capacità predittiva dei modelli

1.4 Software

L'analisi è condotta utilizzando il software **R**, un ambiente open-source ampiamente utilizzato per l'analisi statistica e la modellizzazione dei dati. Sono stati impiegati diversi pacchetti specializzati per l'analisi di modelli grafici gaussiani, l'inferenza causale tramite grafi aciclici diretti, la visualizzazione dei dati e la regressione lineare multipla.

Il codice R Markdown utilizzato per generare questo documento garantisce la **riproducibilità** completa dell'analisi.

2 Osservazioni e Preprocessing dei Dati

Prima di procedere con l'analisi statistica vera e propria, è fondamentale esplorare la struttura del dataset e preparare i dati in modo adeguato per le diverse fasi dell'analisi.

2.1 Visualizzazione Dataset

Il dataset **Wine** è disponibile nel pacchetto **gRbase** di R e contiene informazioni chimiche su 178 campioni di vino italiano. Iniziamo caricando il dataset e osservandone la struttura.

```
# Caricamento dataset Wine
data(wine)

# Visualizzazione delle prime righe
head(wine)
```

```
##  Cult  Alch Mlca  Ash Aloa Mgns Ttlp Flvn Nnfp Prnt Clri  Hue Oodw Prln
## 1   v1 14.23 1.71 2.43 15.6 127 2.80 3.06 0.28 2.29 5.64 1.04 3.92 1065
## 2   v1 13.20 1.78 2.14 11.2 100 2.65 2.76 0.26 1.28 4.38 1.05 3.40 1050
## 3   v1 13.16 2.36 2.67 18.6 101 2.80 3.24 0.30 2.81 5.68 1.03 3.17 1185
## 4   v1 14.37 1.95 2.50 16.8 113 3.85 3.49 0.24 2.18 7.80 0.86 3.45 1480
## 5   v1 13.24 2.59 2.87 21.0 118 2.80 2.69 0.39 1.82 4.32 1.04 2.93  735
## 6   v1 14.20 1.76 2.45 15.2 112 3.27 3.39 0.34 1.97 6.75 1.05 2.85 1450
```

La funzione `head()` mostra le **prime 6 osservazioni** del dataset, permettendoci di vedere i valori “grezzi” delle variabili per i primi campioni di vino. Questo ci consente di verificare immediatamente il formato dei dati e di avere un'idea dei range di valori per ciascuna variabile chimica. Possiamo osservare, ad esempio, che il contenuto alcolico (Alch) varia tra valori intorno a 13-14%, mentre la prolina (Prol) presenta valori nell'ordine delle centinaia.

Per ottenere una visione più completa della distribuzione dei dati, utilizziamo la funzione `summary()`:

```
# Statistiche descrittive per tutte le variabili
summary(wine)
```

```
##  Cult      Alch      Mlca      Ash      Aloa
## v1:59  Min.   :11.03  Min.   :0.740  Min.   :1.360  Min.   :10.60
## v2:71  1st Qu.:12.36  1st Qu.:1.603  1st Qu.:2.210  1st Qu.:17.20
## v3:48  Median :13.05  Median :1.865  Median :2.360  Median :19.50
##      Mean   :13.00  Mean   :2.336  Mean   :2.367  Mean   :19.49
##      3rd Qu.:13.68  3rd Qu.:3.083  3rd Qu.:2.558  3rd Qu.:21.50
##      Max.   :14.83  Max.   :5.800  Max.   :3.230  Max.   :30.00
##      Mgns      Ttlp      Flvn      Nnfp
## Min.   : 70.00  Min.   :0.980  Min.   :0.340  Min.   :0.1300
## 1st Qu.: 88.00  1st Qu.:1.742  1st Qu.:1.205  1st Qu.:0.2700
## Median : 98.00  Median :2.355  Median :2.135  Median :0.3400
## Mean   : 99.74  Mean   :2.295  Mean   :2.029  Mean   :0.3619
## 3rd Qu.:107.00  3rd Qu.:2.800  3rd Qu.:2.875  3rd Qu.:0.4375
## Max.   :162.00  Max.   :3.880  Max.   :5.080  Max.   :0.6600
##      Prnt      Clri      Hue      Oodw
## Min.   :0.410  Min.   : 1.280  Min.   :0.4800  Min.   :1.270
## 1st Qu.:1.250  1st Qu.: 3.220  1st Qu.:0.7825  1st Qu.:1.938
## Median :1.555  Median : 4.690  Median :0.9650  Median :2.780
## Mean   :1.591  Mean   : 5.058  Mean   :0.9574  Mean   :2.612
## 3rd Qu.:1.950  3rd Qu.: 6.200  3rd Qu.:1.1200  3rd Qu.:3.170
## Max.   :3.580  Max.   :13.000  Max.   :1.7100  Max.   :4.000
##      Prln
## Min.   : 278.0
## 1st Qu.: 500.5
## Median : 673.5
## Mean   : 746.9
## 3rd Qu.: 985.0
```

```
## Max. :1680.0
```

Il `summary()` fornisce una panoramica statistica completa del dataset:

- Per le **variabili numeriche** (Alch, Maac, Ash, ecc.), vengono calcolati:
 - **Min** e **Max**: valori minimo e massimo osservati
 - **1st Qu.** e **3rd Qu.**: primo e terzo quartile (25° e 75° percentile)
 - **Median**: valore mediano (50° percentile)
 - **Mean**: media aritmetica
- Per la **variabile categorica Cult**, viene mostrata la **frequenza** di ciascun livello (cultivar)

Queste statistiche sono fondamentali per identificare eventuali caratteristiche peculiari delle variabili, come la presenza di outlier o distribuzioni asimmetriche.

Esaminiamo ora la struttura formale del dataset:

```
# Struttura del dataset
str(wine)
```

```
## 'data.frame': 178 obs. of 14 variables:
## $ Cult: Factor w/ 3 levels "v1","v2","v3": 1 1 1 1 1 1 1 1 1 1 ...
## $ Alch: num 14.2 13.2 13.2 14.4 13.2 ...
## $ Mlca: num 1.71 1.78 2.36 1.95 2.59 1.76 1.87 2.15 1.64 1.35 ...
## $ Ash : num 2.43 2.14 2.67 2.5 2.87 2.45 2.45 2.61 2.17 2.27 ...
## $ Aloa: num 15.6 11.2 18.6 16.8 21 15.2 14.6 17.6 14 16 ...
## $ Mgns: int 127 100 101 113 118 112 96 121 97 98 ...
## $ Ttlp: num 2.8 2.65 2.8 3.85 2.8 3.27 2.5 2.6 2.8 2.98 ...
## $ Flvn: num 3.06 2.76 3.24 3.49 2.69 3.39 2.52 2.51 2.98 3.15 ...
## $ Nnfp: num 0.28 0.26 0.3 0.24 0.39 0.34 0.3 0.31 0.29 0.22 ...
## $ Prnt: num 2.29 1.28 2.81 2.18 1.82 1.97 1.98 1.25 1.98 1.85 ...
## $ Clri: num 5.64 4.38 5.68 7.8 4.32 6.75 5.25 5.05 5.2 7.22 ...
## $ Hue : num 1.04 1.05 1.03 0.86 1.04 1.05 1.02 1.06 1.08 1.01 ...
## $ Oodw: num 3.92 3.4 3.17 3.45 2.93 2.85 3.58 3.58 2.85 3.55 ...
## $ Prln: int 1065 1050 1185 1480 735 1450 1290 1295 1045 1045 ...
```

```
# Dimensioni del dataset
dim(wine)
```

```
## [1] 178 14
```

La funzione `str()` (structure) rivela che il dataset contiene **178 osservazioni** (campioni di vino) e **14 variabili**. Possiamo notare che:

- Le prime 13 variabili (da **Alch** a **Prol**) sono **variabili numeriche continue** (num) che rappresentano misure chimiche ottenute tramite analisi di laboratorio
- La variabile **Cult** è una variabile **categorica** (Factor) con tre livelli (v1, v2, v3), che identifica il tipo di cultivar da cui proviene ciascun campione

Questa distinzione è cruciale per le analisi successive, poiché le tecniche statistiche appropriate differiscono a seconda della natura delle variabili.

Approfondiamo la distribuzione dei campioni tra i tre cultivar:

```
# Distribuzione dei campioni per cultivar
table(wine$Cult)
```

```
##
## v1 v2 v3
## 59 71 48
```

```
# Proporzioni percentuali
round(prop.table(table(wine$Cult)) * 100, 1)
```

```
##
##   v1   v2   v3
## 33.1 39.9 27.0
```

La tabella di frequenza mostra che:

- Il **cultivar v1** conta 59 campioni (33.1% del totale)
- Il **cultivar v2** è il più rappresentato con 71 campioni (39.9%)
- Il **cultivar v3** presenta 48 campioni (27.0%)

Sebbene i tre cultivar non siano perfettamente bilanciati, tutti presentano un **numero sufficiente di osservazioni** ($n > 30$) per condurre analisi statistiche robuste e ottenere stime affidabili sia per l'intera popolazione che per i singoli gruppi.

2.2 Preparazione dei Dati

Come descritto nella sezione degli obiettivi, l'analisi si articola in **due fasi distinte** che richiedono due versioni del dataset:

2.2.1 Dataset per la Fase 1: Popolazione Globale

Per la prima fase dell'analisi, creiamo un dataset che **esclude la variabile Cult**, contenente esclusivamente le 13 misure chimiche. Questo ci permetterà di studiare le relazioni chimiche "pure" tra le sostanze, indipendentemente dal tipo di coltivazione.

```
# Creazione dataset senza la variabile Cult
wine_no_cult <- wine[, -which(names(wine) == "Cult")]

# Conversione di tutte le colonne a numeric (necessario per bnlearn)
wine_no_cult <- as.data.frame(lapply(wine_no_cult, as.numeric))

# Verifica della struttura
dim(wine_no_cult)
```

```
## [1] 178 13
```

```
names(wine_no_cult)
```

```
## [1] "Alch" "Mlca" "Ash" "Aloa" "Mgns" "Ttlp" "Flvn" "Nnfp" "Prnt" "Clri"
## [11] "Hue" "Oodw" "Prln"
```

Il dataset `wine_no_cult` contiene **13 variabili** (tutte continue) e sarà utilizzato per:

- Analisi esplorativa delle relazioni chimiche
- Costruzione di modelli grafici indiretti (UG)
- Inferenza di grafi causali (DAG) senza l'influenza del cultivar
- Modelli di regressione basati esclusivamente su predittori chimici

2.2.2 Dataset per la Fase 2: Analisi Completa con Cultivar

Per la seconda fase, utilizzeremo il **dataset completo** `wine` che include la variabile categorica **Cult**. Questo ci permetterà di:

- Valutare l'effetto del tipo di cultivar sulle relazioni tra variabili chimiche

- Verificare se il cultivar influenza direttamente il contenuto alcolico
- Confrontare i modelli con e senza cultivar

Prima di procedere, convertiamo la variabile `Cult` in fattore, se non lo è già, per assicurarci che R la tratti correttamente come variabile categorica nelle analisi successive.

```
# Verifica e conversione di Cult in fattore  
wine$Cult <- as.factor(wine$Cult)
```

```
# Verifica dei livelli  
levels(wine$Cult)
```

```
## [1] "v1" "v2" "v3"
```

Con i dati ora preparati possiamo procedere con l'analisi esplorativa approfondita che ci permetterà di comprendere le distribuzioni delle variabili, le loro correlazioni e le eventuali differenze tra i cultivar.

3 Analisi Esplorativa

L'analisi esplorativa permette di comprendere le distribuzioni, identificare outlier, visualizzare relazioni bivariate, quantificare correlazioni e confrontare i cultivar.

- Comprendere la **distribuzione** delle variabili chimiche e della variabile target (contenuto alcolico)
- Identificare eventuali **outlier** o valori anomali che potrebbero influenzare le analisi successive
- Visualizzare le **relazioni bivariate** tra le variabili attraverso grafici a dispersione
- Quantificare le **correlazioni lineari** tra i predittori chimici e il contenuto alcolico
- Confrontare le **caratteristiche distributive** dei tre cultivar per evidenziare eventuali differenze sistematiche

L'analisi esplorativa fornisce quindi una **base intuitiva** per interpretare i risultati dei modelli più complessi che costruiremo nelle sezioni successive. In particolare, l'esame delle correlazioni tra variabili ci darà indicazioni preliminari su quali componenti chimici potrebbero essere maggiormente associati al contenuto alcolico, mentre il confronto tra cultivar ci permetterà di valutare se il tipo di coltivazione introduce variabilità sistematica nella composizione chimica del vino.

In questa sezione utilizzeremo diverse tecniche di visualizzazione:

1. **Density plots:** per esaminare la forma delle distribuzioni univariate, verificare la presenza di asimmetrie o multimodalità, e confrontare visivamente le distribuzioni del contenuto alcolico tra i tre cultivar
2. **Boxplots:** per identificare la posizione centrale, la dispersione e la presenza di outlier, con particolare attenzione alle differenze del contenuto alcolico tra i cultivar
3. **Scatterplot matrices:** per esplorare le relazioni bivariate tra le variabili chimiche più rilevanti e individuare pattern lineari o non lineari
4. **Matrici di correlazione e heatmap:** per quantificare e visualizzare l'intensità delle associazioni lineari tra tutte le coppie di variabili, sia per l'intera popolazione che separatamente per ciascun cultivar

Questa esplorazione visiva e numerica ci consentirà di formulare **ipotesi informate** sulle relazioni tra variabili che saranno successivamente testate formalmente attraverso modelli grafici e regressione lineare multipla.

3.1 Statistiche Descrittive e Density Plot

Iniziamo l'analisi esplorativa esaminando la distribuzione della nostra **variabile target**: il contenuto alcolico (Alch). La Tabella seguente riporta le principali statistiche descrittive per l'intera popolazione e per ciascun cultivar.

```
# Statistiche per l'intera popolazione
stat_globali <- wine %>%
  summarise(
    Gruppo = "Globale",
    N = n(),
    Media = round(mean(Alch), 2),
    Dev_Std = round(sd(Alch), 2),
    Minimo = round(min(Alch), 2),
    Q1 = round(quantile(Alch, 0.25), 2),
    Mediana = round(median(Alch), 2),
    Q3 = round(quantile(Alch, 0.75), 2),
    Massimo = round(max(Alch), 2)
  )

# Statistiche per cultivar
stat_cultivar <- wine %>%
  group_by(Cult) %>%
  summarise(
    N = n(),
```

```

Media = round(mean(Alch), 2),
Dev_Std = round(sd(Alch), 2),
Minimo = round(min(Alch), 2),
Q1 = round(quantile(Alch, 0.25), 2),
Mediana = round(median(Alch), 2),
Q3 = round(quantile(Alch, 0.75), 2),
Massimo = round(max(Alch), 2)
) %>%
mutate(Gruppo = paste("Cultivar", ifelse(Cult == "v1", "1", ifelse(Cult == "v2", "2", "3")))) %>%
select(Gruppo, N, Media, Dev_Std, Minimo, Q1, Mediana, Q3, Massimo)

# Unione delle tabelle
stat_complete <- bind_rows(stat_globali, stat_cultivar)

# Visualizzazione tabella
knitr::kable(stat_complete, caption = "Statistiche descrittive del contenuto alcolico")

```

Table 1: Statistiche descrittive del contenuto alcolico

Gruppo	N	Media	Dev_Std	Minimo	Q1	Mediana	Q3	Massimo
Globale	178	13.00	0.81	11.03	12.36	13.05	13.68	14.83
Cultivar 1	59	13.74	0.46	12.85	13.40	13.75	14.10	14.83
Cultivar 2	71	12.28	0.54	11.03	11.91	12.29	12.52	13.86
Cultivar 3	48	13.15	0.53	12.20	12.80	13.16	13.50	14.34

Il contenuto alcolico presenta un range complessivo da 11.03% a 14.83% con media globale di 13%. Si osserva una netta differenziazione tra i tre cultivar: il Cultivar 1 mostra i valori medi più elevati, il Cultivar 3 presenta valori intermedi, mentre il Cultivar 2 registra i contenuti alcolici più bassi. Questa separazione è visivamente evidente nella Figura seguente.

```

ggplot(wine, aes(x = Alch)) +
  geom_density(aes(fill = Cult), alpha = 0.6) +
  geom_density(aes(linetype = "Popolazione Generale"), color = "black", size = 0.8) +
  scale_fill_manual(values = c("v1" = "#E69F00", "v2" = "#56B4E9", "v3" = "#009E73"),
                    labels = c("Cultivar 1", "Cultivar 2", "Cultivar 3"),
                    name = NULL) +
  scale_linetype_manual(values = c("Popolazione Generale" = "dashed"),
                       name = NULL) +
  labs(x = "Contenuto Alcolico (%)",
       y = "Densità") +
  theme_minimal() +
  theme(legend.position = "right",
        legend.text = element_text(size = 7),
        legend.key.size = unit(0.4, "cm"))

```




Figure 1: Distribuzione del contenuto alcolico per cultivar e popolazione generale

Le distribuzioni mostrano una chiara separazione tra i tre gruppi con limitata sovrapposizione, suggerendo che il tipo di cultivar rappresenta un fattore determinante per il contenuto alcolico. Questa evidente differenza giustifica il nostro approccio a due fasi: prima analizzeremo le relazioni chimiche senza considerare il cultivar (Fase 1), poi lo includeremo esplicitamente nei modelli per valutarne l'effetto (Fase 2).

3.2 BoxPlot

Per approfondire l'analisi delle distribuzioni, utilizziamo dei boxplot che consentono di visualizzare sinteticamente la posizione centrale, la dispersione e la presenza di eventuali valori anomali del contenuto alcolico. Il confronto tra la popolazione generale e i singoli cultivar evidenzia l'effetto della stratificazione sulla variabilità osservata.

```
# Boxplot popolazione generale
p1 <- ggplot(wine, aes(x = "", y = Alch)) +
  geom_boxplot(fill = "gray70", alpha = 0.7, outlier.colour = "red", outlier.shape = 16,
    outlier.size = 1.5) +
  labs(x = "Popolazione Generale", y = "Contenuto Alcolico (%)") +
  theme_minimal() +
  theme(axis.text.x = element_text(size = 9))

# Boxplot per cultivar
p2 <- ggplot(wine, aes(x = Cult, y = Alch, fill = Cult)) +
  geom_boxplot(alpha = 0.7, outlier.colour = "red", outlier.shape = 16, outlier.size = 1.5) +
  scale_fill_manual(values = c("v1" = "#E69F00", "v2" = "#56B4E9", "v3" = "#009E73")) +
  scale_x_discrete(labels = c("Cultivar 1", "Cultivar 2", "Cultivar 3")) +
  labs(x = "Cultivar", y = "Contenuto Alcolico (%)") +
  theme_minimal() +
  theme(legend.position = "none", axis.text.x = element_text(size = 8))

grid.arrange(p1, p2, ncol = 2, widths = c(1, 2))
```




Figure 2: Boxplot del contenuto alcolico: popolazione generale e per cultivar

Il confronto è illuminante: il boxplot della popolazione generale mostra una variabilità elevata (intervallo 11-15%) che riflette la sovrapposizione delle tre distribuzioni cultivar-specifiche. Quando stratifichiamo per cultivar (pannello destro), osserviamo mediane ben distinte con l'ordinamento già evidenziato (Cultivar 1 > Cultivar 3 > Cultivar 2) e intervalli interquartili notevolmente più ristretti. Questo conferma che il cultivar è un fattore determinante del contenuto alcolico e che ignorarlo nella modellazione comporterebbe una perdita significativa di potere esplicativo. Eventuali valori anomali (punti rossi) indicano osservazioni che si discostano significativamente dalla distribuzione del proprio gruppo.

3.3 Matrici Scatterplot

Le matrici di scatterplot permettono di esplorare simultaneamente le relazioni bivariate tra tutte le variabili chimiche del dataset. Questa visualizzazione completa consente di identificare pattern, correlazioni e potenziali problemi di multicollinearità che influenzeranno le analisi successive.

```
# Matrice di scatterplot completa
plot(wine_no_cult,
     pch = 20,
     cex = 0.3,
     col = rgb(0, 0, 0.8, 0.3))
```




Figure 3: Matrice di scatterplot dell'intera popolazione

La matrice completa rivela la **struttura di dipendenza** tra tutte le variabili chimiche. Osservando la

prima riga/colonna (Alch), emergono correlazioni moderate con Prln (prolina, $r=0.64$) e Clri (intensità del colore, $r=0.55$), che si confermano come i predittori candidati principali per il contenuto alcolico. Si evidenzia una **forte multicollinearità** in diversi cluster di variabili: i composti fenolici (Flvn-Ttlp $r=0.86$, Flvn-Oodw $r=0.79$) mostrano intercorrelazioni elevate, così come alcune misure chimiche secondarie. Questi pattern richiederanno particolare attenzione nella fase di modellazione per evitare problemi di instabilità. Gli scatterplot mostrano prevalentemente relazioni lineari, validando l'appropriatezza di approcci basati su modelli gaussiani.

3.4 Matrice di Correlazione

La matrice di correlazione quantifica l'intensità e la direzione delle relazioni lineari tra tutte le coppie di variabili chimiche, fornendo una sintesi numerica dei pattern osservati negli scatterplot.

3.4.1 Correlazioni - Intera Popolazione

Analizziamo la struttura di correlazione dell'intera popolazione, senza distinzione per cultivar, per identificare le variabili più associate al contenuto alcolico e individuare eventuali problemi di multicollinearità.

```
# Calcolo della matrice di correlazione
cor_matrix <- cor(wine_no_cult)

# Visualizzazione con corrplot
corrplot(cor_matrix,
  method = "color",
  type = "upper",
  order = "original",
  tl.col = "black",
  tl.cex = 0.7,
  tl.srt = 45,
  addCoef.col = "black",
  number.cex = 0.5,
  col = colorRampPalette(c("#6D9EC1", "white", "#E46726"))(200),
  mar = c(0, 0, 0, 0))
```




Figure 4: Matrice di correlazione - Intera popolazione

Le variabili più fortemente correlate con Alch sono Prln ($r=0.64$), Clri ($r=0.55$), Ttlp ($r=0.29$) e Mgns ($r=0.27$), confermando la prolina e l'intensità del colore come predittori candidati principali. Si osserva una **forte multicollinearità** tra Flvn-Ttlp ($r=0.86$) e Flvn-Oodw ($r=0.79$), suggerendo che questi composti fenolici condividono informazione ridondante. Le correlazioni negative sono generalmente deboli, con Aloa-Alch ($r=-0.31$) e Nnfp-Alch ($r=-0.16$) come più rilevanti. Questa struttura di dipendenza guiderà la selezione delle variabili nei modelli successivi.

3.4.2 Correlazioni per Cultivar - Confronto

Verifichiamo se le relazioni lineari tra variabili rimangono costanti attraverso i tre cultivar o se il tipo di coltivazione modifica la struttura di correlazione.

```
# Calcolo correlazioni con Alch per ciascun cultivar
wine_c1 <- wine %>% filter(Cult == "v1") %>% select(-Cult)
wine_c2 <- wine %>% filter(Cult == "v2") %>% select(-Cult)
wine_c3 <- wine %>% filter(Cult == "v3") %>% select(-Cult)

cor_alch_c1 <- cor(wine_c1)[, "Alch"]
cor_alch_c2 <- cor(wine_c2)[, "Alch"]
cor_alch_c3 <- cor(wine_c3)[, "Alch"]

# Creazione dataframe per visualizzazione
df_comp <- data.frame(
  Variabile = names(cor_alch_c1)[names(cor_alch_c1) != "Alch"],
  Cultivar_1 = cor_alch_c1[names(cor_alch_c1) != "Alch"],
  Cultivar_2 = cor_alch_c2[names(cor_alch_c2) != "Alch"],
  Cultivar_3 = cor_alch_c3[names(cor_alch_c3) != "Alch"]
)

# Reshape per ggplot
df_long <- df_comp %>%
  pivot_longer(cols = starts_with("Cultivar"),
    names_to = "Cultivar",
    values_to = "Correlazione") %>%
  mutate(Cultivar = gsub("Cultivar_", "Cultivar ", Cultivar))

# Grafico a punti
ggplot(df_long, aes(x = Variabile, y = Correlazione, color = Cultivar, shape = Cultivar)) +
  geom_point(size = 2.5, alpha = 0.8) +
  geom_hline(yintercept = 0, linetype = "dashed", color = "gray50") +
  scale_color_manual(values = c("Cultivar 1" = "#E69F00",
    "Cultivar 2" = "#56B4E9",
    "Cultivar 3" = "#009E73")) +
  scale_shape_manual(values = c("Cultivar 1" = 16, "Cultivar 2" = 17, "Cultivar 3" = 15)) +
  labs(x = "Variabile",
    y = "Correlazione con Alch",
    color = NULL,
    shape = NULL) +
  theme_minimal() +
  theme(axis.text.x = element_text(angle = 45, hjust = 1, size = 8),
    legend.position = "top")
```




Figure 5: Confronto correlazioni con Alch per cultivar

Il confronto rivela **eterogeneità marcata** nelle relazioni lineari tra cultivar. Poche variabili mostrano stabilità: **Ash** e **Hue** presentano correlazioni simili attraverso i tre gruppi (rispettivamente ~ 0.2 e ~ 0). Al contrario, si osservano **variazioni sostanziali** per **Prnt** (range -0.2 a $+0.3$), **Aloa** (-0.3 a $+0.2$), **Flvn**, **Ttlp** e **Prln**, dove Cultivar 2 mostra sistematicamente correlazioni prossime allo zero o negative, mentre Cultivar 1 (e in parte 3) presentano valori positivi moderati-forti. Questa eterogeneità indica che il cultivar modifica significativamente la struttura di dipendenza lineare, giustificando l'inclusione di termini di interazione o modelli cultivar-specifici nelle analisi predittive.

3.5 Heatmap delle Correlazioni

Le heatmap con clustering gerarchico offrono una rappresentazione complementare rispetto alla matrice di correlazione standard, raggruppando le variabili in base alla similarità dei loro profili di correlazione. Questo permette di identificare **cluster di variabili** chimicamente correlate e di comprendere la struttura latente del dataset.

In questa sezione presentiamo un'unica heatmap riferita all'**intera popolazione**, poiché il suo valore aggiunto rispetto alle analisi precedenti risiede specificamente nel **clustering gerarchico**, che riordina le variabili evidenziando raggruppamenti non immediatamente visibili nella matrice di correlazione standard. Il confronto delle correlazioni tra i singoli cultivar è stato già ampiamente trattato nella sezione precedente tramite il grafico a punti, che risulta più efficace per mettere in luce le differenze cultivar-specifiche senza ridondanza. Replicare la heatmap per ciascun cultivar non aggiungerebbe informazione sostanziale rispetto a quanto già emerso.

3.5.1 Heatmap - Intera Popolazione

Costruiamo quindi una heatmap della matrice di correlazione dell'intera popolazione, applicando il clustering gerarchico sia sulle righe che sulle colonne per evidenziare i raggruppamenti naturali tra le variabili chimiche.

```
# Matrice di correlazione (già calcolata in precedenza)
cor_pop <- cor(wine_no_cult)

# Heatmap con clustering gerarchico
pheatmap(cor_pop,
          display_numbers = TRUE,
```

```

number_format = "%.2f",
fontsize_number = 7,
fontsize = 9,
color = colorRampPalette(c("#6D9EC1", "white", "#E46726"))(100),
breaks = seq(-1, 1, length.out = 101),
clustering_method = "ward.D2",
clustering_distance_rows = as.dist(1 - abs(cor_pop)),
clustering_distance_cols = as.dist(1 - abs(cor_pop)),
border_color = "grey90",
main = ""

```




Figure 6: Heatmap con clustering gerarchico della matrice di correlazione - Intera popolazione

Il clustering gerarchico rivela una struttura a **blocchi** ben definita nella matrice di correlazione. Il dendrogramma separa le variabili in quattro raggruppamenti principali:

- Un primo cluster comprende i **composti fenolici** (Flvn, Ttlp, Oodw e Prnt), caratterizzato da forti correlazioni positive interne (in particolare Flvn-Ttlp $r=0.86$ e Flvn-Oodw $r=0.79$). Queste variabili condividono un profilo chimico legato ai processi di maturazione e alle proprietà antiossidanti del vino.
- Un secondo cluster raggruppa **Mlca, Hue e Nnfp**. Si tratta di variabili con profili di correlazione atipici rispetto ai cluster adiacenti: **Hue** presenta correlazioni positive con i fenolici ($r=0.54$ con Flvn) ma è più debolmente connessa al blocco Alch-Prln, mentre **Nnfp** (fenoli non-flavonoidi), pur appartenendo alla famiglia fenolica, si correla negativamente con i flavonoidi ($r=-0.54$), suggerendo un rapporto di

compensazione nella composizione fenolica. **Mlca** (acido malico) si associa negativamente sia a Hue ($r=-0.56$) sia ai fenolici, collocandosi in una posizione intermedia nel dendrogramma.

- Un terzo cluster raggruppa le variabili **Mgns**, **Clri**, **Alch** e **Prln**, legate alla struttura alcolica e cromatica del vino. All'interno di questo blocco, le correlazioni più forti con il contenuto alcolico sono quelle con **Prln** ($r=0.64$) e **Clri** ($r=0.55$), che si confermano come i predittori candidati principali. La prolina, un amminoacido la cui concentrazione aumenta con la maturazione dell'uva, è anche moderatamente correlata con l'intensità del colore ($r=0.32$) e il magnesio ($r=0.39$).
- Le variabili **Ash** e **Aloa** formano una coppia a sé stante, legata alla componente minerale del vino, con relazioni più deboli e indipendenti rispetto ai cluster principali.

Come già evidenziato dal confronto delle correlazioni per cultivar nella sezione precedente, questa struttura a blocchi rappresenta una sintesi della popolazione globale che maschera dinamiche cultivar-specifiche, rafforzando la necessità di considerare il cultivar come variabile esplicativa nei modelli successivi.

3.6 Sintesi dell'Analisi Esplorativa

L'analisi esplorativa ha permesso di delineare un quadro chiaro della struttura del dataset e delle relazioni tra le variabili chimiche. I risultati principali possono essere riassunti nei seguenti punti:

- **Variabile target (Alch):** il contenuto alcolico presenta una distribuzione compresa tra 11% e 15% circa, con una media globale intorno a 13%. La stratificazione per cultivar rivela tre distribuzioni ben separate (Cultivar 1 > Cultivar 3 > Cultivar 2), con intervalli interquartili nettamente più ristretti rispetto alla popolazione globale.
- **Predittori principali:** le variabili più fortemente correlate con il contenuto alcolico sono **Prln** ($r=0.64$) e **Clri** ($r=0.55$), seguite a distanza da **Ttlp** ($r=0.29$) e **Mgns** ($r=0.27$). Questi predittori candidati guideranno la costruzione dei modelli nelle sezioni successive.
- **Multicollinearità:** il dataset presenta cluster di variabili fortemente intercorrelate, in particolare i composti fenolici (**Flvn-Ttlp** $r=0.86$, **Flvn-Oodw** $r=0.79$). Questa ridondanza informativa dovrà essere tenuta in considerazione nella fase di modellazione per evitare problemi di instabilità nelle stime.
- **Eterogeneità tra cultivar:** il confronto delle correlazioni ha evidenziato che le relazioni lineari tra variabili chimiche variano significativamente tra i tre cultivar. Il Cultivar 2, in particolare, mostra correlazioni sistematicamente più deboli con il contenuto alcolico rispetto agli altri due gruppi. Questa eterogeneità giustifica l'approccio a due fasi adottato nell'analisi: nella **Fase 1** si studiano le relazioni chimiche pure sull'intera popolazione escludendo il cultivar, per cogliere la struttura di dipendenza intrinseca tra le sostanze; nella **Fase 2** si include il cultivar come variabile esplicativa, per valutare se e come il tipo di coltivazione modifichi tali relazioni e contribuisca alla previsione del contenuto alcolico.

Questi risultati forniscono le basi per le analisi successive: i modelli grafici indiretti (Capitolo 4) e diretti (Capitolo 5) permetteranno di distinguere le correlazioni marginali qui osservate dalle **dipendenze condizionali** e dalle **relazioni causali** tra le variabili, mentre la regressione lineare multipla (Capitolo 6) quantificherà formalmente il contributo di ciascun predittore.

4 Modelli Grafici Indiretti

4.1 Introduzione ai Modelli Grafici Gaussiani

I modelli grafici gaussiani (Gaussian Graphical Models, GGM) rappresentano uno strumento fondamentale per lo studio delle **dipendenze condizionali** tra variabili continue. A differenza delle correlazioni marginali analizzate nel capitolo precedente, che misurano l'associazione diretta tra coppie di variabili, i GGM permettono di identificare quali relazioni persistono **anche dopo aver controllato per l'effetto di tutte le altre variabili**.

Il principio chiave alla base dei GGM risiede nella **matrice di concentrazione** K , definita come l'inversa della matrice di covarianza:

$$K = \Sigma^{-1}$$

dove Σ è la matrice di covarianza del vettore aleatorio $X = (X_1, X_2, \dots, X_p)$. Sotto l'assunzione di normalità multivariata, gli elementi fuori diagonale della matrice di concentrazione hanno un'interpretazione diretta: l'elemento k_{ij} è proporzionale alla **correlazione parziale** tra X_i e X_j , condizionatamente a tutte le altre variabili. In particolare, la correlazione parziale tra X_i e X_j è data da:

$$\rho_{ij \cdot \text{rest}} = -\frac{k_{ij}}{\sqrt{k_{ii} \cdot k_{jj}}}$$

Questa proprietà porta alla regola fondamentale dei GGM: se $k_{ij} = 0$, allora X_i e X_j sono **condizionalmente indipendenti** dato il resto delle variabili. In termini grafici, ciò equivale all'**assenza di un arco** tra i nodi i e j nel grafo indiretto.

Il **grafo indiretto** (Undirected Graph, UG) risultante è quindi un grafo $G = (V, E)$ dove:

- $V = \{1, 2, \dots, p\}$ è l'insieme dei nodi, ciascuno corrispondente a una variabile
- $E \subseteq V \times V$ è l'insieme degli archi, dove $(i, j) \in E$ se e solo se $k_{ij} \neq 0$

Questo grafo codifica la **struttura di indipendenza condizionale** del vettore aleatorio: la presenza di un arco tra due nodi indica una dipendenza diretta che non è spiegabile attraverso le altre variabili del sistema. Un grafo con pochi archi (sparso) suggerisce che molte relazioni osservate nelle correlazioni marginali sono in realtà **spurie**, mediate da variabili intermedie.

Nel nostro contesto, i GGM ci permetteranno di rispondere a una domanda cruciale: quali variabili chimiche hanno una **relazione diretta** con il contenuto alcolico, e quali invece sono correlate ad esso solo indirettamente, attraverso la mediazione di altre sostanze?

4.2 Matrice di Concentrazione - Intera Popolazione

Come introdotto nella sezione precedente, la matrice di concentrazione $K = \Sigma^{-1}$ è lo strumento chiave per identificare le dipendenze condizionali tra le variabili. Calcoliamo innanzitutto la **matrice di covarianza campionaria** S e la sua inversa K per le 13 variabili chimiche del dataset (escludendo il cultivar).

```
# Matrice di covarianza campionaria
S <- cov(wine_no_cult)

# Matrice di concentrazione (inversa della covarianza)
K <- solve(S)

# Assegnazione dei nomi delle variabili
colnames(K) <- rownames(K) <- colnames(wine_no_cult)

# Visualizzazione della matrice di concentrazione
round(K, 3)
```

```
##      Alch  Mlca      Ash  Aloa  Mgns  Ttlp  Flvn  Nnfp  Prnt  Clri
## Alch  3.733 -0.491 -0.515  0.141  0.000 -0.194 -0.034  0.776  0.569 -0.609
## Mlca -0.491  1.327 -0.676 -0.029  0.002  0.033  0.297 -0.967 -0.230  0.130
## Ash -0.515 -0.676 29.037 -1.423 -0.127  0.097 -3.474 -16.360  2.960 -0.436
## Aloa  0.141 -0.029 -1.423  0.201  0.002  0.018  0.164 -0.011 -0.139 -0.010
## Mgns  0.000  0.002 -0.127  0.002  0.007 -0.011  0.025  0.257 -0.039  0.000
## Ttlp -0.194  0.033  0.097  0.018 -0.011 11.066 -4.973 -2.564 -0.767 -0.302
## Flvn -0.034  0.297 -3.474  0.164  0.025 -4.973  7.045  7.047 -2.001 -0.001
## Nnfp  0.776 -0.967 -16.360 -0.011  0.257 -2.564  7.047 115.981 -1.429 -0.297
## Prnt  0.569 -0.230  2.960 -0.139 -0.039 -0.767 -2.001 -1.429  6.031 -0.298
## Clri -0.609  0.130 -0.436 -0.010  0.000 -0.302 -0.001 -0.297 -0.298  0.563
## Hue -0.810  3.231 -0.036  0.080 -0.026  0.373 -3.091 -12.284  0.035  2.375
## Odw -0.600 -0.023 -0.661 -0.039  0.029 -1.550 -2.260  5.137 -0.644  0.859
## Prln -0.004  0.000 -0.007  0.001  0.000 -0.001 -0.001  0.002  0.000 -0.001
##      Hue  Odw  Prln
## Alch -0.810 -0.600 -0.004
## Mlca  3.231 -0.023  0.000
## Ash -0.036 -0.661 -0.007
## Aloa  0.080 -0.039  0.001
## Mgns -0.026  0.029  0.000
## Ttlp  0.373 -1.550 -0.001
## Flvn -3.091 -2.260 -0.001
## Nnfp -12.284  5.137  0.002
## Prnt  0.035 -0.644  0.000
## Clri  2.375  0.859 -0.001
## Hue 48.836 -0.532 -0.006
## Odw -0.532  7.510 -0.001
## Prln -0.006 -0.001  0.000
```

La matrice di concentrazione presenta valori di **ordini di grandezza molto diversi** sugli elementi diagonali (ad esempio, $k_{Prln,Prln}$ è molto piccolo rispetto a $k_{Ash,Ash}$), riflettendo le differenti scale di misura delle variabili chimiche. Questo rende difficile interpretare direttamente i valori fuori diagonale k_{ij} : un valore apparentemente piccolo potrebbe in realtà indicare una forte dipendenza condizionale se rapportato agli elementi diagonali corrispondenti. Per questa ragione, è necessario **standardizzare** la matrice di concentrazione, ottenendo le correlazioni parziali.

4.2.1 Correlazioni Parziali - Intera Popolazione

Le correlazioni parziali si ottengono dalla matrice di concentrazione mediante la formula di standardizzazione:

$$\rho_{ij\text{-rest}} = -\frac{k_{ij}}{\sqrt{k_{ii} \cdot k_{jj}}}$$

che produce valori nell'intervallo $[-1, 1]$, direttamente confrontabili tra tutte le coppie di variabili, indipendentemente dalla loro scala di misura. Un valore prossimo a zero indica **indipendenza condizionale** (assenza di relazione diretta), mentre valori elevati in valore assoluto indicano una **dipendenza condizionale forte**.

```
# Calcolo delle correlazioni parziali dalla matrice di concentrazione
# rho_ij = -K_ij / sqrt(K_ii * K_jj)
D <- diag(1 / sqrt(diag(K)))
P <- -D %*% K %*% D
diag(P) <- 1
colnames(P) <- rownames(P) <- colnames(wine_no_cult)

# Visualizzazione con corrplot
corrplot(P,
  method = "color",
  type = "upper",
  order = "original",
```

```

tl.col = "black",
tl.cex = 0.7,
tl.srt = 45,
addCoef.col = "black",
number.cex = 0.5,
col = colorRampPalette(c("#6D9EC1", "white", "#E46726"))(200),
mar = c(0, 0, 0, 0)

```




Figure 7: Matrice delle correlazioni parziali - Intera popolazione

Il confronto tra la matrice delle correlazioni parziali (qui sopra) e la matrice delle correlazioni marginali (sezione 3.4) è estremamente informativo: molte delle correlazioni marginali osservate nell'analisi esplorativa **scompaiono o si riducono drasticamente** una volta controllato l'effetto delle altre variabili. Questo indica che buona parte delle associazioni bivariate erano **spurie**, mediate da variabili intermedie.

Per il contenuto alcolico (**Alch**), le dipendenze condizionali più rilevanti sono:

- **Clri** ($\rho_{\text{parz}} = 0.42$): l'intensità del colore è la variabile con la **correlazione parziale più forte** con Alch, sebbene ridotta rispetto alla correlazione marginale ($r=0.55$). Questo indica che, pur perdendo parte dell'associazione per effetto di mediazione, Clri mantiene un **legame diretto** importante con il contenuto alcolico.
- **Prln** ($\rho_{\text{parz}} = 0.37$): la prolina mantiene la seconda correlazione parziale più elevata, confermando una **relazione diretta** con il contenuto alcolico anche dopo aver controllato per tutte le altre variabili chimiche. Questo legame riflette il ruolo della prolina come indicatore di maturazione dell'uva e del potenziale alcolico.
- **Mlca** ($\rho_{\text{parz}} = 0.22$): l'acido malico presenta un risultato interessante. La sua correlazione marginale con Alch era molto debole ($r=0.09$), mentre la correlazione parziale è **più che raddoppiata**. Questo rafforzamento indica un **effetto di soppressione**: l'influenza di altre variabili (in particolare quelle fenoliche e l'intensità del colore) mascherava parzialmente il legame positivo diretto tra acido malico e contenuto alcolico, che emerge più chiaramente solo dopo aver condizionato su tutte le altre variabili.
- **Aloa** ($\rho_{\text{parz}} = -0.16$): l'alcalinità delle ceneri mostra una correlazione parziale negativa, indicando una **dipendenza condizionale inversa** con il contenuto alcolico: a parità di tutte le altre variabili chimiche, valori più alti di alcalinità sono associati a un contenuto alcolico inferiore.

D'altra parte, variabili che nell'analisi esplorativa mostravano correlazioni marginali apprezzabili con Alch perdono gran parte della loro associazione una volta controllate le altre variabili:

- **Mgns** ($\rho_{\text{parz}} = 0$): il magnesio, che presentava una correlazione marginale di 0.27, mostra una correlazione parziale prossima allo zero, indicando **indipendenza condizionale** — il legame osservato era in realtà interamente mediato da altre variabili chimiche.
- **TtIp** ($\rho_{\text{parz}} = 0.03$): i fenoli totali (r marginale = 0.29) mostrano anch'essi una correlazione parziale quasi nulla, confermando che la loro associazione con il contenuto alcolico era **spuria**, mediata da variabili come i flavonoidi e la prolina.
- **Flvn** ($\rho_{\text{parz}} = 0.01$): analogamente, i flavonoidi perdono completamente la loro associazione con Alch nelle correlazioni parziali, nonostante una correlazione marginale moderata.

```
# Confronto correlazioni marginali vs parziali con Alch
vars <- colnames(wine_no_cult)[colnames(wine_no_cult) != "Alch"]
df_confronto <- data.frame(
  Variabile = vars,
  Marginale = cor_matrix["Alch", vars],
  Parziale = P["Alch", vars]
)

df_conf_long <- df_confronto %>%
  pivot_longer(cols = c(Marginale, Parziale),
    names_to = "Tipo",
    values_to = "Correlazione")

ggplot(df_conf_long, aes(x = Variabile, y = Correlazione, fill = Tipo)) +
  geom_bar(stat = "identity", position = "dodge", alpha = 0.8, width = 0.6) +
  geom_hline(yintercept = 0, linetype = "dashed", color = "gray50") +
  scale_fill_manual(values = c("Marginale" = "#E46726", "Parziale" = "#6D9EC1"),
    name = NULL) +
  labs(x = "Variabile", y = "Correlazione con Alch") +
  theme_minimal() +
  theme(axis.text.x = element_text(angle = 45, hjust = 1, size = 8),
    legend.position = "top")
```




Figure 8: Confronto tra correlazioni marginali e parziali con Alch

Il grafico di confronto evidenzia chiaramente il **fenomeno di riduzione** delle correlazioni passando dalle marginali alle parziali: la maggior parte delle variabili mostra correlazioni parziali significativamente minori (in valore assoluto) rispetto alle correlazioni marginali. Questo è coerente con la presenza di multicollinearità nel dataset, già identificata nella heatmap (sezione 3.5). Le variabili che mantengono una dipendenza condizionale apprezzabile con Alch sono candidate naturali per la costruzione del grafo indiretto e per l'inclusione nei modelli di regressione.

Osserviamo inoltre che all'interno del cluster fenolico, la forte multicollinearità interna (Flvn-Ttlp $r=0.86$) viene "decomposta" nelle correlazioni parziali: **Flvn** e **Ttlp** mostrano una correlazione parziale reciproca ancora elevata ($\rho_{\text{parz}} = 0.56$), confermando un legame diretto tra queste due variabili, ma il loro legame con Alch si riduce considerevolmente, suggerendo che l'informazione che portano sul contenuto alcolico è in gran parte indirettamente mediata.

4.3 Selezione del Modello - Intera Popolazione

La matrice delle correlazioni parziali calcolata nella sezione precedente rappresenta il modello **saturo**, in cui tutti i 78 archi possibili sono presenti. Tuttavia, molte correlazioni parziali sono prossime a zero, suggerendo che il grafo completo è sovrapparametrizzato. La **selezione del modello** ha l'obiettivo di identificare un grafo **parsimonioso** che mantenga solo gli archi corrispondenti a dipendenze condizionali statisticamente significative, rimuovendo quelli che non apportano informazione rilevante.

Per la selezione utilizziamo il pacchetto **gRim**, che implementa i **modelli grafici di concentrazione** (concentration graph models). L'approccio prevede:

1. La stima del **modello saturo** tramite la funzione `cmod()`, che assume distribuzione normale multivariata e parametrizza il modello attraverso la matrice di concentrazione
2. L'applicazione di una procedura di **selezione all'indietro** (backward stepwise) basata sul criterio **BIC** (Bayesian Information Criterion), che rimuove iterativamente gli archi il cui contributo non è giustificato dal guadagno in verosimiglianza, penalizzando la complessità del modello

Il criterio BIC è definito come:

$$BIC = -2 \cdot \ell(\hat{\theta}) + k \cdot \ln(n)$$

dove $\ell(\hat{\theta})$ è la log-verosimiglianza massimizzata, k è il numero di parametri e n è il numero di osservazioni. La penalizzazione $k \cdot \ln(n)$ rende il BIC più conservativo rispetto all'AIC, favorendo modelli più parsimoniosi.

```
# Modello saturo: tutti gli archi presenti
mod_saturo <- cmod(~.^., data = wine_no_cult)
```

```
# Informazioni sul modello saturo
cat("Numero di variabili:", length(mod_saturo$varNames), "\n")
```

```
## Numero di variabili: 13
```

```
cat("Numero di archi:", length(edgeList(mod_saturo$modelinfo$ug)), "\n")
```

```
## Numero di archi: 78
```

```
cat("Devianza:", round(mod_saturo$fitinfo$dev, 3), "\n")
```

```
## Devianza: 0
```

```
cat("Gradi di libertà:", mod_saturo$fitinfo$dimension["df"], "\n")
```

```
## Gradi di libertà: 0
```

Il modello saturo stima tutti i $\binom{13}{2} = 78$ parametri di dipendenza condizionale (più i 13 parametri diagonali). I risultati confermano le proprietà teoriche attese:

- **Devianza = 0:** la devianza misura la discrepanza tra la matrice di covarianza stimata dal modello e quella campionaria. Nel modello saturo, la matrice di covarianza stimata coincide *esattamente* con quella campionaria S , poiché nessun vincolo $k_{ij} = 0$ è imposto sulla matrice di concentrazione. Di conseguenza, la discrepanza è nulla.
- **Gradi di libertà = 0:** i gradi di libertà corrispondono al numero di vincoli imposti rispetto al modello saturo, ossia al numero di archi rimossi. Poiché nessun arco è stato eliminato, non vi sono vincoli e i g.d.l. sono zero.

Questo modello rappresenta il punto di partenza della procedura di selezione: ogni modello ridotto sarà valutato in termini di quanta devianza aggiunge (perdita di fit) rispetto a quanti parametri risparmia (guadagno in parsimonia). Applichiamo ora la selezione backward con criterio BIC:

```
# Selezione backward con criterio BIC
# Nota: l'output mostra "change.AIC" per convenzione interna di gRim,
# ma il criterio effettivo è il BIC grazie al parametro k = log(n)
mod_selezionato <- backward(mod_saturo, k = log(nrow(wine_no_cult)))
```

```
## change.AIC -5.1818 Edge deleted: Alch,Mgns
## change.AIC -5.1739 Edge deleted: Flvn,Alch
## change.AIC -5.1796 Edge deleted: Flvn,Clri
## change.AIC -5.1687 Edge deleted: Mgns,Clri
## change.AIC -5.1144 Edge deleted: Mlca,Mgns
## change.AIC -5.0101 Edge deleted: Aloa,Clri
## change.AIC -4.9110 Edge deleted: Ttlp,Mgns
## change.AIC -4.8520 Edge deleted: Nnfp,Clri
## change.AIC -5.0558 Edge deleted: Alch,Nnfp
## change.AIC -4.6096 Edge deleted: Aloa,Mgns
## change.AIC -5.0755 Edge deleted: Aloa,Nnfp
## change.AIC -4.4066 Edge deleted: Ttlp,Nnfp
## change.AIC -4.3701 Edge deleted: Hue,Mgns
## change.AIC -4.0658 Edge deleted: Mlca,Nnfp
## change.AIC -3.8387 Edge deleted: Flvn,Mgns
## change.AIC -2.6799 Edge deleted: Mlca,Flvn
## change.AIC -4.2423 Edge deleted: Mlca,Aloa
## change.AIC -4.6866 Edge deleted: Mlca,Prnt
## change.AIC -4.8547 Edge deleted: Oodw,Mlca
## change.AIC -2.7567 Edge deleted: Prln,Mlca
## change.AIC -1.8520 Edge deleted: Hue,Nnfp
## change.AIC -1.1701 Edge deleted: Aloa,Flvn
## change.AIC -4.9462 Edge deleted: Oodw,Aloa
## change.AIC -3.8873 Edge deleted: Prnt,Aloa
## change.AIC -2.2880 Edge deleted: Hue,Aloa
## change.AIC -2.0851 Edge deleted: Alch,Prnt
## change.AIC -2.9972 Edge deleted: Oodw,Alch
## change.AIC -2.3813 Edge deleted: Prnt,Clri
## change.AIC -3.3500 Edge deleted: Prnt,Hue
## change.AIC -2.1642 Edge deleted: Ttlp,Prnt
## change.AIC -2.0148 Edge deleted: Alch,Aloa
## change.AIC -0.6874 Edge deleted: Clri,Mlca
## change.AIC -3.6232 Edge deleted: Alch,Mlca
## change.AIC -5.1481 Edge deleted: Ash,Alch
## change.AIC -5.1200 Edge deleted: Hue,Alch
## change.AIC -3.8137 Edge deleted: Ttlp,Alch
## change.AIC -1.2928 Edge deleted: Ash,Clri
## change.AIC -0.9227 Edge deleted: Ttlp,Mlca
## change.AIC -1.2402 Edge deleted: Ash,Mlca
## change.AIC -2.1226 Edge deleted: Ash,Hue
```

```
## change.AIC -0.1929 Edge deleted: Prnt,Mgns
## change.AIC -5.1797 Edge deleted: Prnt,Oodw
## change.AIC -5.1740 Edge deleted: Nnfp,Prnt
## change.AIC -5.0279 Edge deleted: Prln,Prnt
## change.AIC -3.8301 Edge deleted: Ash,Prnt
```

L'output della procedura backward mostra, per ogni iterazione, l'arco eliminato e la variazione del criterio informativo (etichettata `change.AIC` per convenzione interna del pacchetto, ma corrispondente al **BIC** grazie al parametro $k = \log(n)$). Tutti i 45 valori di variazione sono **negativi**, confermando che ogni singola rimozione ha migliorato il BIC. La procedura si arresta automaticamente quando nessuna ulteriore eliminazione produrrebbe un miglioramento.

Analizzando l'ordine di eliminazione, osserviamo che:

- I **primi archi rimossi** presentano le variazioni BIC più marcate (intorno a -5.18), indicando dipendenze condizionali estremamente deboli. Tra questi figurano archi come Alch-Mgns, Flvn-Alch e Flvn-Clri, coerentemente con le correlazioni parziali prossime allo zero osservate nella sezione precedente.
- Gli **ultimi archi rimossi** mostrano variazioni BIC più contenute (intorno a -0.19 per Prnt-Mgns), segnalando dipendenze condizionali al limite della significatività. Questo è un segnale che la procedura si è avvicinata alla soglia oltre la quale la rimozione non sarebbe più vantaggiosa.
- Le variabili **Mlca** e **Aloa** perdono la maggior parte delle loro connessioni (Mlca-Mgns, Mlca-Aloa, Mlca-Prnt, Mlca-Flvn, ecc.), confermandone la relativa indipendenza dalla struttura chimica principale del dataset.

Esaminiamo ora gli archi mantenuti nel modello selezionato:

```
# Estrazione del grafo indiretto dal modello selezionato
ug_sel <- mod_selezionato$modelinfo$ug
archi_sel <- edgeList(ug_sel)
n_archi_sel <- length(archi_sel)

cat("Numero di archi nel modello selezionato:", n_archi_sel, "\n")
```

```
## Numero di archi nel modello selezionato: 33
```

```
cat("Numero di archi nel modello saturo: 78\n")
```

```
## Numero di archi nel modello saturo: 78
```

```
cat("Archi rimossi:", 78 - n_archi_sel, "\n")
```

```
## Archi rimossi: 45
```

Il modello selezionato mantiene **33 archi** su 78 possibili, con una riduzione del **58%** dei parametri. La procedura backward ha rimosso 45 archi corrispondenti a dipendenze condizionali non giustificate dal BIC. Questo risultato è coerente con la matrice delle correlazioni parziali analizzata nella sezione precedente, dove molte coppie di variabili mostravano valori prossimi allo zero.

Per quanto riguarda la variabile target **Alch**, il modello selezionato mantiene solo **2 archi diretti**: Alch-Clri e Alch-Prln, confermando che intensità del colore e prolina sono le uniche variabili chimiche con una **dipendenza condizionale diretta** con il contenuto alcolico. Tutti gli altri legami osservati nelle correlazioni marginali (Mgns, Ttlp, Flvn, ecc.) risultano **mediati** da variabili intermedie e vengono correttamente eliminati dal modello.

La struttura complessiva del grafo evidenzia anche cluster di variabili densamente connesse (ad esempio il blocco Ash-Flvn-Nnfp-Oodw-Prln-Ttlp) e variabili più periferiche con poche connessioni (come Mlca, connessa

solo a Hue).

Per valutare formalmente la bontà del modello selezionato, eseguiamo un **test del rapporto di verosimiglianza** (Likelihood Ratio Test, LRT) confrontandolo con il modello saturo. Sotto H_0 (il modello ridotto è adeguato), la statistica test $\Delta D = D_{\text{ridotto}} - D_{\text{saturo}}$ segue approssimativamente una distribuzione χ^2 con gradi di libertà pari al numero di archi rimossi:

```
# Test del rapporto di verosimiglianza: modello selezionato vs saturo
# Estrazione devianza e gradi di libertà
dev_sel <- mod_selezionato$fitinfo$dev
dev_sat <- mod_saturo$fitinfo$dev
df_sel <- mod_selezionato$fitinfo$dimension["df"]
df_sat <- mod_saturo$fitinfo$dimension["df"]

# Statistica test e p-value
delta_dev <- dev_sel - dev_sat
delta_df <- df_sel - df_sat
p_value <- 1 - pchisq(delta_dev, df = delta_df)

cat("Devianza modello selezionato:", round(dev_sel, 3), "\n")
```

```
## Devianza modello selezionato: 69.435
```

```
cat("Devianza modello saturo:", round(dev_sat, 3), "\n")
```

```
## Devianza modello saturo: 0
```

```
cat("Delta devianza:", round(delta_dev, 3), "\n")
```

```
## Delta devianza: 69.435
```

```
cat("Gradi di libertà:", delta_df, "\n")
```

```
## Gradi di libertà: 45
```

```
cat("P-value:", round(p_value, 4), "\n")
```

```
## P-value: 0.0112
```

Il test di devianza verifica l'ipotesi nulla H_0 : "il modello ridotto è adeguato" contro H_1 : "il modello saturo è necessario". Il p-value ottenuto è inferiore a 0.05, indicando che il test del rapporto di verosimiglianza **rigetta** H_0 : dal punto di vista del puro adattamento ai dati, la rimozione di 45 archi comporta una perdita di fit statisticamente significativa.

Tuttavia, questo risultato **non invalida** la selezione operata dal BIC. I due criteri rispondono a domande diverse: il LRT misura esclusivamente la bontà di adattamento, mentre il BIC bilancia il fit con la **parsimonia** del modello, penalizzando la complessità con un termine $k \cdot \ln(n)$ più severo. È un fenomeno atteso che il LRT e il BIC possano non concordare, soprattutto quando il numero di parametri rimossi è elevato: il BIC accetta una lieve perdita di adattamento se il guadagno in semplicità è sostanziale. Nel nostro caso, il modello BIC-selezionato riduce il numero di archi da 78 a 33 (una riduzione del 58%), ottenendo un grafo **interpretabile** che mantiene solo le dipendenze condizionali più rilevanti. Questa scelta è appropriata ai fini della nostra analisi, il cui obiettivo primario è identificare la struttura di dipendenza essenziale piuttosto che massimizzare il fit.

4.4 Grafo Indiretto - Interà Popolazione

Il modello selezionato nella sezione precedente definisce un **grafo indiretto** (Undirected Graph, UG) in cui ogni arco rappresenta una dipendenza condizionale statisticamente rilevante tra due variabili. Visualizziamo questo grafo per ottenere una rappresentazione intuitiva della struttura di dipendenza tra le 13 variabili chimiche.

```
# Estrazione del grafo dal modello selezionato
ug_plot <- mod_selezionato$modelinfo$ug

# Calcolo del grado di ciascun nodo per dimensionamento
gradi <- igraph::degree(ug_plot)

# Identificazione dei vicini di Alch per la colorazione
vicini_alch <- names(neighbors(ug_plot, "Alch"))

# Colorazione dei nodi
colori_nodi <- ifelse(V(ug_plot)$name == "Alch", "#E46726",
                     ifelse(V(ug_plot)$name %in% vicini_alch, "#FFD700", "#6D9EC1"))

# Layout Kamada-Kawai per disposizione compatta e leggibile
set.seed(42)
layout_kk <- layout_with_kk(ug_plot)

# Margini ridotti per massimizzare lo spazio del grafo
par(mar = c(1, 1, 0.5, 1))

# Plot del grafo
plot(ug_plot,
     layout = layout_kk,
     vertex.size = 7 + gradi * 1.5,
     vertex.color = colori_nodi,
     vertex.frame.color = "gray30",
     vertex.label.cex = 0.7,
     vertex.label.color = "black",
     vertex.label.font = 2,
     edge.color = "gray50",
     edge.width = 1.3,
     main = "")

# Legenda
legend("bottomleft",
      legend = c("Alch (target)", "Vicini diretti di Alch", "Altre variabili"),
      fill = c("#E46726", "#FFD700", "#6D9EC1"),
      cex = 0.6,
      bty = "n")
```




Figure 9: Grafo indiretto (UG) del modello selezionato - Intera popolazione

Il grafo indiretto rivela una struttura di dipendenza ricca e informativa. Analizziamone i principali aspetti.

Posizione della variabile target. Il contenuto alcolico (**Alch**) è connesso a sole 2 variabili: **Clri** (intensità del colore) e **Prln** (prolina). Questo significa che, condizionatamente a tutte le altre variabili chimiche, Alch è **indipendente** dalle restanti 10 variabili. In termini probabilistici, conoscere i valori di Clri e Prln rende le altre 10 variabili irrilevanti per predire il contenuto alcolico. Questo risultato ha una chiara implicazione per la modellazione predittiva: un modello di regressione per Alch dovrebbe includere almeno Clri e Prln come predittori.

Hub centrali. Il grafo presenta nodi ad alta connettività che fungono da **hub** nella struttura di dipendenza:

```
# Tabella dei gradi dei nodi (ordinata per grado decrescente)
df_gradi <- data.frame(
  Variabile = names(sort(gradi, decreasing = TRUE)),
  Grado = as.integer(sort(gradi, decreasing = TRUE))
)
knitr::kable(df_gradi, caption = "Grado di connettività dei nodi nel grafo selezionato")
```

Table 2: Grado di connettività dei nodi nel grafo selezionato

Variabile	Grado
Prln	10
Oodw	8
Ash	7
Flvn	7
Ttlp	7
Hue	6
Nnfp	5
Clri	5
Mgns	4
Aloa	3
Alch	2
Prnt	1
Mlca	1

La variabile con il grado più elevato è **Prln** (prolina), che si conferma come un **hub centrale** nella rete di dipendenze chimiche, connessa a un gran numero di variabili. Questo ruolo di hub è coerente con il fatto che la prolina è un amminoacido la cui concentrazione è influenzata da molteplici processi biochimici durante la maturazione dell'uva. Seguono **Oodw** (rapporto di assorbanza), **Ash** (ceneri) e **Ttlp/Flvn** (composti fenolici), che formano il nucleo più densamente connesso del grafo.

Al contrario, **Alch** (grado 2), **Mlca** (grado 1) e **Prnt** (grado 1) sono variabili **periferiche**: Mlca è connessa unicamente a Hue, e Prnt solo a Flvn. Questa perifericità indica che queste variabili hanno poche dipendenze condizionali dirette con il resto del sistema chimico, e la loro informazione è in gran parte assorbita indirettamente dalle variabili più centrali.

Cluster di variabili. Il grafo evidenzia due raggruppamenti principali:

- Un **cluster denso centrale** formato da Ash, Flvn, Nnfp, Oodw, Prln, Ttlp, Mgns e Hue, che rappresenta il nucleo delle relazioni chimiche fondamentali. All'interno di questo cluster, le variabili sono fortemente interconnesse, riflettendo la dipendenza condizionale reciproca tra composti fenolici, minerali e indicatori di assorbanza.
- Una **periferia** composta da Alch (connessa solo a Clri e Prln), Mlca (connessa solo a Hue) e Prnt (connessa solo a Flvn), che rappresentano variabili con poche dipendenze dirette.

Ruolo di mediazione. La struttura del grafo suggerisce che **Prln** e **Clri** agiscono come **mediatori** tra il contenuto alcolico e il resto del sistema chimico. Ad esempio, la correlazione marginale tra Alch e Mgns ($r=0.27$) non corrisponde a un arco nel grafo: l'associazione osservata è interamente mediata da Prln, che è connessa sia a Mgns che ad Alch. Analogamente, il legame marginale tra Alch e Ttlp ($r=0.29$) transita attraverso Prln e il cluster fenolico.

4.5 Grafo Indiretto - Con Cultivar

Includiamo ora la variabile **Cult** per valutare come il tipo di coltivazione modifichi la rete di dipendenze condizionali. Per compatibilità con i modelli grafici gaussiani, convertiamo Cult in **due variabili dummy**: Cult_v2 e Cult_v3 (con v1 come livello di riferimento). Il modello saturo con 15 variabili ha $\binom{15}{2} = 105$ archi.

```
# Creazione di variabili dummy per Cult
wine_dummy <- wine %>%
  mutate(Cult_v2 = as.numeric(Cult == "v2"),
         Cult_v3 = as.numeric(Cult == "v3")) %>%
  select(-Cult)

# Modello saturo e selezione backward con BIC
mod_saturo_cult <- cmod(~.^., data = wine_dummy)
mod_sel_cult <- backward(mod_saturo_cult, k = log(nrow(wine_dummy)))
```

```
cat("Modello saturo: 105 archi possibili\n")
```

```
## Modello saturo: 105 archi possibili
```

```
cat("Modello selezionato:", length(edgeList(mod_sel_cult$modelinfo$ug)), "archi\n")
```

```
## Modello selezionato: 60 archi
```

```
cat("Archi rimossi:", 105 - length(edgeList(mod_sel_cult$modelinfo$ug)), "\n")
```

```
## Archi rimossi: 45
```

La selezione BIC mantiene un sottoinsieme parsimonioso di archi. Analizziamo quali variabili sono connesse alle dummy cultivar e ad Alch:

```
ug_sel_cult <- mod_sel_cult$modelinfo$ug
archi_sel_cult <- edgeList(ug_sel_cult)
```

Archi con le dummy cultivar

```
archi_cult_v2 <- archi_sel_cult[sapply(archi_sel_cult, function(x) "Cult_v2" %in% x)]
archi_cult_v3 <- archi_sel_cult[sapply(archi_sel_cult, function(x) "Cult_v3" %in% x)]
```

```
cat("Archi Cult_v2 (", length(archi_cult_v2), "):",
    if(length(archi_cult_v2) > 0) {
      archi_str <- sapply(archi_cult_v2, function(x) paste(x, collapse = "-"))
      paste(strwrap(paste(archi_str, collapse = ", "), width = 80), collapse = "\n ")
    } else "Nessuno", "\n\n")
```

```
## Archi Cult_v2 ( 13 ): Aloa-Cult_v2, Ttlp-Cult_v2, Flvn-Cult_v2, Nnfp-Cult_v2, Clri-Cult_v2,
## Cult_v2-Cult_v3, Cult_v2-Mgns, Cult_v2-Oodw, Cult_v2-Prnt, Cult_v2-Ash,
## Cult_v2-Prln, Cult_v2-Mlca, Cult_v2-Alch
```

```
cat("Archi Cult_v3 (", length(archi_cult_v3), "):",
    if(length(archi_cult_v3) > 0) {
      archi_str <- sapply(archi_cult_v3, function(x) paste(x, collapse = "-"))
      paste(strwrap(paste(archi_str, collapse = ", "), width = 80), collapse = "\n ")
    } else "Nessuno", "\n\n")
```

```
## Archi Cult_v3 ( 12 ): Aloa-Cult_v3, Ttlp-Cult_v3, Flvn-Cult_v3, Nnfp-Cult_v3, Clri-Cult_v3,
## Cult_v2-Cult_v3, Cult_v3-Mgns, Cult_v3-Oodw, Cult_v3-Prln, Cult_v3-Mlca,
## Cult_v3-Hue, Cult_v3-Alch
```

Archi con Alch

```
archi_alch_cult <- archi_sel_cult[sapply(archi_sel_cult, function(x) "Alch" %in% x)]
cat("Archi Alch (", length(archi_alch_cult), "):",
    paste(sapply(archi_alch_cult, function(x) paste(x, collapse = "-")), collapse = ", "), "\n")
```

```
## Archi Alch ( 3 ): Clri-Alch, Cult_v2-Alch, Cult_v3-Alch
```

Estrazione del grafo

```
ug_plot_cult <- mod_sel_cult$modelinfo$ug
```

Calcolo del grado di ciascun nodo

```
gradi_cult <- igraph::degree(ug_plot_cult)
```

Identificazione dei vicini di Alch e delle variabili dummy cultivar

```
vicini_alch_cult <- names(neighbors(ug_plot_cult, "Alch"))
vicini_cult_v2 <- if("Cult_v2" %in% V(ug_plot_cult)$name) {
  names(neighbors(ug_plot_cult, "Cult_v2"))
} else { character(0) }
vicini_cult_v3 <- if("Cult_v3" %in% V(ug_plot_cult)$name) {
  names(neighbors(ug_plot_cult, "Cult_v3"))
} else { character(0) }
vicini_cult <- unique(c(vicini_cult_v2, vicini_cult_v3))
```

Colorazione dei nodi

```
colori_nodi_cult <- ifelse(V(ug_plot_cult)$name == "Alch", "#E46726",
  ifelse(V(ug_plot_cult)$name %in% c("Cult_v2", "Cult_v3"), "#9370DB",
  ifelse(V(ug_plot_cult)$name %in% vicini_alch_cult, "#FFD700",
```

```

        ifelse(V(ug_plot_cult)$name %in% vicini_cult, "#98FB98", "#6D9EC1"))))

# Layout Kamada-Kawai
set.seed(123)
layout_kk_cult <- layout_with_kk(ug_plot_cult)

# Aggiustamento manuale: sposta Alch più in basso per distanziare i suoi archi
idx_alch <- which(V(ug_plot_cult)$name == "Alch")
layout_kk_cult[idx_alch, 2] <- layout_kk_cult[idx_alch, 2] - 1.8

# Margini ridotti
par(mar = c(1, 1, 0.5, 1))

# Plot del grafo
plot(ug_plot_cult,
     layout = layout_kk_cult,
     vertex.size = 7 + gradi_cult * 1.5,
     vertex.color = colori_nodi_cult,
     vertex.frame.color = "gray30",
     vertex.label.cex = 0.7,
     vertex.label.color = "black",
     vertex.label.font = 2,
     edge.color = "gray50",
     edge.width = 1.3,
     main = "")

# Legenda
legend("bottomleft",
      legend = c("Alch (target)", "Cult_v2/v3 (cultivar)",
                 "Vicini di Alch", "Vicini di Cultivar", "Altre variabili"),
      fill = c("#E46726", "#9370DB", "#FFD700", "#98FB98", "#6D9EC1"),
      cex = 0.6,
      bty = "n")

```




Figure 10: Grafo indiretto (UG) con cultivar - Modello selezionato con BIC

Il grafo mostra come le dummy cultivar si integrino nella rete di dipendenze. Un confronto quantitativo con

il modello senza cultivar rivela quali archi sono modificati dall'inclusione del tipo di coltivazione:

```
archi_no_cult <- edgeList(ug_sel)
archi_si_cult <- edgeList(ug_sel_cult)
archi_si_cult_no_cult <- archi_si_cult[!sapply(archi_si_cult,
      function(x) any(c("Cult_v2", "Cult_v3") %in% x))]

archi_to_string <- function(archi_list) {
  sapply(archi_list, function(x) paste(sort(x), collapse = "-"))
}

set_no_cult <- archi_to_string(archi_no_cult)
set_si_cult <- archi_to_string(archi_si_cult_no_cult)

cat("Archi comuni:", length(intersect(set_no_cult, set_si_cult)), "\n")
```

```
## Archi comuni: 19
```

```
cat("Solo SENZA cultivar:", length(setdiff(set_no_cult, set_si_cult)), "\n")
```

```
## Solo SENZA cultivar: 14
```

```
cat("Solo CON cultivar:", length(setdiff(set_si_cult, set_no_cult)), "\n")
```

```
## Solo CON cultivar: 17
```

La connettività dei nodi confrontata tra i due modelli evidenzia come il cultivar redistribuisca le dipendenze:

```
# Tabella dei gradi (ordinata)
df_gradi_cult <- data.frame(
  Variabile = names(sort(gradi_cult, decreasing = TRUE)),
  Grado = as.integer(sort(gradi_cult, decreasing = TRUE))
)

# Calcolo della variazione di grado rispetto al modello senza cultivar
# (per le variabili chimiche, escludendo Cult_v2 e Cult_v3 che non erano presenti)
df_gradi_cult$Grado_NoCult <- NA
for(i in seq_len(nrow(df_gradi_cult))) {
  var <- df_gradi_cult$Variabile[i]
  if(!var %in% c("Cult_v2", "Cult_v3") && var %in% names(gradi)) {
    df_gradi_cult$Grado_NoCult[i] <- gradi[var]
  }
}
df_gradi_cult$Delta <- df_gradi_cult$Grado - df_gradi_cult$Grado_NoCult

knitr::kable(df_gradi_cult, caption = "Grado di connettività nel modello con cultivar")
```

Table 3: Grado di connettività nel modello con cultivar

Variabile	Grado	Grado_NoCult	Delta
Clri	13	5	8
Cult_v2	13	NA	NA
Cult_v3	12	NA	NA
Aloa	10	3	7
Nnfp	10	5	5

Variabile	Grado	Grado_NoCult	Delta
Flvn	9	7	2
Mgns	9	4	5
Ttlp	7	7	0
Prnt	7	1	6
Oodw	6	8	-2
Ash	6	7	-1
Prln	6	10	-4
Mlca	5	1	4
Hue	4	6	-2
Alch	3	2	1

La colonna **Delta** mostra come cambia la connettività delle variabili chimiche con l'inclusione del cultivar. Le dummy Cult_v2 e Cult_v3 con grado elevato indicano che il cultivar introduce nuova informazione strutturale; un grado basso suggerisce invece che le differenze sono in gran parte mediate dalle variabili chimiche.

In sintesi, l'inclusione del cultivar modifica profondamente la struttura del grafo: alcune relazioni del modello senza cultivar erano spurie e mediate dal tipo di coltivazione. **Crucialmente, il modello selezionato include archi diretti Cult_v2-Alch e Cult_v3-Alch**, indicando che il tipo di coltivazione ha un effetto diretto sul contenuto alcolico indipendentemente dalle altre variabili chimiche. Oltre a Clri e Prln (già presenti nel modello senza cultivar), anche le cultivar v2 e v3 sono quindi predittori diretti di Alch, un risultato rilevante per il modello di regressione lineare (Capitolo 6).

4.6 Sintesi dei Modelli Grafici Indiretti

L'analisi dei modelli grafici indiretti ha rivelato la struttura di dipendenze condizionali tra le variabili chimiche del vino, sia nell'intera popolazione che includendo il tipo di cultivar.

Modello senza cultivar (sezione 4.4). Il grafo selezionato con BIC mantiene 33 archi su 78 possibili, con una riduzione del 58% dei parametri. La variabile target **Alch** è connessa unicamente a **Clri** e **Prln**, indicando che, condizionatamente a tutte le altre variabili, solo queste due sono direttamente rilevanti per il contenuto alcolico. Il grafo presenta un cluster denso centrale composto da variabili fenoliche e minerali (Ash, Flvn, Oodw, Ttlp, Mgns), mentre Alch, Mlca e Prnt occupano posizioni periferiche. **Prln** emerge come hub centrale, confermando il suo ruolo di mediatore tra Alch e il resto del sistema chimico.

Modello con cultivar (sezione 4.5). L'inclusione delle variabili dummy **Cult_v2** e **Cult_v3** modifica sostanzialmente la rete di dipendenze. Il modello selezionato include connessioni dirette **Cult_v2-Alch** e **Cult_v3-Alch**, indicando che il tipo di coltivazione ha un **effetto diretto** sul contenuto alcolico, indipendente dalle altre variabili chimiche. Alch è quindi connessa a **3 variabili**: Clri, Cult_v2 e Cult_v3. Significativamente, la connessione Alch-Prln presente nel modello senza cultivar scompare, suggerendo che l'associazione tra prolina e contenuto alcolico era in parte mediata dal tipo di coltivazione.

Implicazioni principali:

1. Alcune relazioni del modello senza cultivar erano spurie, dovute al confondimento con il tipo di coltivazione.
2. Le cultivar introducono nuova informazione strutturale: hanno un effetto autonomo sulla composizione del vino.
3. Per la regressione lineare (Capitolo 6), il cultivar dovrebbe essere incluso come predittore diretto di Alch insieme a Clri e Prln.
4. I modelli indiretti identificano dipendenze condizionali ma non orientano gli archi. Nel Capitolo 5 esploreremo i grafi aciclici diretti (DAG) per identificare relazioni causali.

5 Modelli Grafici Diretti (DAG)

Nel Capitolo 4 abbiamo utilizzato grafi indiretti (UG) per identificare le **dipendenze condizionali** tra le variabili chimiche del vino. I grafi indiretti, tuttavia, non forniscono informazioni sulla **direzione** delle relazioni: un arco tra due variabili indica una dipendenza, ma non specifica quale variabile influenza l'altra.

In questo capitolo utilizziamo i **grafi aciclici diretti** (Directed Acyclic Graphs, DAG) per orientare gli archi e identificare **relazioni causali** tra le variabili. I DAG permettono di rappresentare una struttura di dipendenza più ricca, in cui ogni arco orientato $X \rightarrow Y$ suggerisce che X ha un'influenza diretta su Y , condizionatamente alle altre variabili del grafo. La proprietà di aciclicità garantisce l'assenza di loop causali, rendendo il modello interpretabile in termini di relazioni gerarchiche.

La strategia di analisi rispecchia quella del capitolo precedente:

1. **DAG per l'intera popolazione** (senza cultivar): esploriamo prima un DAG libero, poi un DAG vincolato con **Alch come variabile target** (sink), per identificare i predittori diretti del contenuto alcolico.
2. **DAG con cultivar**: includiamo le variabili dummy Cult_v2 e Cult_v3 e valutiamo come il tipo di coltivazione modifichi la struttura causale. Analizziamo un DAG libero e poi un DAG con **Cult come variabile esogena** (source) e **Alch come target** (sink).

I DAG vengono stimati mediante **modelli di regressione gaussiana** per grafi diretti, utilizzando criteri di informazione (AIC o BIC) per la selezione del modello. A differenza dei grafi indiretti, i DAG richiedono l'orientamento degli archi, che può essere guidato da conoscenze a priori (variabili esogene/endogene) o da procedure di ricerca automatica.

5.1 DAG - Intera Popolazione

5.1.1 DAG Libero

Costruiamo un DAG senza vincoli di orientamento utilizzando una **procedura di selezione stepwise** guidata dal criterio BIC. Partiamo dal modello vuoto (nessun arco) e aggiungiamo iterativamente archi orientati che migliorano significativamente il fit del modello.

```
# Apprendimento di struttura DAG da dati continui usando algoritmo Hill-Climbing
# con score BIC (Bayesian Information Criterion)
dag_libero <- hc(wine_no_cult, score = "bic-g")

# Numero di archi selezionati
n_archi_dag <- narcs(dag_libero)
cat("Numero di archi nel DAG libero:", n_archi_dag, "\n")
```

```
## Numero di archi nel DAG libero: 24
```

```
# Conversione in oggetto igraph per la visualizzazione
dag_igraph <- as.igraph(dag_libero)
```

Il DAG libero selezionato contiene un sottoinsieme di archi orientati che rappresentano dipendenze causali dirette. Visualizziamo il grafo:

```
# Identificazione dei genitori (cause dirette) e figli (effetti diretti) di Alch
genitori_alch <- parents(dag_libero, "Alch")
figli_alch <- children(dag_libero, "Alch")

# Colorazione dei nodi
colori_nodi_dag <- ifelse(V(dag_igraph)$name == "Alch", "#E46726",
  ifelse(V(dag_igraph)$name %in% genitori_alch, "#FFD700",
    ifelse(V(dag_igraph)$name %in% figli_alch, "#90EE90", "#6D9EC1")))
```

```

# Layout gerarchico (sugiyama layout per DAG)
set.seed(456)
layout_dag <- layout_with_sugiyama(dag_igraph)$layout

# Margini ridotti
par(mar = c(1, 1, 0.5, 1))

# Plot del DAG
plot(dag_igraph,
     layout = layout_dag,
     vertex.size = 8,
     vertex.color = colori_nodi_dag,
     vertex.frame.color = "gray30",
     vertex.label.cex = 0.7,
     vertex.label.color = "black",
     vertex.label.font = 2,
     edge.color = "gray50",
     edge.width = 1.5,
     edge.arrow.size = 0.5,
     edge.curved = 0.1,
     main = "")

# Legenda
legend("bottomleft",
     legend = c("Alch (target)", "Genitori di Alch", "Figli di Alch", "Altre variabili"),
     fill = c("#E46726", "#FFD700", "#90EE90", "#6D9EC1"),
     cex = 0.6,
     bty = "n")

```




Figure 11: DAG libero - Interza popolazione

Il DAG libero rivela la struttura di dipendenza causale tra le variabili. Analizziamo i genitori e i figli di Alch:

```
cat("Genitori di Alch (predittori diretti):",  
    if(length(genitori_alch) > 0) paste(genitori_alch, collapse = ", ") else "Nessuno", "\n")
```

```
## Genitori di Alch (predittori diretti): Nessuno
```

```
cat("Figli di Alch (variabili causate da Alch):",  
    if(length(figli_alch) > 0) paste(figli_alch, collapse = ", ") else "Nessuno", "\n")
```

```
## Figli di Alch (variabili causate da Alch): Clri, Hue, Prln
```

Il DAG libero identifica quali variabili sono **cause dirette** del contenuto alcolico (genitori) e quali sono **effetti diretti** (figli). A differenza del grafo indiretto, il DAG specifica la direzione delle relazioni, fornendo un'interpretazione causale più ricca.

Tuttavia, il risultato ottenuto solleva una questione importante: **Alch non ha genitori ma ha tre figli** (Clri, Hue, Prln). Questo suggerisce che l'algoritmo ha interpretato il contenuto alcolico come una "causa" piuttosto che come un "effetto" delle altre proprietà chimiche. Questa orientazione, sebbene statisticamente ottimale secondo il criterio BIC applicato ai dati osservazionali, è **contro-intuitiva dal punto di vista del dominio enologico**: ci aspetteremmo che variabili come la prolina, i fenoli o l'acidità influenzino il contenuto alcolico durante il processo di fermentazione, non viceversa.

Questo illustra un **limite fondamentale dell'inferenza causale puramente data-driven**: senza vincoli basati sulla conoscenza del dominio, l'algoritmo può orientare gli archi in qualsiasi direzione che massimizzi il fit statistico, producendo strutture causali plausibili dal punto di vista matematico ma non necessariamente interpretabili. Per questo motivo, nella prossima sezione imponiamo vincoli espliciti per garantire che Alch sia modellato come variabile target.

5.1.2 DAG con Alch Target

Per imporre questa struttura causale basata sulla conoscenza del dominio, costruiamo un **DAG vincolato** dove Alch può essere solo un **node sink** (ricevere archi ma non emetterne). Questo significa che Alch può avere solo genitori (predittori diretti) ma non figli.

```
# Creazione della blacklist: Alch non può essere genitore di nessuna variabile  
altre_vars <- setdiff(names(wine_no_cult), "Alch")  
blacklist_alch <- data.frame(  
  from = rep("Alch", length(altre_vars)),  
  to = altre_vars  
)
```

```
# Apprendimento DAG con vincolo: Alch come sink node  
dag_target <- hc(wine_no_cult, score = "bic-g", blacklist = blacklist_alch)
```

```
# Numero di archi selezionati  
n_archi_target <- narcs(dag_target)  
cat("Numero di archi nel DAG vincolato:", n_archi_target, "\n")
```

```
## Numero di archi nel DAG vincolato: 23
```

```
cat("Numero di archi nel DAG libero:", n_archi_dag, "\n")
```

```
## Numero di archi nel DAG libero: 24
```

```
# Conversione in oggetto igraph
dag_target_igraph <- as.igraph(dag_target)
```

Il vincolo imposto modifica la struttura appresa: l'algoritmo deve ora trovare la migliore configurazione di archi compatibile con l'assunzione che Alch sia una variabile risposta. Visualizziamo il DAG vincolato:

```
# Identificazione dei genitori di Alch (ora non può avere figli per costruzione)
genitori_alch_target <- parents(dag_target, "Alch")
# Colorazione dei nodi
colori_nodi_target <- ifelse(V(dag_target_igraph)$name == "Alch", "#E46726",
                             ifelse(V(dag_target_igraph)$name %in% genitori_alch_target,
                                     "#FFD700", "#6D9EC1"))

# Layout gerarchico
set.seed(789)
layout_target <- layout_with_sugiyama(dag_target_igraph)$layout
# Margini ridotti
par(mar = c(1, 1, 0.5, 1))
# Plot del DAG
plot(dag_target_igraph,
     layout = layout_target,
     vertex.size = 8,
     vertex.color = colori_nodi_target,
     vertex.frame.color = "gray30",
     vertex.label.cex = 0.7,
     vertex.label.color = "black",
     vertex.label.font = 2,
     edge.color = "gray50",
     edge.width = 1.5,
     edge.arrow.size = 0.5,
     edge.curved = 0.1,
     main = "")
# Legenda
legend("bottomright",
      legend = c("Alch (target)", "Predittori diretti di Alch", "Altre variabili"),
      fill = c("#E46726", "#FFD700", "#6D9EC1"),
      cex = 0.6,
      bty = "n")
```




Figure 12: DAG vincolato con Alch come sink - Intera popolazione

Analizziamo i predittori diretti di Alch nel modello vincolato:

```
cat("Predittori diretti di Alch:",  
    if(length(genitori_alch_target) > 0)  
      paste(genitori_alch_target, collapse = ", ") else "Nessuno", "\n")
```

```
## Predittori diretti di Alch: Clri, Prln
```

Il DAG vincolato identifica le variabili che hanno un **effetto causale diretto** sul contenuto alcolico, secondo la struttura ottimale compatibile con il vincolo imposto. Queste variabili rappresentano i candidati naturali per un modello di regressione che mira a predire il contenuto alcolico.

Confronto tra DAG libero e DAG vincolato:

Imporre il vincolo che Alch sia un nodo sink ha modificato sostanzialmente la struttura del grafo:

- **Numero di archi:** Il DAG vincolato contiene un numero diverso di archi rispetto al DAG libero, riflettendo la riorganizzazione della struttura causale per rispettare il vincolo imposto.
- **Predittori di Alch:** Nel DAG libero, Alch non aveva genitori (predittori diretti), mentre nel DAG vincolato l'algoritmo ha identificato un insieme specifico di variabili come cause dirette del contenuto alcolico. Questi predittori rappresentano le variabili chimiche che, condizionatamente alle altre, hanno l'influenza più forte su Alch.
- **Interpretabilità:** Il DAG vincolato fornisce una struttura causale **più interpretabile e coerente** con la conoscenza enologica, dove il contenuto alcolico è chiaramente una variabile risposta influenzata da proprietà chimiche misurabili, piuttosto che una causa di esse.

Questa analisi dimostra l'importanza di **integrare conoscenza del dominio** nell'inferenza causale: i vincoli espliciti guidano l'algoritmo verso strutture causali più plausibili e utili per l'interpretazione scientifica e la modellazione predittiva.

5.2 DAG - Con Cultivar

5.2.1 DAG Libero con Cultivar

Includiamo ora la variabile **Cult** nell'analisi dei DAG. Come nel Capitolo 4, utilizziamo due **variabili dummy** (Cult_v2 e Cult_v3) per rappresentare i tre livelli del cultivar, con v1 come riferimento. Questo permette di valutare come il tipo di coltivazione modifichi la struttura causale tra le variabili chimiche e il contenuto alcolico.

Iniziamo con un DAG libero, senza vincoli di orientamento, per esplorare la struttura causale suggerita dai soli dati osservazionali.

```
# Preparazione dataset con dummy variables per cultivar  
wine_cult <- wine %>%  
  mutate(Cult_v2 = as.numeric(Cult == "v2"),  
         Cult_v3 = as.numeric(Cult == "v3")) %>%  
  select(-Cult) %>%  
  as.data.frame()  
  
# Conversione a numeric per bnlearn  
wine_cult <- as.data.frame(lapply(wine_cult, as.numeric))  
  
# Apprendimento DAG libero  
dag_libero_cult <- hc(wine_cult, score = "bic-g")  
  
# Numero di archi
```

```
n_archi_dag_cult <- narcs(dag_libero_cult)
cat("Numero di archi nel DAG libero con cultivar:", n_archi_dag_cult, "\n")
```

```
## Numero di archi nel DAG libero con cultivar: 35
```

```
cat("Numero di archi nel DAG libero senza cultivar:", n_archi_dag, "\n")
```

```
## Numero di archi nel DAG libero senza cultivar: 24
```

```
# Conversione in igraph
dag_cult_igraph <- as.igraph(dag_libero_cult)
```

Il DAG con cultivar contiene più nodi (15 variabili invece di 13) e potenzialmente una struttura più complessa. Visualizziamo il grafo:

```
# Identificazione genitori e figli di Alch
genitori_alch_cult <- parents(dag_libero_cult, "Alch")
figli_alch_cult <- children(dag_libero_cult, "Alch")

# Identificazione figli di Cult_v2 e Cult_v3 (variabili influenzate dal cultivar)
figli_cult_v2 <- children(dag_libero_cult, "Cult_v2")
figli_cult_v3 <- children(dag_libero_cult, "Cult_v3")
figli_cult <- unique(c(figli_cult_v2, figli_cult_v3))

# Colorazione dei nodi
colori_nodi_dag_cult <- ifelse(V(dag_cult_igraph)$name == "Alch", "#E46726",
                               ifelse(V(dag_cult_igraph)$name %in% c("Cult_v2", "Cult_v3"), "#9370DB",
                                       ifelse(V(dag_cult_igraph)$name %in% genitori_alch_cult, "#FFD700",
                                               ifelse(V(dag_cult_igraph)$name %in% figli_alch_cult,
                                                       "#90EE90", "#6D9EC1")))))

# Layout gerarchico
set.seed(567)
layout_dag_cult <- layout_with_sugiyama(dag_cult_igraph)$layout

# Margini ridotti
par(mar = c(1, 1, 0.5, 1))

# Plot
plot(dag_cult_igraph,
     layout = layout_dag_cult,
     vertex.size = 8,
     vertex.color = colori_nodi_dag_cult,
     vertex.frame.color = "gray30",
     vertex.label.cex = 0.7,
     vertex.label.color = "black",
     vertex.label.font = 2,
     edge.color = "gray50",
     edge.width = 1.5,
     edge.arrow.size = 0.5,
     edge.curved = 0.1,
     main = "")

# Legenda
legend("bottomleft",
      legend = c("Alch (target)", "Cult_v2/v3 (cultivar)",
                 "Genitori di Alch", "Figli di Alch", "Altre variabili"),
```

```
fill = c("#E46726", "#9370DB", "#FFD700", "#90EE90", "#6D9EC1"),
cex = 0.55,
bty = "n")
```




Figure 13: DAG libero con cultivar - Dataset completo

Analizziamo la struttura causale di Alch e delle variabili cultivar:

```
cat("Genitori di Alch (predittori diretti):",
    if(length(genitori_alch_cult) > 0) paste(genitori_alch_cult, collapse = ", ") else "Nessuno", "\n")
```

```
## Genitori di Alch (predittori diretti): Nessuno
```

```
cat("Figli di Alch (variabili causate da Alch):",
    if(length(figli_alch_cult) > 0) paste(figli_alch_cult, collapse = ", ") else "Nessuno", "\n\n")
```

```
## Figli di Alch (variabili causate da Alch): Clri, Prln, Cult_v2, Cult_v3
```

```
cat("Figli di Cult_v2:",
    if(length(figli_cult_v2) > 0) paste(figli_cult_v2, collapse = ", ") else "Nessuno", "\n")
```

```
## Figli di Cult_v2: Ash, Aloa
```

```
cat("Figli di Cult_v3:",
    if(length(figli_cult_v3) > 0) paste(figli_cult_v3, collapse = ", ") else "Nessuno", "\n")
```

```
## Figli di Cult_v3: Mlca, Aloa, Clri, Hue, Oodw, Cult_v2
```

Il DAG libero con cultivar rivela come il tipo di coltivazione influenzi altre variabili (figli di Cult_v2 e

Cult_v3) e come queste, a loro volta, possano influenzare il contenuto alcolico. Tuttavia, come osservato per il DAG senza cultivar, l'orientazione automatica degli archi può produrre strutture causali poco interpretabili: potremmo osservare archi che vanno da Alch verso variabili chimiche, o dalle variabili chimiche verso il cultivar, orientazioni che contraddicono la conoscenza del dominio.

Per ottenere una struttura causale più coerente con la realtà enologica, nella prossima sezione imponiamo vincoli espliciti basati sulla conoscenza del dominio.

5.2.2 DAG con Cult Esogena e Alch Target

Per imporre una struttura causale interpretabile, costruiamo un **DAG doppiamente vincolato** dove:

1. **Cult_v2 e Cult_v3 sono variabili esogene** (source nodes): possono solo influenzare altre variabili, non essere influenzate. Il tipo di coltivazione è determinato esogenamente (scelta agronomica) e non può essere causato dalle proprietà chimiche del vino.
2. **Alch è variabile target** (sink node): può solo ricevere influenze, non causarne. Come visto nella sezione 5.1.2, questa è l'interpretazione enologica corretta.

Questi vincoli garantiscono una **struttura gerarchica causale**: Cult → variabili chimiche → Alch.

```
# Blacklist 1: Cult_v2 e Cult_v3 non possono avere genitori (sono esogene)
altre_vars_cult <- setdiff(names(wine_cult), c("Cult_v2", "Cult_v3"))

# Costruzione più esplicita della blacklist per Cult
blacklist_cult_v2 <- data.frame(
  from = altre_vars_cult,
  to = rep("Cult_v2", length(alte_vars_cult))
)
blacklist_cult_v3 <- data.frame(
  from = altre_vars_cult,
  to = rep("Cult_v3", length(alte_vars_cult))
)
blacklist_cult_source <- rbind(blacklist_cult_v2, blacklist_cult_v3)

# Blacklist 2: Alch non può essere genitore (è sink)
altre_vars_no_alch <- setdiff(names(wine_cult), "Alch")
blacklist_alch_sink <- data.frame(
  from = rep("Alch", length(alte_vars_no_alch)),
  to = altre_vars_no_alch
)

# Blacklist 3: Cult_v2 e Cult_v3 non possono influenzarsi a vicenda (sono dummy della stessa variabile)
blacklist_cult_mutual <- data.frame(
  from = c("Cult_v2", "Cult_v3"),
  to = c("Cult_v3", "Cult_v2")
)

# Combinazione delle blacklist
blacklist_completa <- rbind(blacklist_cult_source, blacklist_alch_sink, blacklist_cult_mutual)

# Apprendimento DAG vincolato
dag_vinc_cult <- hc(wine_cult, score = "bic-g", blacklist = blacklist_completa)

# Numero di archi
n_archi_vinc_cult <- narcs(dag_vinc_cult)
cat("Numero di archi nel DAG vincolato con cultivar:", n_archi_vinc_cult, "\n")
```

```
## Numero di archi nel DAG vincolato con cultivar: 34
```



```
cat("Numero di archi nel DAG libero con cultivar:", n_archi_dag_cult, "\n")
```

```
## Numero di archi nel DAG libero con cultivar: 35
```

```
# Conversione in igraph
```

```
dag_vinc_cult_igraph <- as.igraph(dag_vinc_cult)
```

Il vincolo imposto riorganizza sostanzialmente la struttura del grafo per rispettare la gerarchia causale Cult → Chimica → Alch.

Visualizziamo il DAG vincolato:

```
# Identificazione genitori di Alch
```

```
genitori_alch_vinc <- parents(dag_vinc_cult, "Alch")
```

```
# Colorazione dei nodi
```

```
colori_nodi_vinc_cult <- ifelse(V(dag_vinc_cult_igraph)$name == "Alch", "#E46726",  
                               ifelse(V(dag_vinc_cult_igraph)$name %in% c("Cult_v2", "Cult_v3"), "#9370DB",  
                                       ifelse(V(dag_vinc_cult_igraph)$name %in% genitori_alch_vinc,  
                                              "#FFD700", "#6D9EC1"))))
```

```
# Layout gerarchico
```

```
set.seed(678)
```

```
layout_vinc_cult <- layout_with_sugiyama(dag_vinc_cult_igraph)$layout
```

```
# Sposta Alch più a destra per migliorare la visibilità
```

```
alch_idx <- which(V(dag_vinc_cult_igraph)$name == "Alch")
```

```
if(length(alch_idx) > 0) {
```

```
  layout_vinc_cult[alch_idx, 1] <- layout_vinc_cult[alch_idx, 1] + 2.5
```

```
}
```

```
# Margini ridotti
```

```
par(mar = c(1, 1, 0.5, 1))
```

```
# Plot
```

```
plot(dag_vinc_cult_igraph,  
     layout = layout_vinc_cult,  
     vertex.size = 8,  
     vertex.color = colori_nodi_vinc_cult,  
     vertex.frame.color = "gray30",  
     vertex.label.cex = 0.7,  
     vertex.label.color = "black",  
     vertex.label.font = 2,  
     edge.color = "gray50",  
     edge.width = 1.5,  
     edge.arrow.size = 0.5,  
     edge.curved = 0.1,  
     main = "")
```

```
# Legenda
```

```
legend("bottomright",  
      legend = c("Alch (target)", "Cult_v2/v3 (esogene)",  
                 "Predittori diretti di Alch", "Altre variabili"),  
      fill = c("#E46726", "#9370DB", "#FFD700", "#6D9EC1"),  
      cex = 0.6,  
      bty = "n")
```




Figure 14: DAG vincolato: Cult esogena, Alch target

Analizziamo i predittori diretti di Alch nel modello vincolato:

```
cat("Predittori diretti di Alch:",
    if(length(genitori_alch_vinc) > 0)
      paste(genitori_alch_vinc, collapse = ", ") else "Nessuno", "\n")

## Predittori diretti di Alch: Clri, Cult_v2, Cult_v3

# Verifica se Cult_v2 o Cult_v3 sono predittori diretti di Alch
cult_vars_in_parents <- c("Cult_v2", "Cult_v3")[c("Cult_v2", "Cult_v3") %in% genitori_alch_vinc]
if(length(cult_vars_in_parents) > 0) {
  cat("Effetto diretto del cultivar su Alch:", paste(cult_vars_in_parents, collapse = ", "), "\n")
} else {
  cat("Effetto del cultivar su Alch: solo indiretto (mediato da variabili chimiche)\n")
}

## Effetto diretto del cultivar su Alch: Cult_v2, Cult_v3
```

Risultato cruciale: Il DAG vincolato identifica **Cult_v2** e **Cult_v3** come genitori diretti di **Alch**, insieme a **Clri**. Questo è un risultato di grande rilevanza enologica: il tipo di coltivazione ha un **effetto causale diretto** sul contenuto alcolico che non è completamente mediato dalle 13 variabili chimiche misurate nel dataset.

In altre parole, il cultivar influenza il contenuto alcolico attraverso **due percorsi causali**:

1. **Effetto indiretto:** Cult → variabili chimiche (Clri, Prln, ecc.) → Alch
2. **Effetto diretto:** Cult → Alch (non mediato dalle variabili misurate)

L'esistenza dell'effetto diretto suggerisce che vi sono **meccanismi biologici o enologici non catturati**

dalle 13 variabili chimiche del dataset che collegano il tipo di coltivazione al contenuto alcolico finale. Questi potrebbero includere differenze nei processi di fermentazione, nella composizione microbiologica, o in altre proprietà biochimiche non misurate.

Confronto tra DAG libero e DAG vincolato con cultivar:

L'imposizione dei vincoli causali ha riorganizzato sostanzialmente la struttura del grafo:

- **Struttura gerarchica:** Il DAG vincolato rispetta la gerarchia causale $\text{Cult} \rightarrow \text{Chimica} \rightarrow \text{Alch}$, dove le variabili cultivar influenzano le proprietà chimiche e il contenuto alcolico, mai il contrario.
- **Predittori di Alch:** Il DAG vincolato identifica **tre predittori diretti** del contenuto alcolico: Clri (intensità del colore), Cult_v2 e Cult_v3. Questo indica che, condizionatamente alle altre variabili, questi tre fattori hanno l'influenza causale più forte su Alch.
- **Interpretabilità e validità scientifica:** Il DAG vincolato fornisce una rappresentazione causale coerente con la conoscenza enologica, dove il tipo di coltivazione è una caratteristica esogena che determina sia le proprietà chimiche sia direttamente il contenuto alcolico.

5.3 Sintesi dei Modelli Grafici Diretti

In questo capitolo abbiamo analizzato **quattro modelli DAG** per esplorare le relazioni causali tra le variabili del dataset Wine, con particolare attenzione al contenuto alcolico (Alch).

5.3.1 Confronto tra Modelli e Principali Scoperte

Ruolo di Alch nei modelli senza vincoli:

Nel DAG libero sulla popolazione (5.1.1), l'algoritmo ha identificato Alch come **variabile causale** piuttosto che come effetto, con tre variabili figlie (Clri, Hue, Prln) e nessun genitore. Questa struttura è **contro-intuitiva** dal punto di vista enologico: il contenuto alcolico è tipicamente una conseguenza delle proprietà chimiche dell'uva e del processo di fermentazione, non una loro causa.

Importanza dei vincoli basati su conoscenza del dominio:

Imponendo il vincolo che Alch sia una variabile sink (5.1.2), il DAG ha riorganizzato la struttura causale identificando **predittori diretti** del contenuto alcolico. Questo dimostra che l'**integrazione di conoscenza del dominio** è essenziale per ottenere modelli causali scientificamente validi: l'apprendimento puramente data-driven può produrre strutture statisticamente corrette ma causalmente implausibili.

Effetto del Cultivar:

L'inclusione del tipo di coltivazione (sezioni 5.2.1 e 5.2.2) ha ottenuto un risultato di grande rilevanza enologica: nel DAG vincolato, **Cult_v2 e Cult_v3 sono predittori diretti di Alch**, insieme a Clri. Questo indica che il cultivar ha un **effetto causale diretto** sul contenuto alcolico che non è completamente mediato dalle 13 variabili chimiche misurate.

L'esistenza di questo effetto diretto suggerisce la presenza di **meccanismi biologici o enologici non catturati** dalle variabili misurate, come differenze nei processi di fermentazione, nella composizione microbiologica, o in altre proprietà biochimiche specifiche del cultivar.

Struttura gerarchica causale:

Il DAG vincolato con cultivar (5.2.2) rispetta la gerarchia causale $\text{Cult} \rightarrow \text{Chimica} \rightarrow \text{Alch}$, dove:

- Il cultivar (variabile esogena) influenza sia le proprietà chimiche sia direttamente il contenuto alcolico
- Le variabili chimiche fungono da **mediatori parziali** dell'effetto del cultivar su Alch
- Alch è il **nodo terminale** (sink) che riceve influenze ma non ne genera

5.3.2 Collegamento con i Grafi Indiretti (Capitolo 4)

La progressione da grafi indiretti (UG, Capitolo 4) a grafi diretti (DAG, Capitolo 5) riflette un **approfondimento nell'analisi causale**, passando dai semplici pattern di associazione condizionale alle strutture gerarchiche di influenza diretta e indiretta.

Per i modelli sulla popolazione (senza cultivar):

- Nel **Capitolo 4** (grafi indiretti), abbiamo identificato le variabili connesse ad Alch tramite archi non orientati, che indicano dipendenze condizionali ma non specificano la direzione della relazione causale.
- Nel **Capitolo 5** (sezione 5.1.2), il DAG vincolato fornisce informazioni più specifiche: identifica non solo quali variabili sono dipendenti da Alch, ma anche la **direzione causale**, specificando quali variabili agiscono come predittori diretti del contenuto alcolico.
- Confrontando i due grafi, alcune variabili connesse ad Alch nel grafo indiretto sono state identificate come **genitori diretti** nel DAG, mentre altre influenzano Alch solo indirettamente, attraverso catene causali mediate da altre variabili.

Per i modelli con cultivar:

- Nel **Capitolo 4** (sezione 4.5), il grafo indiretto con cultivar ha identificato connessioni dirette tra Cult_v2/Cult_v3 e Alch, suggerendo un'associazione condizionale tra tipo di coltivazione e contenuto alcolico.
- Nel **Capitolo 5** (sezione 5.2.2), il DAG vincolato **conferma e rafforza questa scoperta** fornendo un'interpretazione causale: le connessioni Cult-Alch osservate nel grafo indiretto riflettono **vere relazioni causali dirette**, non semplicemente associazioni spurie o mediate da altre variabili.
- Il DAG specifica inoltre la **direzione della causalità**: sono le caratteristiche del cultivar a influenzare il contenuto alcolico, e non viceversa (cosa ovvia dal punto di vista biologico ma importante da un punto di vista statistico).

5.3.3 Implicazioni per la Modellazione Predittiva (Capitolo 6)

I risultati dei DAG hanno importanti implicazioni per l'analisi di regressione del Capitolo 6:

1. **Necessità di includere il cultivar:** La presenza di un effetto causale diretto del cultivar su Alch indica che per prevedere accuratamente il contenuto alcolico **non è sufficiente conoscere solo le proprietà chimiche** del vino. È necessario includere anche l'informazione sul tipo di coltivazione nel modello di regressione.
2. **Identificazione dei predittori rilevanti:** I DAG vincolati forniscono indicazioni su quali variabili sono più rilevanti come predittori diretti di Alch, guidando la selezione delle variabili nel modello di regressione multipla.
3. **Interpretazione causale vs predittiva:** Mentre i DAG forniscono un'interpretazione **causale** delle relazioni (qual è la direzione dell'influenza), la regressione del Capitolo 6 quantificherà **l'entità dell'associazione** e la capacità predittiva del modello.
4. **Effetti diretti e indiretti:** La distinzione tra predittori diretti e indiretti identificata nei DAG aiuterà a interpretare i coefficienti di regressione, distinguendo effetti diretti da quelli mediati da altre variabili.

6 Regressione Lineare Multipla

Nei capitoli precedenti abbiamo utilizzato **modelli grafici** (indiretti e diretti) per esplorare la struttura di dipendenze tra le variabili chimiche del vino e identificare le relazioni causali che collegano la composizione chimica al contenuto alcolico. Questi modelli hanno fornito un quadro qualitativo delle relazioni, specificando **quali** variabili sono connesse tra loro e **in che direzione** agisce l'influenza causale.

In questo capitolo passiamo dall'analisi strutturale alla **modellazione quantitativa predittiva**, utilizzando la regressione lineare multipla per:

1. **Quantificare l'effetto** di ciascun predittore chimico sul contenuto alcolico
2. **Stimare** i coefficienti di regressione che specificano l'entità e la direzione delle associazioni
3. **Predire** il contenuto alcolico a partire dalle misure chimiche osservate
4. **Valutare** la capacità esplicativa del modello attraverso metriche di adattamento
5. **Confrontare** modelli alternativi per identificare la specificazione ottimale

La regressione lineare multipla rappresenta il naturale complemento ai modelli grafici: mentre i DAG identificano i predittori diretti del contenuto alcolico e la struttura causale, la regressione **quantifica l'entità** di queste relazioni e valuta la capacità predittiva del modello.

6.1 Il Modello di Regressione Lineare Multipla

La regressione lineare multipla è una tecnica statistica appropriata per modellare una variabile dipendente continua in funzione di più variabili esplicative. Nel nostro contesto, utilizziamo questa metodologia per predire il contenuto alcolico (**Alch**) a partire dalle proprietà chimiche del vino e, nella seconda fase, dal tipo di cultivar.

6.1.1 Formulazione del Modello

Il modello di regressione lineare multipla assume la forma:

$$\text{Alch}_i = \beta_0 + \beta_1 x_{i1} + \beta_2 x_{i2} + \cdots + \beta_p x_{ip} + \varepsilon_i$$

dove:

- Alch_i è il valore del contenuto alcolico per la i -esima osservazione (variabile target)
- $x_{i1}, x_{i2}, \dots, x_{ip}$ sono i valori dei p predittori (variabili chimiche e/o dummy per il cultivar) per l'osservazione i
- β_0 è l'intercetta, che rappresenta il valore atteso di Alch quando tutti i predittori sono pari a zero
- $\beta_1, \beta_2, \dots, \beta_p$ sono i coefficienti di regressione parziali, che quantificano l'effetto di ciascun predittore sul contenuto alcolico, tenendo costanti tutti gli altri predittori
- ε_i è il termine di errore per l'osservazione i

Il modello assume che gli errori siano **indipendenti e identicamente distribuiti** secondo una distribuzione normale:

$$\varepsilon_i \sim N(0, \sigma^2)$$

dove σ^2 è la varianza comune degli errori, costante per tutte le osservazioni.

6.1.2 Stima dei Parametri

Per la stima dei coefficienti $\beta_0, \beta_1, \dots, \beta_p$ utilizziamo la funzione **lm()** (Linear Model) di R, che implementa il metodo dei **minimi quadrati ordinari** (OLS - Ordinary Least Squares). Questo metodo determina i coefficienti che minimizzano la somma dei quadrati dei residui:

$$RSS = \sum_{i=1}^n (y_i - \hat{y}_i)^2 = \sum_{i=1}^n \left(\text{Alch}_i - \hat{\beta}_0 - \hat{\beta}_1 x_{i1} - \dots - \hat{\beta}_p x_{ip} \right)^2$$

dove $\hat{\beta}_0, \hat{\beta}_1, \dots, \hat{\beta}_p$ sono le stime dei coefficienti e $\hat{y}_i$ è il valore predetto per l'osservazione i .

Gli stimatori OLS godono di proprietà ottimali sotto le assunzioni classiche del modello lineare (teorema di Gauss-Markov): sono **non distorti**, **consistenti** e **efficienti** (varianza minima tra tutti gli stimatori lineari non distorti).

6.2 Approccio Metodologico

Come nei capitoli precedenti, l'analisi si articola in **due fasi** corrispondenti ai due dataset:

Fase 1 - Popolazione Globale (senza cultivar): Costruiamo modelli di regressione utilizzando esclusivamente le **13 variabili chimiche** come predittori del contenuto alcolico. Questa analisi permette di quantificare le relazioni chimiche “pure” identificate nei grafi indiretti (Capitolo 4, sezione 4.4) e nei DAG vincolati (Capitolo 5, sezione 5.1.2).

Fase 2 - Dataset con Cultivar: Includiamo il **tipo di coltivazione** come predittore categorico (tramite variabili dummy), per valutare se il cultivar contribuisce significativamente alla previsione del contenuto alcolico oltre alle proprietà chimiche. Questa analisi quantifica l'effetto diretto del cultivar identificato nei modelli grafici (Capitolo 4, sezione 4.5 e Capitolo 5, sezione 5.2.2).

Per ciascuna fase, applichiamo **procedure di selezione stepwise** con due criteri alternativi e tre direzioni di ricerca:

Criteri di selezione:

- **AIC (Akaike Information Criterion):** Metrica che bilancia la bontà di adattamento e la complessità del modello con una penalizzazione moderata. Tende a selezionare modelli più ricchi di predittori, privilegiando la capacità esplicativa.

$$AIC = n \cdot \ln(RSS/n) + 2k$$

- **BIC (Bayesian Information Criterion):** Criterio che penalizza la complessità in modo più severo dell'AIC, favorendo modelli parsimoniosi. È definito come:

$$BIC = n \cdot \ln(RSS/n) + k \cdot \ln(n)$$

dove n è il numero di osservazioni, RSS è la somma dei quadrati dei residui, e k è il numero di parametri stimati.

Direzioni di ricerca:

- **Backward:** Parte dal modello saturo (tutti i predittori) e rimuove iterativamente le variabili che contribuiscono meno al criterio
- **Forward:** Parte dal modello nullo (solo intercetta) e aggiunge iterativamente i predittori che migliorano maggiormente il criterio
- **Both (bidirectional):** Combina aggiunta e rimozione di variabili ad ogni passo, permettendo maggiore flessibilità nella selezione

L'applicazione sistematica di **6 procedure** (AIC/BIC $\times$ backward/forward/both) per ciascuna fase permette di valutare la **stabilità** dei modelli selezionati rispetto alla scelta del criterio e della strategia di ricerca. Variabili che emergono consistentemente attraverso diverse procedure sono i predittori più robusti e affidabili.

Al termine delle due fasi, confronteremo i risultati per valutare:

- La **stabilità delle selezioni** attraverso criteri e direzioni diverse
- Il **contributo del cultivar** come variabile esplicativa aggiuntiva
- La **coerenza** tra i predittori selezionati e le dipendenze dirette identificate dai modelli grafici

6.3 Collegamento con i Modelli Grafici

I risultati dei capitoli precedenti forniscono **indicazioni cruciali** per la specificazione dei modelli di regressione:

Dal grafo indiretto (Capitolo 4): Il grafo UG selezionato ha identificato **Clri** e **Prln** come le uniche variabili connesse direttamente ad Alch nell'analisi senza cultivar. Questo suggerisce che un modello parsimonioso potrebbe includere solo questi due predittori. Con il cultivar, il grafo UG ha inoltre evidenziato connessioni dirette **Cult-Alch**, indicando la necessità di includere le variabili dummy nel modello.

Dal DAG vincolato (Capitolo 5): I DAG in cui Alch è imposto come variabile sink hanno identificato i **predittori diretti causali** del contenuto alcolico. Nel modello senza cultivar (5.1.2), le variabili genitori di Alch forniscono un sottoinsieme naturale di predittori per la regressione. Nel modello con cultivar (5.2.2), il DAG ha rivelato che **Cult_v2 e Cult_v3 hanno un effetto causale diretto** su Alch non mediato dalle variabili chimiche, rafforzando la necessità di includere il cultivar nella regressione.

Dall'analisi esplorativa (Capitolo 3): Le correlazioni marginali (3.4) hanno identificato **Prln** ($r=0.64$) e **Clri** ($r=0.55$) come i predittori con le associazioni lineari più forti con Alch. Tuttavia, come dimostrato dalle correlazioni parziali (4.2), molte di queste correlazioni marginali erano spurie e mediate da altre variabili. La regressione multipla, controllando simultaneamente per tutti i predittori, fornirà stime degli **effetti parziali** analoghi alle correlazioni parziali.

Le procedure stepwise, applicando sia criteri AIC che BIC in diverse direzioni di ricerca, permetteranno di identificare quali predittori emergono in modo robusto come variabili esplicative del contenuto alcolico, offrendo una validazione quantitativa delle strutture di dipendenza identificate nei modelli grafici.

6.4 Analisi sulla Popolazione Globale

In questa sezione analizziamo il dataset `wine_no_cult`, che contiene le **13 variabili chimiche** escludendo il tipo di cultivar. L'obiettivo è costruire un modello di regressione multipla per predire il contenuto alcolico (**Alch**) utilizzando esclusivamente informazioni sulla composizione chimica del vino.

Applicheremo la procedura di selezione stepwise utilizzando sia il criterio **AIC** che il criterio **BIC**, con tre direzioni diverse: **backward**, **forward** e **both**. Questo approccio permette di identificare il modello più parsimonioso che bilancia adattamento ai dati e complessità del modello.

```
# Definizione del modello nullo
null_model <- lm(Alch ~ 1, data = wine_no_cult)

# Definizione del modello saturo
full_model <- lm(Alch ~ ., data = wine_no_cult)

# Definizione dello scope per gli intervalli di lavoro
scope <- list(lower = formula(null_model), upper = formula(full_model))

# ===== AIC =====

# Backward
back_model_AIC <- step(full_model, scope = scope, direction = "backward", trace = 0)
cat("=== AIC Backward ===")

## === AIC Backward ===

summary(back_model_AIC)
```

```
##
## Call:
## lm(formula = Alch ~ Mlca + Aloa + Prnt + Clri + Oodw + Prln,
##     data = wine_no_cult)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -1.50233 -0.34225  0.00116  0.33005  1.69364
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) 11.3332831  0.3943623  28.738 < 2e-16 ***
## Mlca         0.1143127  0.0397878   2.873  0.00458 **
## Aloa        -0.0324405  0.0137533  -2.359  0.01947 *
## Prnt        -0.1296362  0.0846088  -1.532  0.12732
## Clri         0.1585201  0.0231627   6.844 1.32e-10 ***
## Oodw         0.2254528  0.0834109   2.703  0.00757 **
## Prln         0.0011358  0.0001708   6.651 3.76e-10 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.5295 on 171 degrees of freedom
## Multiple R-squared:  0.5889, Adjusted R-squared:  0.5745
## F-statistic: 40.83 on 6 and 171 DF,  p-value: < 2.2e-16
```

Forward

```
forw_model_AIC <- step(null_model, scope = scope, direction = "forward", trace = 0)
cat("=== AIC Forward ===")
```

```
## === AIC Forward ===
```

`summary(forw_model_AIC)`

```
##
## Call:
## lm(formula = Alch ~ Prln + Clri + Mlca + Aloa + Oodw + Prnt,
##     data = wine_no_cult)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -1.50233 -0.34225  0.00116  0.33005  1.69364
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) 11.3332831  0.3943623  28.738 < 2e-16 ***
## Prln         0.0011358  0.0001708   6.651 3.76e-10 ***
## Clri         0.1585201  0.0231627   6.844 1.32e-10 ***
## Mlca         0.1143127  0.0397878   2.873  0.00458 **
## Aloa        -0.0324405  0.0137533  -2.359  0.01947 *
## Oodw         0.2254528  0.0834109   2.703  0.00757 **
## Prnt        -0.1296362  0.0846088  -1.532  0.12732
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.5295 on 171 degrees of freedom
## Multiple R-squared:  0.5889, Adjusted R-squared:  0.5745
## F-statistic: 40.83 on 6 and 171 DF,  p-value: < 2.2e-16
```

Both

```
both_model_AIC <- step(null_model, scope = scope, direction = "both", trace = 0)
cat("=== AIC Both ===")
```



```
## === AIC Both ===
```

```
summary(both_model_AIC)
```

```
##
## Call:
## lm(formula = Alch ~ Prln + Clri + Mlca + Aloa + Oodw + Prnt,
##     data = wine_no_cult)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -1.50233 -0.34225  0.00116  0.33005  1.69364
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) 11.3332831  0.3943623  28.738 < 2e-16 ***
## Prln        0.0011358  0.0001708   6.651 3.76e-10 ***
## Clri        0.1585201  0.0231627   6.844 1.32e-10 ***
## Mlca        0.1143127  0.0397878   2.873  0.00458 **
## Aloa       -0.0324405  0.0137533  -2.359  0.01947 *
## Oodw        0.2254528  0.0834109   2.703  0.00757 **
## Prnt       -0.1296362  0.0846088  -1.532  0.12732
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.5295 on 171 degrees of freedom
## Multiple R-squared:  0.5889, Adjusted R-squared:  0.5745
## F-statistic: 40.83 on 6 and 171 DF, p-value: < 2.2e-16
```

```
# ===== BIC =====
```

```
# Backward
```

```
back_model_BIC <- step(full_model, scope = scope, direction = "backward",
                        k = log(nrow(wine_no_cult)), trace = 0)
cat("=== BIC Backward ===")
```

```
## === BIC Backward ===
```

```
summary(back_model_BIC)
```

```
##
## Call:
## lm(formula = Alch ~ Mlca + Aloa + Clri + Prln, data = wine_no_cult)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -1.47459 -0.36917  0.00056  0.36430  1.77082
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept) 11.8295611  0.3287319  35.985 < 2e-16 ***
## Mlca        0.1024480  0.0397664   2.576  0.0108 *
## Aloa       -0.0337045  0.0139570  -2.415  0.0168 *
## Clri        0.1249396  0.0196251   6.366 1.68e-09 ***
## Prln        0.0012811  0.0001561   8.209 4.96e-14 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.5378 on 173 degrees of freedom
## Multiple R-squared:  0.5711, Adjusted R-squared:  0.5612
```

```
## F-statistic: 57.6 on 4 and 173 DF, p-value: < 2.2e-16
```

```
# Forward
forw_model_BIC <- step(null_model, scope = scope, direction = "forward",
                        k = log(nrow(wine_no_cult)), trace = 0)
cat("=== BIC Forward ===")
```

```
## === BIC Forward ===
```

```
summary(forw_model_BIC)
```

```
##
## Call:
## lm(formula = Alch ~ Prln + Clri, data = wine_no_cult)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -1.31693 -0.40475 -0.02155  0.36010  1.53773
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  1.132e+01  1.235e-01  91.659  < 2e-16 ***
## Prln         1.349e-03  1.386e-04   9.737  < 2e-16 ***
## Clri         1.334e-01  1.882e-02   7.088 3.21e-11 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.5507 on 175 degrees of freedom
## Multiple R-squared:  0.545, Adjusted R-squared:  0.5398
## F-statistic: 104.8 on 2 and 175 DF, p-value: < 2.2e-16
```

```
# Both
both_model_BIC <- step(null_model, scope = scope, direction = "both",
                        k = log(nrow(wine_no_cult)), trace = 0)
cat("=== BIC Both ===")
```

```
## === BIC Both ===
```

```
summary(both_model_BIC)
```

```
##
## Call:
## lm(formula = Alch ~ Prln + Clri, data = wine_no_cult)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -1.31693 -0.40475 -0.02155  0.36010  1.53773
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  1.132e+01  1.235e-01  91.659  < 2e-16 ***
## Prln         1.349e-03  1.386e-04   9.737  < 2e-16 ***
## Clri         1.334e-01  1.882e-02   7.088 3.21e-11 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.5507 on 175 degrees of freedom
## Multiple R-squared:  0.545, Adjusted R-squared:  0.5398
## F-statistic: 104.8 on 2 and 175 DF, p-value: < 2.2e-16
```

Le procedure di selezione hanno prodotto risultati che evidenziano chiaramente la differenza tra i due criteri:

Modelli AIC (backward, forward, both): Tutte e tre le direzioni convergono allo **stesso modello** con 6 predittori: **Mlca, Aloa, Prnt, Clri, Oodw, Prln** ($R^2 = 0.589$, R^2 adj = 0.574). Di questi, cinque sono significativi (Mlca $p=0.005^{**}$, Aloa $p=0.019^*$, Clri $p=1.32e-10^{***}$, Oodw $p=0.008^{**}$, Prln $p=3.76e-10^{***}$), mentre **Prnt** non risulta significativo ($p=0.127$). L'AIC privilegia la capacità esplicativa includendo più variabili, anche se una di esse non raggiunge la soglia di significatività convenzionale.

Modelli BIC: Le tre direzioni producono due specificazioni distinte:

- **BIC backward**: seleziona 4 predittori (**Mlca, Aloa, Clri, Prln**, $R^2 = 0.571$, R^2 adj = 0.561), tutti significativi. Questo modello intermedio rimuove le variabili meno informative (Oodw e Prnt) rispetto al modello AIC, ma mantiene ancora Mlca e Aloa oltre ai due predittori principali.
- **BIC forward e both**: convergono sul modello più parsimonioso con **solo 2 predittori: Prln e Clri** ($R^2 = 0.545$, R^2 adj = 0.540), entrambi altamente significativi (Prln $p<2e-16^{***}$, Clri $p=3.21e-11^{***}$). Nonostante la riduzione del numero di variabili, il modello mantiene una capacità esplicativa elevata (54.5% della varianza), con una perdita minima rispetto ai modelli più complessi (circa 4 punti percentuali rispetto al modello AIC).

La **stabilità di Prln e Clri** è notevole: queste due variabili emergono in **tutti i modelli** indipendentemente dal criterio e dalla direzione, confermandosi come i predittori più robusti del contenuto alcolico.

6.4.1 Confronto con i Modelli Grafici

I risultati delle procedure stepwise forniscono una **validazione quantitativa straordinaria** delle strutture identificate nei modelli grafici:

Grafo indiretto (Capitolo 4, sezione 4.4): Il grafo UG sulla popolazione globale aveva identificato **Clri e Prln** come le uniche variabili con archi diretti verso Alch, dopo aver controllato per tutte le altre variabili chimiche. Il modello **BIC forward/both conferma esattamente questa struttura**: seleziona precisamente e unicamente Prln e Clri come predittori, replicando la topologia del grafo UG in termini quantitativi. Questo risultato dimostra che le dipendenze condizionali identificate dall'analisi grafica corrispondono agli effetti parziali stimati dalla regressione multipla.

Le altre variabili incluse nel modello AIC (Mlca, Aloa, Oodw) o nel modello BIC backward (Mlca, Aloa) contribuiscono marginalmente alla previsione, ma il loro effetto è **secondario** rispetto a quello dei due predittori principali. Questo è coerente con l'assenza di archi diretti verso Alch nel grafo UG: le correlazioni osservate tra Alch e queste variabili nell'analisi esplorativa erano in gran parte **mediate** da Clri e Prln. Il fatto che Prnt venga selezionato dal criterio AIC ma non risulti significativo ($p=0.127$) rafforza ulteriormente questa interpretazione: la sua apparente associazione con Alch è spuria e scompare una volta controllato per gli altri predittori.

DAG vincolato (Capitolo 5, sezione 5.1.2): Il DAG con Alch imposto come nodo sink aveva identificato i **genitori causali diretti** del contenuto alcolico. La coincidenza tra questi genitori e i predittori selezionati dal modello BIC forward/both (Prln e Clri) indica che non solo queste variabili sono associate condizionalmente ad Alch (grafo UG), non solo predicono efficacemente il contenuto alcolico (regressione), ma rappresentano anche i fattori causali immediati secondo l'analisi DAG.

I coefficienti stimati nel modello BIC forward/both quantificano queste relazioni causali:

- **Prln** (prolina, $\beta=0.00135$): Un incremento di 100 unità nella concentrazione di prolina è associato a un aumento medio di 0.135 punti percentuali nel contenuto alcolico, controllando per l'intensità del colore. La prolina, un amminoacido che aumenta con la maturazione dell'uva, è il predittore più forte in termini univariati ($r=0.64$ dal Capitolo 3) e mantiene questo ruolo anche nella regressione multipla.
- **Clri** (intensità del colore, $\beta=0.133$): Un incremento di un'unità nell'intensità del colore è associato a un aumento medio di 0.133 punti percentuali nel contenuto alcolico, controllando per la prolina. Il colore, legato alla concentrazione di antociani e alla maturazione, fornisce informazione predittiva complementare alla prolina.

Otteniamo quindi una **validazione triangolata robusta**: tre approcci metodologici indipendenti (grafi indiretti, DAG, regressione con BIC) convergono sullo stesso insieme minimale di predittori (Prln e Clri), fornendo evidenza coerente di quali variabili chimiche determinano direttamente il contenuto alcolico nel vino.

6.5 Wine Dataset con Cultivar

In questa sezione includiamo la variabile categorica **Cult** per valutare se il tipo di cultivar contribuisce in modo significativo alla previsione del contenuto alcolico, oltre alle proprietà chimiche del vino. Come evidenziato dai modelli grafici (Capitoli 4 e 5), il cultivar presenta connessioni dirette con Alch, suggerendo un potenziale effetto diretto sulla variabile target.

Applichiamo nuovamente le procedure di selezione stepwise con criteri AIC e BIC, questa volta includendo le variabili dummy per il cultivar.

```
# Preparazione dataset con variabili dummy per cultivar
wine_cult <- wine %>%
  mutate(Cult_v2 = as.numeric(Cult == "v2"),
         Cult_v3 = as.numeric(Cult == "v3")) %>%
  select(-Cult) %>%
  as.data.frame()

# Conversione a numeric per compatibilità
wine_cult <- as.data.frame(lapply(wine_cult, as.numeric))

# Definizione del modello nullo
null_model_cult <- lm(Alch ~ 1, data = wine_cult)

# Definizione del modello saturo
full_model_cult <- lm(Alch ~ ., data = wine_cult)

# Definizione dello scope
scope_cult <- list(lower = formula(null_model_cult), upper = formula(full_model_cult))

# ===== AIC =====

# Backward
back_model_cult_AIC <- step(full_model_cult, scope = scope_cult,
                           direction = "backward", trace = 0)
cat("=== AIC Backward (con Cultivar) ===")
```

```
## === AIC Backward (con Cultivar) ===
```

```
summary(back_model_cult_AIC)
```

```
##
## Call:
## lm(formula = Alch ~ Mlca + Ash + Clri + Hue + Cult_v2 + Cult_v3,
##     data = wine_cult)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -1.33440 -0.30934 -0.01978  0.32788  1.56680
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  13.14205    0.48231  27.248  < 2e-16 ***
## Mlca          0.06962    0.04197   1.659   0.0990 .
## Ash         -0.25578    0.14324  -1.786   0.0759 .
## Clri          0.12371    0.02531   4.887 2.34e-06 ***
## Hue           0.38310    0.25164   1.522   0.1298
```

```
## Cult_v2      -1.21023      0.10879 -11.124 < 2e-16 ***
## Cult_v3      -0.77362      0.13705  -5.645 6.75e-08 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.4823 on 171 degrees of freedom
## Multiple R-squared:  0.659, Adjusted R-squared:  0.6471
## F-statistic: 55.08 on 6 and 171 DF,  p-value: < 2.2e-16
```

Forward

```
forw_model_cult_AIC <- step(null_model_cult, scope = scope_cult,
                           direction = "forward", trace = 0)
cat("=== AIC Forward (con Cultivar) ===")
```

```
## === AIC Forward (con Cultivar) ===
```

`summary(forw_model_cult_AIC)`

```
##
## Call:
## lm(formula = Alch ~ Cult_v2 + Cult_v3 + Clri + Ash, data = wine_cult)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -1.12938 -0.30689 -0.02893  0.31972  1.64186
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  13.67754    0.37714   36.266 < 2e-16 ***
## Cult_v2      -1.24623    0.10777  -11.564 < 2e-16 ***
## Cult_v3      -0.79825    0.10462   -7.630 1.51e-12 ***
## Clri          0.10880    0.02425    4.486 1.32e-05 ***
## Ash          -0.21756    0.14262   -1.525  0.129
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.4848 on 173 degrees of freedom
## Multiple R-squared:  0.6514, Adjusted R-squared:  0.6434
## F-statistic: 80.83 on 4 and 173 DF,  p-value: < 2.2e-16
```

Both

```
both_model_cult_AIC <- step(null_model_cult, scope = scope_cult,
                           direction = "both", trace = 0)
cat("=== AIC Both (con Cultivar) ===")
```

```
## === AIC Both (con Cultivar) ===
```

`summary(both_model_cult_AIC)`

```
##
## Call:
## lm(formula = Alch ~ Cult_v2 + Cult_v3 + Clri + Ash, data = wine_cult)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -1.12938 -0.30689 -0.02893  0.31972  1.64186
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  13.67754    0.37714   36.266 < 2e-16 ***
## Cult_v2      -1.24623    0.10777  -11.564 < 2e-16 ***
```

```
## Cult_v3      -0.79825    0.10462   -7.630 1.51e-12 ***
## Clri         0.10880    0.02425    4.486 1.32e-05 ***
## Ash         -0.21756    0.14262   -1.525 0.129
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.4848 on 173 degrees of freedom
## Multiple R-squared:  0.6514, Adjusted R-squared:  0.6434
## F-statistic: 80.83 on 4 and 173 DF,  p-value: < 2.2e-16
```

```
# ===== BIC =====
```

```
# Backward
```

```
back_model_cult_BIC <- step(full_model_cult, scope = scope_cult,
                             direction = "backward",
                             k = log(nrow(wine_cult)), trace = 0)
cat("=== BIC Backward (con Cultivar) ===")
```

```
## === BIC Backward (con Cultivar) ===
```

```
summary(back_model_cult_BIC)
```

```
##
## Call:
## lm(formula = Alch ~ Clri + Cult_v2 + Cult_v3, data = wine_cult)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -1.12074 -0.32721 -0.04133  0.34799  1.54962
##
## Coefficients:
##              Estimate Std. Error t value Pr(>|t|)
## (Intercept)  13.14845    0.14871   88.417 < 2e-16 ***
## Clri          0.10786    0.02434    4.432 1.65e-05 ***
## Cult_v2     -1.20265    0.10431  -11.530 < 2e-16 ***
## Cult_v3     -0.79248    0.10495   -7.551 2.33e-12 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.4866 on 174 degrees of freedom
## Multiple R-squared:  0.6468, Adjusted R-squared:  0.6407
## F-statistic: 106.2 on 3 and 174 DF,  p-value: < 2.2e-16
```

```
# Forward
```

```
forw_model_cult_BIC <- step(null_model_cult, scope = scope_cult,
                             direction = "forward",
                             k = log(nrow(wine_cult)), trace = 0)
cat("=== BIC Forward (con Cultivar) ===")
```

```
## === BIC Forward (con Cultivar) ===
```

```
summary(forw_model_cult_BIC)
```

```
##
## Call:
## lm(formula = Alch ~ Cult_v2 + Cult_v3 + Clri, data = wine_cult)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -1.12074 -0.32721 -0.04133  0.34799  1.54962
```

```
##
## Coefficients:
##           Estimate Std. Error t value Pr(>|t|)
## (Intercept) 13.14845    0.14871  88.417 < 2e-16 ***
## Cult_v2     -1.20265    0.10431 -11.530 < 2e-16 ***
## Cult_v3     -0.79248    0.10495  -7.551 2.33e-12 ***
## Clri         0.10786    0.02434   4.432 1.65e-05 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.4866 on 174 degrees of freedom
## Multiple R-squared:  0.6468, Adjusted R-squared:  0.6407
## F-statistic: 106.2 on 3 and 174 DF,  p-value: < 2.2e-16
```

```
# Both
both_model_cult_BIC <- step(null_model_cult, scope = scope_cult,
                             direction = "both",
                             k = log(nrow(wine_cult)), trace = 0)
cat("=== BIC Both (con Cultivar) ===")
```

```
## === BIC Both (con Cultivar) ===
```

```
summary(both_model_cult_BIC)
```

```
##
## Call:
## lm(formula = Alch ~ Cult_v2 + Cult_v3 + Clri, data = wine_cult)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -1.12074 -0.32721 -0.04133  0.34799  1.54962
##
## Coefficients:
##           Estimate Std. Error t value Pr(>|t|)
## (Intercept) 13.14845    0.14871  88.417 < 2e-16 ***
## Cult_v2     -1.20265    0.10431 -11.530 < 2e-16 ***
## Cult_v3     -0.79248    0.10495  -7.551 2.33e-12 ***
## Clri         0.10786    0.02434   4.432 1.65e-05 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 0.4866 on 174 degrees of freedom
## Multiple R-squared:  0.6468, Adjusted R-squared:  0.6407
## F-statistic: 106.2 on 3 and 174 DF,  p-value: < 2.2e-16
```

L'inclusione del cultivar produce risultati che dimostrano in modo inequivocabile l'importanza del tipo di coltivazione come predittore del contenuto alcolico:

Modelli AIC: Le tre direzioni producono due specificazioni distinte:

- **AIC backward:** seleziona 6 predittori (Mlca, Ash, Clri, Hue, Cult_v2, Cult_v3, $R^2 = 0.659$, R^2 adj = 0.647). Le variabili cultivar sono fortemente significative (Cult_v2 $p < 2e-16^{***}$, Cult_v3 $p = 6.75e-08^{***}$), mentre tra le variabili chimiche solo Clri risulta significativa ($p = 2.34e-06^{***}$). Mlca ($p = 0.099$), Ash ($p = 0.076$) e Hue ($p = 0.130$) hanno contributi marginali o non significativi.
- **AIC forward e both:** convergono su 4 predittori (Cult_v2, Cult_v3, Clri, Ash, $R^2 = 0.651$, R^2 adj = 0.643). Le due dummy cultivar sono altamente significative (Cult_v2 $p < 2e-16^{***}$, Cult_v3 $p = 1.51e-12^{***}$), come anche Clri ($p = 1.32e-05^{***}$), mentre Ash non raggiunge la significatività ($p = 0.129$).

Modelli BIC: Tutte e tre le direzioni (backward, forward, both) convergono allo **stesso modello parsimonioso** con 3 predittori: **Cult_v2, Cult_v3 e Clri** ($R^2 = 0.647$, R^2 adj = 0.641), tutti altamente

significativi (Cult_v2 $p < 2 \times 10^{-16}$ ***, Cult_v3 $p = 2.33 \times 10^{-12}$ ***, Clri $p = 1.65 \times 10^{-5}$ ***).

Risultati chiave:

1. **Stabilità assoluta del cultivar:** Le variabili dummy **Cult_v2** e **Cult_v3** sono selezionate in **tutti e 6 i modelli** (AIC e BIC, tutte le direzioni) con significatività estrema ($p < 2 \times 10^{-12}$ o inferiore). Questo rappresenta la validazione dell'effetto del tipo di coltivazione sul contenuto alcolico.
2. **Scomparsa di Prln:** **Prolina**, che era il predittore più forte nell'analisi senza cultivar (sezione 6.1), **non compare in nessun modello con cultivar**. Questo risultato indica che l'effetto della prolina sul contenuto alcolico è **completamente mediato** dal tipo di cultivar: le differenze di prolina osservate tra i vini sono principalmente dovute alle caratteristiche specifiche di ciascun cultivar.
3. **Persistenza di Clri:** L'**intensità del colore** rimane l'unico predittore chimico selezionato in tutti i modelli BIC e nella maggior parte dei modelli AIC, indicando che Clri fornisce informazione predittiva **indipendente** dal cultivar.
4. **Incremento sostanziale dell' R^2 :** Il modello BIC con cultivar spiega il **64.7% della varianza** ($R^2 = 0.647$), contro il 54.5% del modello BIC senza cultivar. L'aggiunta del cultivar produce un **aumento di oltre 10 punti percentuali** nella capacità esplicativa, confermando che il tipo di coltivazione cattura variabilità sostanziale non spiegata dalle sole proprietà chimiche.

6.5.1 Confronto con i Modelli Grafici (con Cultivar)

I risultati forniscono una **validazione quantitativa straordinaria** delle strutture causali identificate dai modelli grafici:

Grafo indiretto con cultivar (Capitolo 4, sezione 4.5): Il grafo UG aveva rivelato archi diretti **Cult-Alch**, indicando dipendenza condizionale del contenuto alcolico dal cultivar anche dopo aver controllato per tutte le variabili chimiche. Il modello **BIC (3 predittori)** **conferma perfettamente questa struttura**: Cult_v2 e Cult_v3 sono selezionate con Clri come unici predittori, replicando esattamente la topologia del grafo UG. La selezione del cultivar in tutti i 6 modelli, con significatività estrema, dimostra che il grafo UG aveva correttamente identificato un'associazione condizionale **robusta e non spuria** tra Cult e Alch.

DAG vincolato con cultivar (Capitolo 5, sezione 5.2.2): Il DAG aveva identificato **Cult_v2, Cult_v3 e Clri come genitori diretti di Alch**, implicando effetti causali diretti sul contenuto alcolico. La regressione quantifica questi effetti causali nel modello BIC:

- **Cult_v2** ($\beta = -1.20$): I vini del Cultivar 2 hanno un contenuto alcolico mediamente **1.20 punti percentuali inferiore** rispetto al Cultivar 1 (baseline), controllando per l'intensità del colore. Questo coefficiente negativo altamente significativo ($p < 2 \times 10^{-16}$ ***) conferma che il Cultivar 2 produce vini con minore gradazione alcolica, coerentemente con l'analisi esplorativa (Capitolo 3).
- **Cult_v3** ($\beta = -0.79$): I vini del Cultivar 3 hanno un contenuto alcolico mediamente **0.79 punti percentuali inferiore** rispetto al Cultivar 1, controllando per il colore ($p = 2.33 \times 10^{-12}$ ***). Il coefficiente intermedio rispetto a Cult_v2 conferma la gerarchia osservata: Cultivar 1 > Cultivar 3 > Cultivar 2.
- **Clri** ($\beta = 0.108$): L'intensità del colore mantiene un effetto positivo ($p = 1.65 \times 10^{-5}$ ***), anche dopo aver controllato per il cultivar. Un aumento unitario nel colore si associa a +0.108 punti percentuali di Alch. Questo conferma che Clri fornisce informazione **complementare** al cultivar, non completamente mediata dal tipo di coltivazione.

I segni e le magnitudini dei coefficienti sono **perfettamente coerenti** con le differenze medie osservate nell'analisi esplorativa e con la struttura causale proposta dal DAG, fornendo una validazione quantitativa completa.

Mediazione della prolina attraverso il cultivar:

Il confronto tra modelli con e senza cultivar rivela un risultato enologicamente rilevante: **Prln**, predittore dominante senza cultivar ($r = 0.64$ univariato, presente in tutti i modelli della sezione 6.1), **scompare completamente** quando si include il cultivar. Questo dimostra che:

1. Le differenze di prolina tra i vini sono principalmente **determinate dal cultivar**: ogni tipo di coltivazione produce uve con caratteristici livelli di prolina
2. L'effetto della prolina sul contenuto alcolico è **mediato** dal tipo di cultivar
3. Il cultivar cattura l'informazione predittiva che, in assenza di questa variabile, veniva erroneamente attribuita alla prolina

Questo è coerente con la struttura causale del DAG: $\mathbf{Cult} \rightarrow \mathbf{Prln} \rightarrow \mathbf{Alch}$ e $\mathbf{Cult} \rightarrow \mathbf{Alch}$ (effetto diretto). Quando includiamo Cult nella regressione, la variabile Prln diventa ridondante perché la variabile Cult cattura sia l'effetto diretto che quello mediato da Prln.

Otteniamo quindi una **convergenza perfetta** tra i tre approcci metodologici: il grafo UG aveva identificato Cult e Clri come connessi ad Alch, il DAG li aveva identificati come genitori causali, e la regressione quantifica esattamente questi effetti, confermando una validazione triangolata completa.

7 Conclusioni

Questo studio ha investigato le relazioni tra la composizione chimica del vino, il tipo di cultivar e il contenuto alcolico utilizzando un approccio statistico multilivello che integra analisi esplorativa, modelli grafici (indiretti e diretti) e regressione lineare multipla. L'obiettivo principale era identificare i fattori chimici e biologici che determinano il contenuto alcolico nei vini, quantificandone l'entità e validando le relazioni attraverso metodologie complementari.

L'**analisi esplorativa** (Capitolo 3) ha rivelato una struttura complessa di correlazioni tra le 13 variabili chimiche, con **Prln** (prolina, $r=0.64$) e **Clri** (intensità del colore, $r=0.55$) emergenti come i predittori marginali più forti del contenuto alcolico. Tuttavia, l'elevata multicollinearità tra i composti fenolici e l'eterogeneità delle correlazioni tra cultivar hanno suggerito la necessità di distinguere tra associazioni marginali spurie e dipendenze condizionali effettive.

I **modelli grafici indiretti** (Capitolo 4) hanno permesso di identificare le dipendenze condizionali controllando per l'effetto di tutte le altre variabili. Il grafo UG sulla popolazione globale ha isolato **Prln** e **Clri** come le uniche variabili connesse direttamente ad Alch, indicando che molte correlazioni osservate nell'analisi bivariata erano mediate da queste due variabili. L'inclusione del cultivar ha rivelato un arco diretto **Cult-Alch**, suggerendo un effetto del tipo di coltivazione non completamente spiegato dalle proprietà chimiche.

I **DAG vincolati** (Capitolo 5), imponendo Alch come variabile sink, hanno aggiunto la dimensione causale all'analisi. Nel modello senza cultivar, i genitori di Alch corrispondevano ai predittori identificati dal grafo UG. Nel modello con cultivar, **Cult_v2**, **Cult_v3** e **Clri** sono emersi come genitori diretti di Alch, confermando che il cultivar esercita un effetto causale diretto sul contenuto alcolico, non completamente mediato dalle variabili chimiche misurate.

La **regressione lineare multipla** (Capitolo 6) ha fornito la quantificazione di queste relazioni. Il modello BIC più parsimonioso senza cultivar ha selezionato **Prln** e **Clri** ($R^2=54.5\%$), replicando esattamente la struttura del grafo UG. Con l'inclusione del cultivar, il modello ottimale comprende **Cult_v2** ($\beta=-1.20$), **Cult_v3** ($\beta=-0.79$) e **Clri** ($\beta=0.108$) ($R^2=64.7\%$), con Prln che scompare completamente dai modelli selezionati. Questo risultato dimostra che l'effetto della prolina è **mediato** dal cultivar: le differenze di prolina tra i vini sono principalmente determinate dal tipo di coltivazione.

L'incremento di oltre 10 punti percentuali nell' R^2 (da 54.5% a 64.7%) quantifica il contributo sostanziale del cultivar alla previsione del contenuto alcolico. I coefficienti negativi e altamente significativi di Cult_v2 e Cult_v3 confermano la gerarchia osservata nell'analisi esplorativa: **Cultivar 1 > Cultivar 3 > Cultivar 2** in termini di contenuto alcolico medio.

Un risultato metodologico cruciale è la **validazione triangolata** delle relazioni identificate: i grafi indiretti hanno isolato le dipendenze condizionali, i DAG hanno specificato le direzioni causali plausibili, e la regressione ha quantificato gli effetti parziali. La convergenza perfetta tra questi tre approcci indipendenti fornisce evidenza robusta che le relazioni identificate riflettono strutture di dipendenza e causalità nei dati.

Dal punto di vista **enologico**, i risultati confermano che l'effetto del cultivar sul contenuto alcolico non è riducibile alle sole caratteristiche chimiche dell'uva misurate, ma include un'influenza diretta attraverso meccanismi biologici e biochimici non completamente catturati dalle 13 variabili considerate. Questi potrebbero includere differenze nei processi fermentativi, nella composizione microbiologica o in altre proprietà biochimiche specifiche del cultivar.

In conclusione, questo studio dimostra l'efficacia di un approccio statistico integrato per l'analisi di dati enologici complessi, evidenziando come l'integrazione di metodi esplorativi, grafici e predittivi possa fornire una comprensione approfondita delle relazioni tra composizione chimica, caratteristiche biologiche e qualità del vino.

8 Riferimenti bibliografici

[1] S. Aeberhard and M. Forina. Wine. UCI Machine Learning Repository, 1992. DOI: <https://doi.org/10.24432/C5PC7J>.